โครงงานทางสถิติ

เรื่อง

การวิเคราะห์และพยากรณ์ความต้องการใช้ไฟฟ้าในภาคใต้โดยใช้แบบจำลองอนุกรมเวลา

จัดทำโดย

นางสาวนลินนิภา วัชรสินธุ์ รหัสนักศึกษา 6610210641

นางสาวอัมพิกา ประทุมทอง รหัสนักศึกษา 6610210813

โครงงานตามหลักสูตรวิทยาศาสตร์บัณฑิต สาขาสถิติ

ภาควิชาคณิตศาสตร์และสถิติ คณะวิทยาศาสตร์ มหาวิทยาลัยสงขลานครินทร์

ภาคการเรียนที่ 2 ปีการศึกษา 2569

บทที่1

บริบทของข้อมูล แหล่งข้อมูล และคุณภาพข้อมูล

1.1 บริบทของข้อมูล (Domain Context)

พลังงานไฟฟ้าเป็นปัจจัยพื้นฐานที่มีความสำคัญต่อการดำเนินชีวิตของประชาชน การพัฒนาเศรษฐกิจ และการดำเนินกิจกรรมในทุกภาคส่วน ไม่ว่าจะเป็นภาคอุตสาหกรรม ภาคธุรกิจ ภาคบริการ และภาคครัวเรือน ดังนั้นการบริหารจัดการระบบไฟฟ้าให้มีประสิทธิภาพจึงจำเป็นต้องอาศัยการวางแผนการผลิตและการกระจายพลังงานไฟฟ้าให้เพียงพอกับความต้องการในแต่ละช่วงเวลา เพื่อให้ระบบไฟฟ้ามีเสถียรภาพและสามารถรองรับความต้องการได้อย่างเหมาะสม

การพยากรณ์ความต้องการใช้ไฟฟ้า (Electricity Demand Forecasting) เป็นหนึ่งในหัวข้อสำคัญของการวิเคราะห์ข้อมูลอนุกรมเวลา (Time Series Analysis) เนื่องจากความต้องการใช้ไฟฟ้ามีการเปลี่ยนแปลงตามเวลา และมักมีรูปแบบที่ชัดเจน เช่น แนวโน้ม (Trend) และฤดูกาล (Seasonality) โดยเฉพาะในระดับรายชั่วโมง ซึ่งสามารถสะท้อนพฤติกรรมการใช้ไฟฟ้าในแต่ละช่วงของวันได้ เช่น ช่วงกลางวัน ช่วงเย็น และช่วงกลางคืน

ภาคใต้ของประเทศไทยมีลักษณะภูมิอากาศแบบร้อนชื้น ส่งผลให้มีความต้องการใช้ไฟฟ้าสำหรับเครื่องปรับอากาศอย่างต่อเนื่องตลอดทั้งปี อีกทั้งยังเป็นพื้นที่เศรษฐกิจด้านการท่องเที่ยวและบริการ ทำให้รูปแบบการใช้ไฟฟ้ามีความแตกต่างระหว่างวันทำงานและวันหยุดรวมถึงมีความผันผวนตามกิจกรรมทางเศรษฐกิจและพฤติกรรมของผู้บริโภค

อย่างไรก็ตาม การศึกษาการพยากรณ์ความต้องการใช้ไฟฟ้าในระดับรายชั่วโมงในบริบทภาคใต้ยังมีจำนวนจำกัดและยังขาดการเปรียบเทียบประสิทธิภาพของแบบจำลองพยากรณ์ในเชิงระบบ ดังนั้น การศึกษานี้จึงมุ่งเน้นการวิเคราะห์ข้อมูลความต้องการใช้ไฟฟ้าในระดับรายชั่วโมง เพื่อศึกษารูปแบบและองค์ประกอบของข้อมูลอนุกรมเวลาและพัฒนาแบบจำลองสำหรับการพยากรณ์ในระยะสั้น

ข้อมูลที่ใช้ในการศึกษานี้ครอบคลุมช่วงเวลา ตั้งแต่มกราคม ค.ศ. 2023 ถึงเดือนสิงหาคม ค.ศ. 2023 รวมทั้งสิ้นประมาณ 8 เดือน หรือประมาณ 5,831 ชั่วโมง ซึ่งเพียงพอสำหรับการวิเคราะห์รูปแบบรายวัน (Daily Seasonality: 24 ชั่วโมง)

ข้อมูลมีลักษณะเป็นอนุกรมเวลา (Time Series) ในโดเมนเวลา โดยมีความถี่รายชั่วโมง (Hourly Frequency) และมีหน่วยเป็นเมกะวัตต์ (Megawatt: MW) ทั้งนี้ ได้กำหนด seasonal period เท่ากับ 24 ชั่วโมง (s = 24) เพื่อสะท้อนรูปแบบฤดูกาลรายวันอย่างชัดเจน การเลือกใช้ seasonal period เท่ากับ 24 ชั่วโมงเป็นค่าเริ่มต้น มีเหตุผลดังนี้ 1.ข้อมูลมีความถี่รายชั่วโมง ทำให้รูปแบบการใช้ไฟฟ้าในแต่ละวันมีความชัดเจน 2.พฤติกรรมการใช้ไฟฟ้ามีความสัมพันธ์กับกิจกรรมประจำวัน เช่น ช่วงเช้า ช่วงกลางวัน และช่วงเย็น 3.การตั้งค่า s = 24 ช่วยให้แบบจำลอง Holt-Winters และ Exponential Smoothing สามารถจับรูปแบบรายวันได้อย่างมีประสิทธิภาพ 4.เป็นค่า seasonal period มาตรฐานสำหรับข้อมูลโหลดไฟฟ้ารายชั่วโมงในงานวิจัยด้านพลังงาน

ข้อมูลรายชั่วโมงดังกล่าวใช้เขตเวลาเป็นเวลาประเทศไทย (Thailand Standard Time: UTC+7) และไม่มีการปรับเวลา Daylight Saving Time ทำให้ข้อมูลมีความต่อเนื่องของช่วงเวลาอย่างสม่ำเสมอและเหมาะสมสำหรับการวิเคราะห์อนุกรมเวลาโดยไม่ต้องปรับแก้ค่าเวลาเพิ่มเติม

ผลลัพธ์จากการพยากรณ์สามารถนำไปใช้สนับสนุนการวางแผนการผลิตไฟฟ้า (Generation Planning) และการบริหารจัดการโหลดไฟฟ้า (Load Management) เพื่อเพิ่มประสิทธิภาพของระบบไฟฟ้าและลดความเสี่ยงจากการผลิตไฟฟ้าไม่เพียงพอ

1.2 วัตถุประสงค์ของการศึกษา (Objectives)

1. เพื่อศึกษาลักษณะและรูปแบบของข้อมูลความต้องการใช้ไฟฟ้าในภาคใต้ของประเทศไทย

2. เพื่อวิเคราะห์องค์ประกอบของอนุกรมเวลา ได้แก่ แนวโน้ม (Trend) และฤดูกาล (Seasonality)

3. เพื่อพัฒนาและประมาณค่าแบบจำลองพยากรณ์ความต้องการใช้ไฟฟ้าโดยใช้เทคนิคอนุกรมเวลาและกำหนดค่าพารามิเตอร์ที่เหมาะสม

4. เพื่อประเมินและเปรียบเทียบความแม่นยำของแบบจำลอง โดยใช้ตัวชี้วัด ได้แก่ MAE, MSE, RMSE และ MAPE รวมถึงการประเมินแบบ Out-of-sample

5. เพื่อให้กระบวนการวิเคราะห์สามารถทำซ้ำได้ (Reproducibility) โดยใช้ขั้นตอนและเครื่องมือในโปรแกรม Microsoft Excel

1.3 ขอบเขตของการศึกษา (Scope of Study)

1.ใช้ข้อมูลความต้องการใช้ไฟฟ้าในภาคใต้ของประเทศไทย

2.ใช้ข้อมูลในช่วงระยะเวลา 8 เดือน (มกราคม 2023 ถึง สิงหาคม 2023)

3.ใช้ข้อมูลในระดับรายชั่วโมง (Hourly Data)

4.ใช้ตัวแปรหลักเพียงตัวแปรเดียว คือ south_demand

5. มุ่งเน้นการวิเคราะห์แบบอนุกรมเวลาแบบตัวแปรเดียว (Univariate Time Series)

6. ใช้แบบจำลอง เช่น Decomposition Method, Exponential Smoothing และ Holt-Winters Method

7. เป็นการพยากรณ์ระยะสั้น (Short-term Forecasting)

8. แบ่งข้อมูลออกเป็น Training Set และ Test Set ตามลำดับเวลา

9. กำหนด seasonal period เท่ากับ 24 ชั่วโมง เพื่อสะท้อนรูปแบบรายวัน

10. ใช้แบบจำลองพื้นฐาน (Baseline Model) เช่น Naïve Method เพื่อใช้เปรียบเทียบ

11. ใช้เกณฑ์ AIC และ BIC (ในกรณีของแบบจำลองที่สามารถคำนวณได้)

12. ตรวจสอบคุณสมบัติของ Residuals ได้แก่ White Noise, Autocorrelation และ Normality

13. โดยกำหนดช่วงพยากรณ์ล่วงหน้า(Forecast Horizon)

1.4 แหล่งที่มาของข้อมูล (Data Source)

ข้อมูลที่ใช้ในการศึกษานี้มาจากชุดข้อมูลเปิดที่เผยแพร่ผ่านแพลตฟอร์ม Zenodo ซึ่งเป็นคลังข้อมูลวิจัยแบบเปิดที่ใช้สำหรับเผยแพร่ข้อมูลทางวิชาการ โดยชุดข้อมูลที่ใช้คือ Thai Power System: Hourly Power Generation, Demand, and Cross-Border Flows

ข้อมูลดังกล่าวรวบรวมจาก การไฟฟ้าฝ่ายผลิตแห่งประเทศไทย ซึ่งเป็นหน่วยงานหลักที่รับผิดชอบในการบริหารจัดการระบบไฟฟ้าของประเทศไทย โดยชุดข้อมูลประกอบด้วยข้อมูลด้านการผลิตไฟฟ้า (Power Generation) ความต้องการใช้ไฟฟ้า (Electricity Demand) และการแลกเปลี่ยนพลังงานไฟฟ้าระหว่างประเทศ (Cross-Border Flows) ซึ่งเป็นแหล่งข้อมูลที่ได้รับการยอมรับในงานวิจัยด้านพลังงาน และมีความน่าเชื่อถือสูง

ข้อมูลต้นฉบับถูกบันทึกในรูปแบบรายชั่วโมง (Hourly Data) ทำให้สามารถวิเคราะห์การเปลี่ยนแปลงของระบบไฟฟ้าได้อย่างละเอียด ในการศึกษานี้ได้เลือกใช้ข้อมูลเฉพาะช่วงเวลา 8 เดือน เพื่อให้เหมาะสมกับขอบเขตของการวิเคราะห์และการพยากรณ์ระยะสั้น

ข้อมูลดังกล่าวถูกดาวน์โหลดจาก Zenodo (https://zenodo.org/records/17109911) เมื่อวันที่ 17 มีนาคม 2569 และนำเข้าสู่โปรแกรม Microsoft Excel เพื่อทำการวิเคราะห์ ข้อมูลดังกล่าวสามารถเข้าถึงได้แบบสาธารณะ ทำให้สามารถตรวจสอบและทำซ้ำการวิเคราะห์ได้

1.5 โครงสร้างของข้อมูล (Data Structure)

ข้อมูลที่ใช้ในการวิเคราะห์เป็นข้อมูลอนุกรมเวลา (Time Series Data) ซึ่งเป็นข้อมูลที่ถูกบันทึกตามลำดับของเวลาอย่างต่อเนื่อง ในชุดข้อมูลต้นฉบับมีตัวแปรหลายตัวแปรที่เกี่ยวข้องกับระบบไฟฟ้าของประเทศไทย อย่างไรก็ตาม ในการศึกษานี้เลือกใช้เฉพาะตัวแปรที่เกี่ยวข้องกับความต้องการใช้ไฟฟ้าในภาคใต้ของประเทศไทย โดยประกอบด้วยตัวแปรหลัก 2 ตัวแปร ดังนี้

Variable	Type	Unit	Description
Datetime	DateTime	-	วันและเวลาที่บันทึกข้อมูล

south_demand	Numeric	Megawatt (MW)	ปริมาณความต้องการใช้ไฟฟ้าในภาคใต้

ตารางที่ 1 โครงสร้างข้อมูล

รายการ	**รายละเอียด**
ช่วงเวลา	ม.ค. 2023-ส.ค. 2023
ความถี่ข้อมูล	รายชั่วโมง(Hourly)
จำนวนข้อมูล	ประมาณ 5,831 จุด
Seasonal Period	24 ชั่วโมง
ประเภทข้อมูล	Time Series

ตารางที่ 2 คุณลักษณะของข้อมูล

Datetime	south_demand
1/1/2023 00:00	1565.016
1/1/2023 01:00	1618.037
1/1/2023 02:00	1841.558
1/1/2023 03:00	1897.033

ตารางที่ 3 ตัวอย่างข้อมูล

ลักษณะของข้อมูลรายชั่วโมงทำให้สามารถวิเคราะห์รูปแบบการใช้ไฟฟ้าในแต่ละช่วงเวลาต่างๆ ของวันได้ชัดเจน

1.6 การเลือกตัวแปรสำหรับการวิเคราะห์ (Variable Selection)

แม้ว่าชุดข้อมูลต้นฉบับจะมีตัวแปรหลายตัวแปร แต่ในการศึกษานี้เลือกใช้เฉพาะตัวแปร south_demand ซึ่งแสดงถึงปริมาณความต้องการใช้ไฟฟ้าในภาคใต้ของประเทศไทย โดยมีเหตุผลดังนี้

1.สอดคล้องกับวัตถุประสงค์ของการศึกษา ที่มุ่งเน้นการพยากรณ์ความต้องการใช้ไฟฟ้าในภาคใต้

2.เหมาะสมกับการวิเคราะห์แบบ Univariate Time Series ซึ่งใช้ข้อมูลในอดีตของตัวแปรเดียวในการพยากรณ์

3.สอดคล้องกับแบบจำลองที่ใช้ เช่น Decomposition, Exponential Smoothing และ Holt-Winters Method

4.ช่วยลดความซับซ้อนของแบบจำลอง และเอื้อต่อการตีความผลลัพธ์ได้อย่างชัดเจน

5.ข้อมูลรายชั่วโมงสามารถสะท้อนพฤติกรรมการใช้ไฟฟ้าในแต่ละช่วงเวลาได้อย่างละเอียด

6.สามารถวิเคราะห์รูปแบบฤดูกาลทั้งในระดับรายวันและรายสัปดาห์ได้อย่างชัดเจน

7.มีความเกี่ยวข้องกับการใช้งานจริง เช่น การวางแผนการผลิตไฟฟ้าและการบริหารจัดการโหลดไฟฟ้า

การเลือกใช้ตัวแปรเดียวช่วยให้แบบจำลองมีความเรียบง่าย (Parsimony) และลดปัญหาการประมาณค่าพารามิเตอร์จำนวนมากเกินไป อย่างไรก็ตาม การใช้ตัวแปรเดียวอาจทำให้แบบจำลองไม่สามารถอธิบายความผันผวนที่เกิดจากปัจจัยภายนอก (Exogenous Variables) เช่น อุณหภูมิ วันหยุด หรือกิจกรรมทางเศรษฐกิจได้อย่างครบถ้วน ซึ่งถือเป็นข้อจำกัดของการศึกษา

เหตุผลในการเลือกใช้ข้อมูลช่วงเวลา 8 เดือน

ในการศึกษานี้เลือกใช้ข้อมูลเพียงช่วงระยะเวลา 8 เดือน จากข้อมูลทั้งหมด โดยมีเหตุผลสำคัญดังนี้

1.ความเหมาะสมสำหรับการพยากรณ์ระยะสั้น: การศึกษานี้มุ่งเน้นการพยากรณ์ระยะสั้น ซึ่งไม่จำเป็นต้องใช้ข้อมูลระยะยาวหลายปี

2.ลดผลกระทบจากการเปลี่ยนแปลงเชิงโครงสร้าง (Structural Change): การใช้ข้อมูลช่วงเวลาสั้นช่วยลดผลกระทบจากเหตุการณ์หรือการเปลี่ยนแปลงเชิงระบบ เช่น นโยบายพลังงานหรือพฤติกรรมผู้ใช้ไฟฟ้าที่เปลี่ยนไปในระยะยาว

3.ข้อมูลมีความทันสมัย (Recent Data): การใช้ข้อมูลช่วงล่าสุดช่วยให้แบบจำลองสะท้อนพฤติกรรมการใช้ไฟฟ้าในปัจจุบันได้ดีขึ้น

4.เพียงพอสำหรับการวิเคราะห์ Seasonality: แม้จะไม่ครอบคลุมฤดูกาลรายปี แต่ข้อมูล 8 เดือนสามารถครอบคลุมรูปแบบรายวันและรายสัปดาห์ได้หลายรอบ

5.ความเหมาะสมกับขอบเขตของการศึกษา: การจำกัดช่วงข้อมูลช่วยให้การวิเคราะห์และการสร้างแบบจำลองมีความชัดเจนและไม่ซับซ้อนเกินไป

อย่างไรก็ตาม การใช้ตัวแปรเดียว (Univariate) อาจทำให้แบบจำลองไม่สามารถอธิบายความผันผวนที่เกิดจากปัจจัยภายนอก (Exogenous Variables) ได้อย่างครบถ้วน

1.7 การเตรียมข้อมูล (Data Preprocessing)

ก่อนนำข้อมูลไปใช้ในการวิเคราะห์ ได้มีการดำเนินการเตรียมข้อมูล (Data Preprocessing) เพื่อให้ข้อมูลมีความถูกต้องและเหมาะสมสำหรับการสร้างแบบจำลองอนุกรมเวลา โดยมีขั้นตอนดังนี้

1. ตรวจสอบและแปลงรูปแบบของตัวแปรเวลา (Datetime) ให้อยู่ในรูปแบบ DateTime ที่ถูกต้อง

2.จัดเรียงข้อมูลตามลำดับเวลาโดยใช้คำสั่ง Sort (Oldest to Newest)

3.ตรวจสอบค่าที่หายไป (Missing Values) โดยใช้ฟังก์ชัน เช่น COUNTBLANK

4.ตรวจสอบข้อมูลซ้ำ (Duplicate Data) โดยใช้ Conditional Formatting หรือ Remove Duplicates

5. ตรวจสอบค่าผิดปกติ (Outliers) โดยใช้กราฟ Time Series และ Boxplot

6.แบ่งข้อมูลออกเป็น Training Set และ Test Set ตามลำดับเวลา เช่น 80:20

7.ตรวจสอบความสม่ำเสมอของความถี่รายชั่วโมง (Hourly Frequency)

8.กำหนด Datetime เป็นดัชนีเวลา (Time Index)

นอกจากนี้ ได้มีการพิจารณาการแปลงข้อมูล (Data Transformation) เช่น Log Transformation ในกรณีที่ความแปรปรวนของข้อมูลไม่คงที่ รวมถึงการตรวจสอบความจำเป็นของการทำ Smoothing เพื่อช่วยลดความผันผวนของข้อมูลในระยะสั้น

ขั้นตอนการเตรียมข้อมูลดังกล่าวมีวัตถุประสงค์เพื่อให้ข้อมูลมีความถูกต้อง ลดความผิดพลาด และเพิ่มความน่าเชื่อถือของแบบจำลอง โดยทุกขั้นตอนสามารถดำเนินการซ้ำได้ในโปรแกรม Microsoft Excel โดยใช้เครื่องมือมาตรฐาน เช่น Sort, Filter, Conditional Formatting และฟังก์ชันพื้นฐาน

1.8 การประเมินคุณภาพของข้อมูล (Data Quality Assessment)

การประเมินคุณภาพของข้อมูลเป็นขั้นตอนสำคัญก่อนนำข้อมูลไปใช้ในการวิเคราะห์ เนื่องจากคุณภาพของข้อมูลมีผลโดยตรงต่อความแม่นยำของแบบจำลองพยากรณ์ หากข้อมูลมีความผิดพลาดหรือไม่สมบูรณ์ อาจทำให้ผลลัพธ์ของการวิเคราะห์เกิดความคลาดเคลื่อนได้ ดังนั้นจึงได้มีการตรวจสอบคุณภาพของข้อมูลในหลายด้าน ดังนี้

1.ความครบถ้วนของข้อมูล (Data Completeness)

ได้ทำการตรวจสอบค่าที่หายไป (Missing Values) ในตัวแปรหลัก ได้แก่ Datetime และ south_demand เพื่อให้มั่นใจว่าข้อมูลมีความสมบูรณ์ในทุกช่วงเวลา จากการตรวจสอบพบว่า Missing values คิดเป็น 0% ของจำนวนข้อมูลทั้งหมด ไม่มีค่าที่หายไป ข้อมูลมีการบันทึกอย่างครบถ้วนในระดับรายชั่วโมงตลอดช่วงเวลา 8 เดือน จึงไม่จำเป็นต้องดำเนินการเติมค่าข้อมูล (Imputation) เพิ่มเติม

2.ความต่อเนื่องของข้อมูลตามเวลา (Temporal Consistency)

เนื่องจากข้อมูลเป็นข้อมูลอนุกรมเวลาแบบรายชั่วโมง จึงได้มีการตรวจสอบความต่อเนื่องของลำดับเวลา โดยพิจารณาว่ามีช่วงเวลาที่ขาดหาย (Missing Time Steps) หรือมีการซ้ำของเวลา (Duplicate Timestamp) หรือไม่ ผลการตรวจสอบพบว่าข้อมูลมีความต่อเนื่องตามลำดับเวลาอย่างสม่ำเสมอ ไม่มีการข้ามช่วงเวลา และไม่มีข้อมูลซ้ำ จึงสามารถนำไปใช้ในการวิเคราะห์อนุกรมเวลาได้อย่างถูกต้อง

3.ความถูกต้องของรูปแบบข้อมูล (Data Format Consistency)

ได้มีการตรวจสอบรูปแบบของตัวแปร Datetime ให้อยู่ในรูปแบบ DateTime (YYYY-MM-DD HH:MM) ซึ่งเหมาะสมสำหรับการวิเคราะห์ข้อมูลอนุกรมเวลา และสามารถนำไปใช้ในการสร้างดัชนีเวลา (Time Index) ในการวิเคราะห์และสร้างแบบจำลองได้อย่างถูกต้อง

4.ความสมเหตุสมผลของค่าข้อมูล (Data Validity)

ได้ทำการตรวจสอบค่าของตัวแปร south_demand โดยใช้กราฟ Time Series และสถิติเบื้องต้น เพื่อตรวจสอบว่ามีค่าที่ผิดปกติหรือไม่ จากการตรวจสอบพบว่าค่าความต้องการใช้ไฟฟ้าอยู่ในช่วงที่สมเหตุสมผล ไม่มีค่าที่สูงหรือต่ำผิดปกติอย่างรุนแรง และมีรูปแบบการเปลี่ยนแปลงที่ต่อเนื่องตามลักษณะของการใช้ไฟฟ้า

5.การตรวจสอบค่าผิดปกติ (Outlier Detection)

โดยพิจารณาจากค่า Interquartile Range (IQR) ซึ่งเป็นวิธีการตรวจสอบค่าผิดปกติทางสถิติ พบว่าไม่มีค่าที่อยู่นอกช่วง [Q1 - 1.5IQR, Q3 + 1.5IQR] แม้ว่าจะไม่พบค่าผิดปกติที่รุนแรง แต่ได้มีการตรวจสอบค่าที่อาจเบี่ยงเบนจากแนวโน้มโดยรวมของข้อมูล โดยใช้การพิจารณาจากกราฟ Time Series และการเปรียบเทียบกับค่ากลางของข้อมูล พบว่าค่าที่ปรากฏยังอยู่ในช่วงที่สามารถอธิบายได้ตามพฤติกรรมการใช้ไฟฟ้า เช่น ช่วงเวลาที่มีความต้องการใช้ไฟฟ้าสูงในตอนกลางวันหรือช่วงเย็น

6.ความสม่ำเสมอของหน่วยข้อมูล (Data Unit Consistency)

ได้มีการตรวจสอบหน่วยของข้อมูลในตัวแปร south_demand ซึ่งอยู่ในหน่วยเมกะวัตต์ (MW) อย่างสม่ำเสมอตลอดทั้งชุดข้อมูล ไม่พบการเปลี่ยนแปลงของหน่วยหรือความคลาดเคลื่อนของการบันทึกข้อมูล

7.ความเหมาะสมของขนาดข้อมูล (Data Sufficiency)

แม้ว่าข้อมูลจะครอบคลุมระยะเวลาเพียง 8 เดือน แต่เนื่องจากเป็นข้อมูลรายชั่วโมง จึงทำให้มีจำนวนข้อมูลจำนวนมาก (ประมาณ 5,831 จุดข้อมูล) ซึ่งเพียงพอสำหรับการวิเคราะห์แนวโน้ม (Trend) และรูปแบบฤดูกาล (Seasonality) โดยเฉพาะในระดับรายวัน (Daily Seasonality) และราย

สัปดาห์ (Weekly Seasonality) แม้ว่าจะยังไม่ครอบคลุมฤดูกาลรายปี (Yearly Seasonality) แต่ก็เพียงพอสำหรับการพยากรณ์ระยะสั้น

8.ความเหมาะสมสำหรับการสร้างแบบจำลอง (Model Suitability)

ลักษณะของข้อมูลที่มีความต่อเนื่อง มีรูปแบบแนวโน้ม และมีฤดูกาลในระดับรายวันและรายสัปดาห์ ทำให้เหมาะสมสำหรับการนำไปใช้กับแบบจำลองอนุกรมเวลา

9.สรุปผลการประเมินคุณภาพข้อมูล

จากการตรวจสอบในทุกด้านพบว่า ข้อมูลมีความครบถ้วน มีความต่อเนื่องตามลำดับเวลา และมีรูปแบบที่ถูกต้อง อีกทั้งข้อมูลในระดับรายชั่วโมงสามารถสะท้อนพฤติกรรมการใช้ไฟฟ้าได้อย่างละเอียด ทั้งในระดับรายวันและรายสัปดาห์ แม้ว่าจะครอบคลุมเพียงช่วงเวลา 8 เดือน แต่เนื่องจากมีจำนวนข้อมูลจำนวนมาก จึงเพียงพอสำหรับการวิเคราะห์และการสร้างแบบจำลองพยากรณ์ระยะสั้น ดังนั้นข้อมูลชุดนี้จึงมีคุณภาพที่ดีและมีความเหมาะสมสำหรับการนำไปใช้ในการวิเคราะห์อนุกรมเวลาและการพยากรณ์ความต้องการใช้ไฟฟ้าในอนาคต

สมมติฐาน

1.รูปแบบของข้อมูลในอดีตสามารถใช้แทนพฤติกรรมในอนาคตได้ (Stationarity in Pattern)

2.ไม่มีการเปลี่ยนแปลงเชิงโครงสร้างที่รุนแรงในช่วงเวลาที่ศึกษา

ความเสี่ยงของการพยากรณ์

สภาพอากาศ วันหยุดพิเศษ นโยบายพลังงาน เหตุการณ์ไม่คาดคิด ซึ่งไม่ได้รวมอยู่ในแบบจำลอง และอาจส่งผลต่อความแม่นยำของการพยากรณ์การวิเคราะห์ทั้งหมดดำเนินการในโปรแกรม Microsoft Excel โดยกำหนดขั้นตอนอย่างชัดเจน เช่น การแบ่งข้อมูล Training/Test และการตั้งค่าพารามิเตอร์ต่าง ๆ ซึ่งทำให้สามารถทำซ้ำผลการวิเคราะห์ได้อย่างครบถ้วน และมีความเหมาะสมสำหรับการนำไปใช้ในการสร้างแบบจำลองเชิงพยากรณ์

1.9 บทสรุปผู้บริหาร (Executive Summary)

งานวิจัยนี้ศึกษาการพยากรณ์ความต้องการใช้ไฟฟ้าในภาคใต้ของประเทศไทย โดยใช้ข้อมูลอนุกรมเวลารายชั่วโมงช่วงเวลา 8 เดือน จำนวนประมาณ 5,831 จุดข้อมูล

ข้อมูลมีคุณภาพดี ไม่มี Missing values และมีความต่อเนื่องตามลำดับเวลา โดยพบแนวโน้มและฤดูกาลในระดับรายวันและรายสัปดาห์

การศึกษานี้ใช้การวิเคราะห์แบบ Univariate Time Series และพัฒนาแบบจำลอง Exponential Smoothing และ Holt-Winters พร้อมเปรียบเทียบกับแบบจำลองพื้นฐาน (Baseline Model)

ผลลัพธ์สามารถนำไปใช้สนับสนุนการวางแผนการผลิตไฟฟ้าและการบริหารจัดการโหลดไฟฟ้า โดยคำนึงถึงข้อจำกัดของข้อมูลและความเสี่ยงจากปัจจัยภายนอก

บทที่2

การตรวจสอบข้อมูลเบื้องต้นและการทดสอบความนิ่งของข้อมูล

2.1 การวิเคราะห์ลักษณะของข้อมูล (Exploratory Data Analysis)

การตรวจสอบค่าที่หายไป (Missing Values)

เช็ค Missing
missing/NaN
0

พบว่าไม่มีข้อมูลสูญหาย (Missing = 0) แสดงว่าชุดข้อมูลมีความครบถ้วนสมบูรณ์ ไม่จำเป็นต้องดำเนินการจัดการข้อมูลที่หายไป เช่น การแทนค่าหรือการลบข้อมูล และสามารถนำข้อมูลไปใช้ในการวิเคราะห์ขั้นถัดไปได้ทันที ซึ่งช่วยลดความซับซ้อนในขั้นตอนการเตรียมข้อมูล และเพิ่มความน่าเชื่อถือของผลการวิเคราะห์

สถิติเชิงพรรณนา (Descriptive Statistics)

Statistic	Value
Mean	2105.875
Min	1363.2
Max	2787.2
Std	238.6259

ตารางที่ 4 สถิติเชิงพรรณนา

จากการวิเคราะห์ข้อมูลเชิงพรรณนา พบว่า ค่าเฉลี่ย (Mean)ของความต้องการใช้ไฟฟ้าอยู่ที่ประมาณ 2105.875 เมกะวัตต์ แสดงถึงระดับการใช้ไฟฟ้าโดยเฉลี่ย ค่าต่ำสุด (Minimum) เท่ากับ 1363.2 และค่าสูงสุด (Maximum) เท่ากับ 2787.2 ซึ่งสะท้อนให้เห็นถึงช่วงการเปลี่ยนแปลงของความต้องการใช้

ไฟฟ้าที่ค่อนข้างกว้าง โดยมีความแตกต่างระหว่างค่าสูงสุดและค่าต่ำสุดอย่างชัดเจน ส่วนเบี่ยงเบนมาตรฐาน (Standard Deviation) เท่ากับ 238.6259 แสดงให้เห็นว่าข้อมูลมีการกระจายตัวในระดับปานกลาง

โดยรวมแล้ว สถิติเชิงพรรณนาชี้ให้เห็นว่าข้อมูลมีความแปรปรวนในระดับเหมาะสม และมีช่วงค่าที่สอดคกับลักษณะของข้อมูลการใช้ไฟฟ้าจริง จึงเหมาะสมสำหรับการนำไปวิเคราะห์ด้วยแบบจำลองอนุกรมเวลา

การวิเคราะห์กราฟอนุกรมเวลา (Time Series Plot)

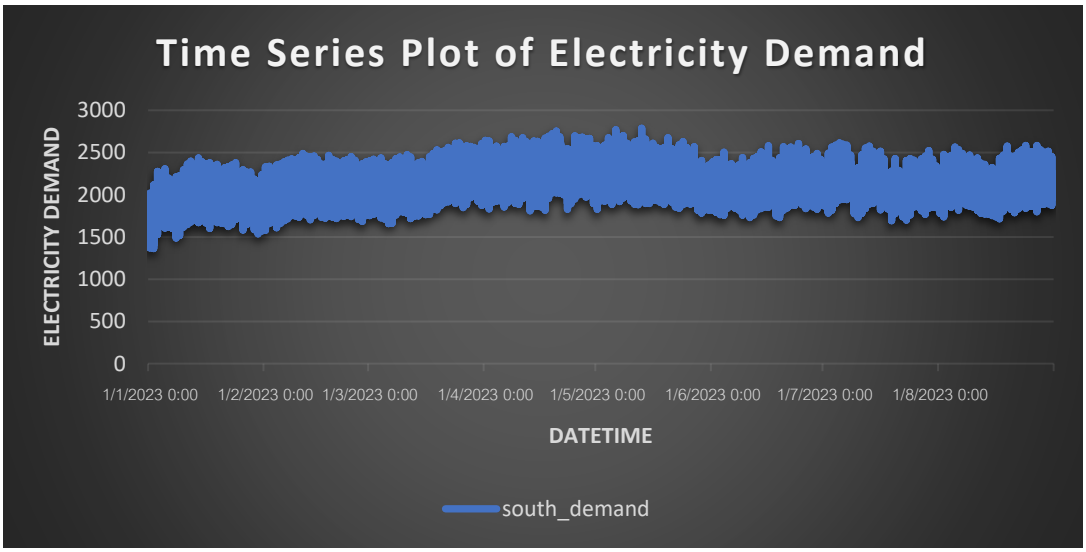

จากกราฟอนุกรมเวลา (Time Series Plot) แสดงความต้องการใช้ไฟฟ้า พบว่า ค่าความต้องการไฟฟ้ามีการเปลี่ยนแปลงอย่างต่อเนื่องตลอดช่วงเวลาที่ศึกษา โดยมีลักษณะขึ้นลงเป็นช่วง ๆ อย่างชัดเจน นอกจากนี้ยังพบแนวโน้มเพิ่มขึ้นในช่วงต้นไปจนถึงกลางช่วงเวลา และเริ่มมีความผันผวนลดลงเล็กน้อยในช่วงท้าย โดยค่าความต้องการไฟฟ้ามีช่วงประมาณ 1,300 ถึง 2,800 เมกะวัตต์ ซึ่งสอดคล้องกับผลการวิเคราะห์เชิงพรรณนา

ลักษณะดังกล่าวบ่งชี้ว่าข้อมูลมีทั้ง แนวโน้ม (Trend) และ ความผันผวนตามเวลา จึงเหมาะสมสำหรับการนำไปวิเคราะห์แบบจำลองอนุกรมเวลา

การวิเคราะห์ฤดูกาลรายวัน (Daily Seasonality)

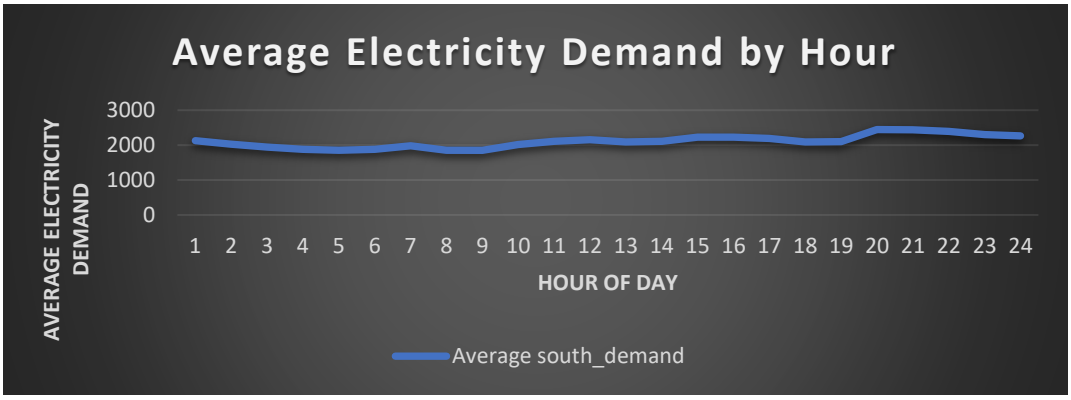

จากกราฟค่าเฉลี่ยความต้องการใช้ไฟฟ้าในแต่ละชั่วโมง พบว่ามีรูปแบบการใช้ไฟฟ้ามีรูปแบบฤดูกาลรายวัน (Daily Seasonality) อย่างชัดเจน โดยค่าความต้องการไฟฟ้าจะต่ำในช่วงเช้ามืด (ประมาณ 04.00–06.00 น.) จากนั้นจะเพิ่มขึ้นในช่วงกลางวัน และมีค่าสูงสุดในช่วงเย็นถึงค่ำ (ประมาณ 19.00–21.00 น.) ซึ่งเป็นช่วงที่มีการใช้ไฟฟ้าสูงสุด หลังจากนั้นค่าจะลดลงอีกครั้งในช่วงกลางคืน รูปแบบดังกล่าวสะท้อนถึงพฤติกรรมการใช้ไฟฟ้าในชีวิตประจำวันของผู้บริโภค และถือเป็นลักษณะสำคัญของข้อมูลอนุกรมเวลาในระบบพลังงานไฟฟ้า

โดยรูปแบบดังกล่าวเกิดซ้ำทุก 24 ชั่วโมง (s = 24) ซึ่งเป็นลักษณะของ Daily Seasonality

การวิเคราะห์การกระจายตัวของข้อมูล (Histogram)

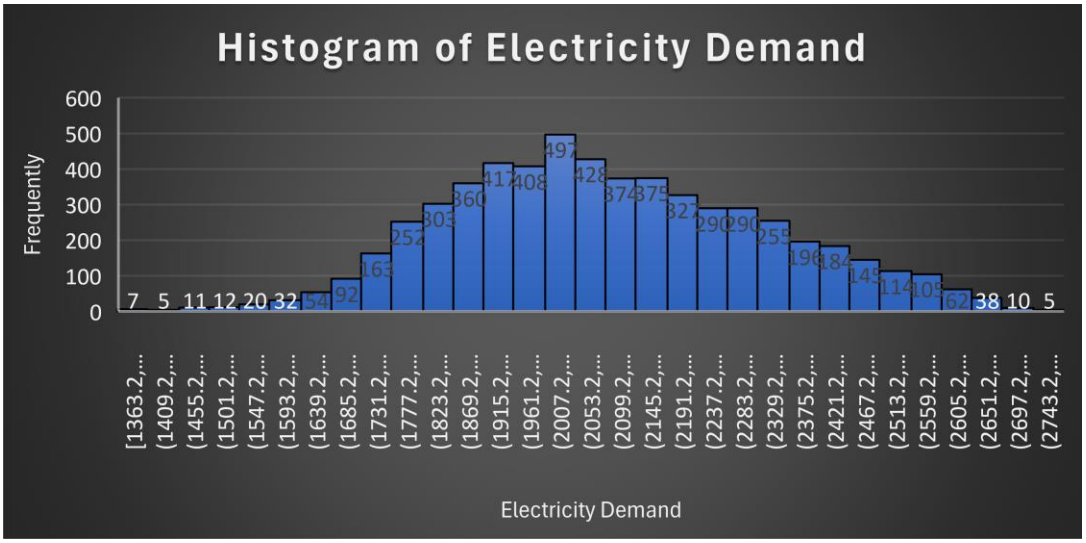

จากกราฟ Histogram พบว่าข้อมูลมีลักษณะการกระจายแบบ ใกล้เคียงการแจกแจงปกติ (Normal distribution) โดยค่าข้อมูลส่วนใหญ่กระจุกตัวอยู่ในช่วงประมาณ 1,900 – 2,300 เมกะวัตต์ ซึ่งใกล้เคียงกับค่าเฉลี่ยที่คำนวณได้และมีการกระจายออกไปทั้งด้านค่าต่ำและค่าสูงอย่างสมดุลและมีจำนวนค่าที่อยู่สุดขอบค่อนข้างน้อย แสดงให้เห็นว่าข้อมูลมีความแปรปรวนในระดับปานกลางและไม่มีค่าผิดปกติที่รุนแรง

การวิเคราะห์ค่าผิดปกติ (Boxplot)

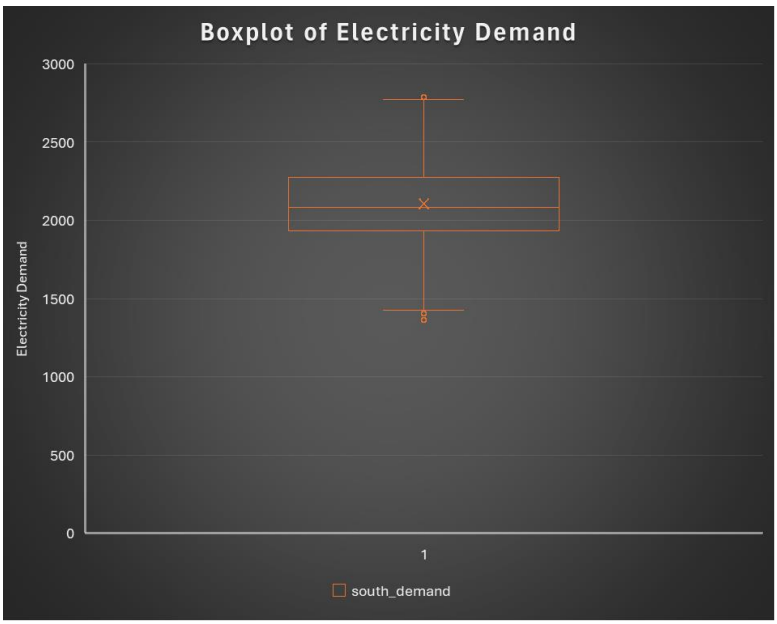

จากกราฟ Boxplot พบว่า ค่ามัธยฐาน (Median) ของความต้องการใช้ไฟฟ้าอยู่ใกล้เคียงกับค่าเฉลี่ย (ประมาณ 2,100 เมกะวัตต์) โดยข้อมูลส่วนใหญ่กระจายตัวอยู่ในช่วงระหว่างควอไทล์ที่ 1 ถึงควอไทล์ที่ 3 (IQR) ซึ่งแสดงถึงช่วงค่าปกติของข้อมูล นอกจากนี้ยังพบ ค่าผิดปกติ (Outliers) บางค่าโดยเฉพาะในช่วงค่าต่ำ ซึ่งอาจเกิดจากช่วงเวลาที่มีการใช้ไฟฟ้าน้อยผิดปกติ แต่ค่าดังกล่าวไม่ได้ส่งผลกระทบต่อโครงสร้างโดยรวมของข้อมูล และยังสามารถอธิบายได้ตามพฤติกรรมการใช้ไฟฟ้าในบางช่วงเวลา

2.2 การทดสอบความนิ่งของข้อมูล (Stationarity Test)

การทดสอบความนิ่งของข้อมูลเป็นขั้นตอนสำคัญในการวิเคราะห์อนุกรมเวลา เนื่องจากแบบจำลองหลายประเภทต้องการข้อมูลที่มีคุณสมบัติทางสถิติคงที่ (Stationary) กล่าวคือ ค่าเฉลี่ย ความแปรปรวน และโครงสร้างความสัมพันธ์ของข้อมูลไม่เปลี่ยนแปลงตามเวลา หากข้อมูลไม่เป็น Stationary อาจส่งผลให้แบบจำลองพยากรณ์มีความคลาดเคลื่อนและไม่สามารถอธิบายรูปแบบของข้อมูลได้อย่างถูกต้อง

ในการศึกษานี้ใช้วิธี Augmented Dickey-Fuller (ADF) Test เพื่อทดสอบความนิ่งของข้อมูล โดยทำการทดสอบกับชุดข้อมูลฝึกสอน (Training Set) ในช่วงเดือนมกราคมถึงมิถุนายน พ.ศ. 2566 ซึ่งเป็นช่วงข้อมูลที่ใช้ในการสร้างแบบจำลอง

รายการทดสอบ	ค่าสถิติ(Value)
ADF Test Statistic	-4.169
p-value	0.0007
Critical Value (1%)	-3.432
Critical Value (5%)	-2.862

ตารางที่ 5 ADF Test

สมมติฐานของการทดสอบ Augmented Dickey-Fuller (ADF Test)

H_0: ข้อมูลไม่เป็น Stationary

H_1: ข้อมูลเป็น Stationary

ผลการทดสอบพบว่า ค่าสถิติทดสอบ (ADF Statistic) เท่ากับ -4.169 ซึ่งมีค่าน้อยกว่า ค่าวิกฤต (Critical Value) ที่ระดับนัยสำคัญ 0.05 (ซึ่งเท่ากับ -2.862) และเมื่อพิจารณาค่า p-value พบว่ามีค่าเท่ากับ 0.0007 ซึ่งน้อยกว่า 0.05 อย่างมีนัยสำคัญทางสถิติ ดังนั้นสามารถปฏิเสธสมมติฐานหลัก (H_0) และสรุปได้ว่าข้อมูลเป็น Stationary ในเชิงสถิติ (Statistically Stationary) แต่ยังมีองค์ประกอบของฤดูกาล (Seasonality)

อย่างไรก็ตาม จากการวิเคราะห์กราฟอนุกรมเวลาและกราฟฤดูกาล พบว่าข้อมูลยังคงมีองค์ประกอบของฤดูกาลรายวัน (Daily Seasonality) อย่างชัดเจน ซึ่งหมายความว่าข้อมูลมีลักษณะเป็นอนุกรมเวลาที่มีฤดูกาล (Seasonal Time Series) มากกว่าการเป็น Stationary อย่างสมบูรณ์

ดังนั้น แม้ว่าข้อมูลจะผ่านการทดสอบ Stationarity ในเชิงสถิติ แต่เนื่องจากยังมีฤดูกาลที่ชัดเจน จึงเหมาะสมสำหรับการใช้แบบจำลองที่สามารถรองรับทั้งแนวโน้มและฤดูกาล เช่น Holt-Winters Method และ Additive Decomposition Model

2.3 การแบ่งข้อมูล (Train-Test Split)

ในการศึกษานี้ได้แบ่งข้อมูลออกเป็น 2 ส่วน ได้แก่ ชุดข้อมูลฝึกสอน (Training Set) และชุดข้อมูลทดสอบ (Test Set) โดยใช้วิธีการแบ่งตามลำดับเวลา (Time-based Split) ซึ่งสอดคล้องกับลักษณะของข้อมูลอนุกรมเวลา และช่วยป้องกันการรั่วไหลของข้อมูลในอนาคต (Data Leakage)

Training Set: ใช้ข้อมูลช่วง 6 เดือนแรก

Test Set: ใช้ข้อมูลช่วง 2 เดือนสุดท้าย

ชุดข้อมูล Training ใช้สำหรับสร้างแบบจำลองและประมาณค่าพารามิเตอร์ ขณะที่ชุดข้อมูล Test ใช้สำหรับประเมินความสามารถในการพยากรณ์ของแบบจำลอง เพื่อให้ได้ผลลัพธ์ที่สะท้อนประสิทธิภาพของแบบจำลองกับข้อมูลใหม่ได้อย่างเหมาะสม

การแบ่งข้อมูลตามลำดับเวลามีความสำคัญในการวิเคราะห์อนุกรมเวลา เนื่องจากข้อมูลในอนาคตไม่ควรถูกนำมาใช้ในการฝึกแบบจำลอง ซึ่งจะช่วยให้การประเมินผลมีความสมจริงและสะท้อนการใช้งานจริง

2.4 แบบจำลองที่ใช้ในการพยากรณ์

ในการศึกษานี้ได้เลือกใช้แบบจำลองอนุกรมเวลาเพื่อเปรียบเทียบประสิทธิภาพในการพยากรณ์ความต้องการใช้ไฟฟ้า จำนวน 4 แบบ ได้แก่

1.Naive Model เป็นแบบจำลองพื้นฐานที่ใช้ค่าล่าสุดเป็นค่าพยากรณ์ของช่วงเวลาถัดไป เหมาะสำหรับใช้เป็นเกณฑ์เปรียบเทียบกับแบบจำลองอื่น

2.Simple Exponential Smoothing (SES) เป็นแบบจำลองที่ใช้ค่าเฉลี่ยถ่วงน้ำหนักแบบเอ็กซ์โพเนนเชียลของข้อมูลในอดีต โดยให้ค่าน้ำหนักกับข้อมูลล่าสุดมากกว่าข้อมูลเก่า เหมาะสำหรับข้อมูลที่ไม่มีแนวโน้มและไม่มีฤดูกาล

3.Additive Decomposition Modelเป็นแบบจำลองที่แยกองค์ประกอบของข้อมูลออกเป็น Trend, Seasonality และ Residual โดยใช้รูปแบบการรวมแบบบวก (Additive) เหมาะสำหรับข้อมูลที่มีฤดูกาลและแนวโน้ม

4.Holt-Winters Additive Methodเป็นแบบจำลองที่ขยายจาก Exponential Smoothing เพื่อรองรับทั้งแนวโน้มและฤดูกาล โดยใช้พารามิเตอร์สามตัว ได้แก่ Level, Trend และ Seasonality เหมาะสำหรับข้อมูลที่มีฤดูกาลรายวันอย่างชัดเจน

2.5 เกณฑ์การประเมินแบบจำลอง

การประเมินและเปรียบเทียบประสิทธิภาพของแบบจำลองใช้ค่าความคลาดเคลื่อน (Error Metrics) ดังนี้

MAE (Mean Absolute Error)

MSE (Mean Squared Error)

RMSE (Root Mean Squared Error)

MAPE (Mean Absolute Percentage Error)

ค่า MAE แสดงค่าเฉลี่ยของความคลาดเคลื่อนแบบค่าสัมบูรณ์

ค่า MSE แสดงค่าเฉลี่ยของความคลาดเคลื่อนยกกำลังสอง

ค่า RMSE เป็นรากที่สองของค่า MSE ซึ่งมีหน่วยเดียวกับข้อมูลจริง

ค่า MAPE แสดงความคลาดเคลื่อนในรูปเปอร์เซ็นต์

ค่าความคลาดเคลื่อนที่ต่ำแสดงถึงแบบจำลองที่มีความแม่นยำในการพยากรณ์สูง ดังนั้นแบบจำลองที่มีค่า Error ต่ำสุดจะถูกเลือกเป็นแบบจำลองที่เหมาะสมที่สุด

2.6 การตรวจสอบค่าคลาดเคลื่อน(Residual Analysis)

หลังจากสร้างแบบจำลองแล้ว ได้มีการตรวจสอบค่า Residual เพื่อประเมินความเหมาะสมของแบบจำลอง โดยพิจารณาคุณสมบัติดังต่อไปนี้

1.ค่าเฉลี่ยของ Residual ใกล้ศูนย์ (White Noise)

2.ไม่มีความสัมพันธ์กันเอง (No Autocorrelation)

3.ความแปรปรวนคงที่ (Homoscedasticity)

4.มีการแจกแจงใกล้เคียงปกติ (Normal Distribution)

หาก Residual เป็นไปตามเงื่อนไขดังกล่าว แสดงว่าแบบจำลองสามารถอธิบายโครงสร้างของข้อมูลได้อย่างเหมาะสม และส่วนที่เหลือเป็นเพียงสัญญาณรบกวนแบบสุ่ม (Random Noise) ซึ่งบ่งชี้ว่าแบบจำลองมีความน่าเชื่อถือในการพยากรณ์

การตรวจสอบ Residual จะช่วยยืนยันว่าแบบจำลองไม่มีรูปแบบที่หลงเหลืออยู่ในข้อมูล และสามารถใช้สำหรับการพยากรณ์ความต้องการใช้ไฟฟ้าในอนาคตได้อย่างเหมาะสม

บทที่ 3

การวิเคราะห์ข้อมูล (Data Analysis)

ในการศึกษาครั้งนี้ ผู้วิจัยได้เลือกใช้แบบจำลองการพยากรณ์อนุกรมเวลา (Time Series Forecasting Models) จำนวน 4 แบบ ได้แก่ Naive Model, Simple Exponential Smoothing (SES), Additive Decomposition Model และ Holt-Winters Additive Method เพื่อเปรียบเทียบประสิทธิภาพของแบบจำลองในการพยากรณ์ข้อมูลความต้องการใช้ไฟฟ้า โดยแต่ละแบบจำลองมีรายละเอียดดังนี้

3.1 แบบจำลองที่ใช้ในการศึกษา

3.1.1 Naive Model

Naive Model เป็นแบบจำลองพยากรณ์พื้นฐาน (Baseline Model) ที่ใช้ค่าจริงของช่วงเวลาก่อนหน้าเป็นค่าพยากรณ์ของช่วงเวลาถัดไป โดยไม่มีการพิจารณาแนวโน้ม (Trend) หรือรูปแบบฤดูกาล (Seasonality) ของข้อมูล แบบจำลองนี้มีโครงสร้างง่ายและไม่ต้องประมาณค่าพารามิเตอร์ใด ๆ

สมการของ Naive Model สามารถเขียนได้ดังนี้

$Ft = Yt\text{-}1$

โดยที่ Ft คือ ค่าพยากรณ์ในช่วงเวลา t

Yt-1 คือ ค่าจริงในช่วงเวลาก่อนหน้า

เหตุผลในการเลือกใช้ Naive Model

แบบจำลองนี้มีโครงสร้างง่าย ไม่ต้องประมาณค่าพารามิเตอร์ และเหมาะสำหรับใช้เป็นค่าอ้างอิง (Benchmark) ในการเปรียบเทียบกับแบบจำลองอื่น หากแบบจำลองที่ซับซ้อนให้ค่าความคลาดเคลื่อนสูงกว่า Naïve Model แสดงว่าแบบจำลองนั้นอาจไม่เหมาะสมกับข้อมูล

3.1.2 Simple Exponential Smoothing (SES)

Simple Exponential Smoothing เป็นแบบจำลองพยากรณ์ที่ใช้ค่าเฉลี่ยถ่วงน้ำหนักแบบเอ็กซ์โพเนนเชียล โดยให้น้ำหนักกับข้อมูลล่าสุดมากกว่าข้อมูลในอดีต ทำให้แบบจำลองสามารถตอบสนองต่อการเปลี่ยนแปลงของข้อมูลได้ดีกว่าวิธีค่าเฉลี่ยธรรมดา

สมการของ Simple Exponential Smoothing คือ

$Ft = \alpha Yt\text{-}1 + (1\text{-}\alpha)Ft\text{-}1$

โดยที่

α คือ ค่าพารามิเตอร์การปรับเรียบ (Smoothing Parameter)

Ft คือ ค่าพยากรณ์ในช่วงเวลา t

Yt-1 คือ ค่าจริงในช่วงเวลาก่อนหน้า

ในการศึกษานี้ได้ทดลองค่า alpha หลายค่า ได้แก่ $\alpha = 0.2$ $\alpha = 0.3$ $\alpha = 0.4$ $\alpha = 0.5$

เพื่อเลือกค่า alpha ที่ให้ค่าความคลาดเคลื่อนต่ำที่สุด

เหตุผลในการเลือกใช้ SES

จากการวิเคราะห์ข้อมูลเบื้องต้นพบว่าข้อมูลมีความผันผวนในระยะสั้น จึงเลือกใช้ SES เพื่อทำ smoothing ข้อมูล และลด noise ที่เกิดขึ้นในข้อมูล นอกจากนี้ SES อย่างไรก็ตาม SES มีข้อจำกัดเนื่องจากไม่สามารถรองรับแนวโน้ม (Trend) และฤดูกาล (Seasonality) ได้ ซึ่งอาจส่งผลให้ค่าพยากรณ์มีความคลาดเคลื่อนสูง

3.1.3 Additive Decomposition Model

Additive Decomposition เป็นวิธีแยกองค์ประกอบของอนุกรมเวลาออกเป็น 3 ส่วน ได้แก่ แนวโน้ม (Trend), ฤดูกาล (Seasonality) และค่าความคลาดเคลื่อน (Residual)

สมการของแบบจำลองคือ

$Y_t = T_t + S_t + e_t$

โดยที่

T_t คือ แนวโน้มระยะยาว

S_t คือ องค์ประกอบฤดูกาล

e_t คือ ค่าความคลาดเคลื่อน

ค่าพยากรณ์สามารถคำนวณได้จาก

Forecast = Trend + Seasonal

เหตุผลในการเลือกใช้ Additive Model

จากการวิเคราะห์ข้อมูลพบว่ารูปแบบฤดูกาลมีค่อนข้างคงที่ จึงเหมาะกับ additive model มากกว่า multiplicative model Additive decomposition สามารถแยกโครงสร้างของข้อมูลออกได้อย่างชัดเจน และช่วยให้เข้าใจ pattern ของข้อมูล ทั้งแนวโน้มและฤดูกาล ทำให้สามารถสร้างค่าพยากรณ์ได้แม่นยำขึ้น

3.1.4 Holt-Winters Additive Method

Holt-Winters Additive เป็นแบบจำลองที่พัฒนาจาก Exponential Smoothing เพื่อรองรับข้อมูลที่มีทั้ง Trend และ Seasonality แบบจำลอง Holt-Winters Additive ประกอบด้วย 3 องค์ประกอบ ได้แก่ Level (Lt), Trend (Tt) และ Seasonal (St)

สมการของแบบจำลอง:

Level: $L_t = \alpha(Y_t - S_{t-s}) + (1-\alpha)(L_{t-1} + T_{t-1})$

Trend: $T_t = \beta(L_t - L_{t-1}) + (1-\beta)T_{t-1}$

Seasonal: $S_t = \gamma(Y_t - L_t) + (1-\gamma)S_{t-s}$

โดยที่ α = smoothing parameter ของ level

β = smoothing parameter ของ trend

γ = smoothing parameter ของ seasonality

ในการศึกษานี้กำหนด seasonal period เท่ากับ 24 ชั่วโมง (s = 24) เนื่องจากข้อมูลมีฤดูกาลรายวัน

เหตุผลในการเลือก Holt-Winters

จากการวิเคราะห์ข้อมูลพบว่าข้อมูลมีทั้งแนวโน้มเพิ่มขึ้น และมีรูปแบบฤดูกาลที่เกิดซ้ำอย่างชัดเจน ทำให้ SES ไม่เพียงพอ จึงเลือกใช้ Holt-Winters additive ซึ่งสามารถรองรับทั้ง trend และ seasonality ได้พร้อมกันนอกจากนี้ Holt-Winters additive เหมาะกับข้อมูลที่ seasonal fluctuation ค่อนข้างคงที่ ซึ่งสอดคล้องกับลักษณะของข้อมูลในการศึกษานี้ จึงคาดว่าจะให้ผลการพยากรณ์ที่แม่นยำที่สุดเมื่อเทียบกับแบบจำลองอื่น

Model	Parameter	Value
SES	α	0.5
Holt-Winters	α	0.2
	β	0.01
	γ	0.2

ตารางที่ 6 พารามิเตอร์ของแบบจำลอง

3.2ข้อจำกัดของการประเมินโมเดล (Model Evaluation Limitation)

เนื่องจากแบบจำลองที่ใช้ในการศึกษานี้เป็นกลุ่ม Exponential Smoothing ซึ่งดำเนินการผ่านโปรแกรม Microsoft Excel และ Minitab ทำให้ไม่สามารถรายงานค่า AIC และ BIC ได้โดยตรง ดังนั้นการเปรียบเทียบแบบจำลองจึงใช้เกณฑ์ความคลาดเคลื่อน (Error-based Criteria) ได้แก่ MAE, MSE และ RMSE ร่วมกับหลักการเลือกแบบจำลองที่มีความสมดุลระหว่างความแม่นยำและความเรียบง่าย (Model Parsimony) แทน

การใช้เกณฑ์ดังกล่าวช่วยให้สามารถประเมินประสิทธิภาพของแบบจำลองได้อย่างเหมาะสม และยังคงสอดคล้องกับแนวทางการเลือกแบบจำลองอนุกรมเวลาในเชิงปฏิบัติ

3.3 เกณฑ์การประเมินประสิทธิภาพแบบจำลอง

ในการศึกษานี้ การประเมินประสิทธิภาพของแบบจำลองพยากรณ์แบ่งออกเป็น 2 ส่วน ได้แก่ การประเมินบนข้อมูลฝึก (In-sample Evaluation) และการประเมินบนข้อมูลทดสอบ (Out-of-sample Evaluation) เพื่อให้สามารถเปรียบเทียบแบบจำลองได้อย่างเหมาะสมและลดความลำเอียงจากการใช้ข้อมูลชุดเดียว

ในหัวข้อนี้จะพิจารณาการประเมินผลบนข้อมูลฝึก (Training Set) ซึ่งใช้สำหรับคัดเลือกแบบจำลองที่เหมาะสมเบื้องต้น โดยใช้ตัวชี้วัดดังต่อไปนี้

1.MAE (Mean Absolute Error) MAE คือ ค่าเฉลี่ยของค่าความคลาดเคลื่อนสัมบูรณ์ระหว่างค่าจริงกับค่าพยากรณ์ ใช้สำหรับวัดความคลาดเคลื่อนเฉลี่ยของแบบจำลอง โดยไม่พิจารณาทิศทางของความคลาดเคลื่อน MAE = average |Actual – Forecast | ค่า MAE ยิ่งต่ำ แสดงว่าแบบจำลองมีความแม่นยำสูง

2.MSE (Mean Squared Error) MSE คือ ค่าเฉลี่ยของค่าความคลาดเคลื่อนกำลังสอง ใช้สำหรับวัดความคลาดเคลื่อนของแบบจำลอง โดยให้ความสำคัญกับความคลาดเคลื่อนที่มีค่ามาก MSE = average (Actual — Forecast)^2 ค่า MSE ยิ่งต่ำ แสดงว่าแบบจำลองมีความแม่นยำสูง

3.RMSE (Root Mean Squared Error) RMSE คือ รากที่สองของค่า MSE ใช้สำหรับวัดความคลาดเคลื่อนในหน่วยเดียวกับข้อมูลจริง ทำให้ง่ายต่อการตีความ RMSE = $\sqrt{\text{MSE}}$ ค่า RMSE ยิ่งต่ำแสดงว่าแบบจำลองพยากรณ์ได้แม่นยำมากขึ้น

แบบจำลอง	**ค่า MAE**	**ค่า MSE**	**ค่า RMSE**
Naïve	82.1094	12276.4993	110.7993
SES	152.0060	32271.0400	179.6414
Holt-Winters Additive	39.9590	2897.1670	53.8253
Additive Decomposition	173.3470	45231.0636	212.6760

ตารางที่ 7 เปรียบเทียบแบบจำลอง (Training Set)

จากตารางเปรียบเทียบค่าความคลาดเคลื่อนของแบบจำลองพยากรณ์ทั้งหมด พบว่าแต่ละแบบจำลองให้ค่าความแม่นยำแตกต่างกันอย่างชัดเจน โดยพิจารณาจากตัวชี้วัด 4 ค่า ได้แก่ Mean Absolute Error (MAE), Mean Squared Error (MSE), Root Mean Squared Error (RMSE)

1.จากผลการวิเคราะห์พบว่าแบบจำลอง Holt-Winters Additive ให้ค่าความคลาดเคลื่อนต่ำที่สุดในทุกตัวชี้วัด โดยมีค่า MAE เท่ากับ 39.9590 ซึ่งเป็นค่าความคลาดเคลื่อนเฉลี่ยที่ต่ำที่สุดเมื่อเทียบกับแบบจำลองอื่น แสดงว่าโดยเฉลี่ยแล้วค่าพยากรณ์จากแบบจำลองนี้มีความแตกต่างจากค่าจริงน้อยที่สุด นอกจากนี้ค่า MSE เท่ากับ 2897.1670 และค่า RMSE เท่ากับ 53.8253 ซึ่งเป็นค่าที่ต่ำที่สุดเช่นเดียวกัน สะท้อนถึงความคลาดเคลื่อนโดยรวมที่อยู่ในระดับต่ำ จึงสามารถสรุปได้ว่าแบบจำลอง Holt-Winters Additive มีความแม่นยำในการพยากรณ์สูงที่สุด

2.แบบจำลอง Naïve ให้ค่าความคลาดเคลื่อนอยู่ในระดับปานกลาง โดยมีค่า MAE เท่ากับ 82.1094 ค่า MSE เท่ากับ 12276.4993 และค่า RMSE เท่ากับ 110.7993 ซึ่งสูงกว่าแบบจำลอง Holt-Winters Additive อย่างชัดเจน แม้แบบจำลอง Naïve จะเป็นแบบจำลองพื้นฐานที่ใช้ค่าก่อนหน้าเป็นค่า

พยากรณ์ และสามารถให้ผลการพยากรณ์ในระดับที่ยอมรับได้ในกรณีที่ข้อมูลมีความต่อเนื่อง แต่เนื่องจากแบบจำลอง Naïve ไม่สามารถอธิบายแนวโน้มและฤดูกาลของข้อมูลได้ จึงส่งผลให้ความแม่นยำของการพยากรณ์ยังต่ำกว่าแบบจำลองที่มีความซับซ้อนมากกว่า

3.แบบจำลอง Simple Exponential Smoothing (SES) ให้ค่าความคลาดเคลื่อนค่อนข้างสูง โดยมีค่า MAE เท่ากับ 152.0060 ค่า MSE เท่ากับ 32271.0400 ค่า RMSE เท่ากับ 179.6414 ซึ่งสูงกว่าแบบจำลอง Naïve และ Holt-Winters อย่างมีนัยสำคัญ เนื่องจาก SES เป็นแบบจำลองที่เหมาะสำหรับข้อมูลที่ไม่มีแนวโน้มและฤดูกาล แต่ข้อมูลในการศึกษานี้มีทั้งแนวโน้มและฤดูกาล ทำให้แบบจำลอง SES ไม่สามารถจับโครงสร้างของข้อมูลได้ครบถ้วน ส่งผลให้ค่าความคลาดเคลื่อนสูงขึ้น

4.แบบจำลอง Additive Decomposition พบว่ามีค่าความคลาดเคลื่อนสูง โดยมีค่า MAE เท่ากับ 173.3470 ค่า MSE เท่ากับ 45231.0636 ค่า RMSE เท่ากับ 212.6760 แสดงว่าให้เห็นว่าแบบจำลองมีประสิทธิภาพในการพยากรณ์ค่อนข้างต่ำ ทั้งนี้อาจเกิดจากข้อจำกัดในการประมาณค่าแนวโน้ม (Trend) และดัชนีฤดูกาล (Seasonal Index) ซึ่งไม่สามารถอธิบายความผันผวนของข้อมูลได้อย่างสมบูรณ์ ทำให้ค่าพยากรณ์มีความคลาดเคลื่อนมากกว่าแบบจำลองอื่น

ดังนั้น จากการเปรียบเทียบค่าความคลาดเคลื่อนของแบบจำลองทั้งหมด สามารถสรุปได้ว่าแบบจำลอง Holt-Winters Additive เป็นแบบจำลองที่เหมาะสมที่สุดสำหรับการพยากรณ์ข้อมูลในงานวิจัยนี้ เนื่องจากให้ค่าความคลาดเคลื่อนต่ำที่สุดในทุกตัวชี้วัด และสามารถอธิบายโครงสร้างของข้อมูลที่มีทั้งแนวโน้มและฤดูกาลได้อย่างมีประสิทธิภาพ ผู้วิจัยจึงเลือกใช้แบบจำลองดังกล่าวในการพยากรณ์ข้อมูลในขั้นตอนถัดไป รวมถึงการวิเคราะห์ค่าคลาดเคลื่อน (Residual Analysis) เพื่อประเมินความเหมาะสมของแบบจำลองต่อไป

อย่างไรก็ตาม การประเมินผลบนข้อมูลฝึกเพียงอย่างเดียวอาจทำให้เกิดปัญหา overfitting กล่าวคือ แบบจำลองอาจเหมาะสมกับข้อมูลในอดีต แต่ไม่สามารถพยากรณ์ข้อมูลใหม่ได้อย่างแม่นยำ ดังนั้น

จึงจำเป็นต้องมีการประเมินเพิ่มเติมบนข้อมูลทดสอบ (Test Set) โดยใช้ตัวชี้วัด เช่น MAE, RMSE และ MAPE ซึ่งจะกล่าวถึงในหัวข้อถัดไป

3.4 การวินิจฉัยความเหมาะสมของแบบจำลอง(Model Diagnostic)

การวินิจฉัยความเหมาะสมของแบบจำลองเป็นขั้นตอนสำคัญในการตรวจสอบว่าแบบจำลองสามารถอธิบายโครงสร้างของข้อมูลได้อย่างเหมาะสมหรือไม่ โดยพิจารณาจากลักษณะของค่าคลาดเคลื่อน (Residuals) ว่ามีคุณสมบัติเป็นแบบสุ่ม (White Noise) หรือไม่ กล่าวคือ ค่าคลาดเคลื่อนควรมีค่าเฉลี่ยใกล้ศูนย์ เป็นอิสระต่อกัน (ไม่มี Autocorrelation) ไม่มีรูปแบบของแนวโน้ม (Trend) หรือฤดูกาล (Seasonality) และมีความแปรปรวนคงที่ หากเป็นไปตามเงื่อนไขดังกล่าว แสดงว่าแบบจำลองมีความเหมาะสมสำหรับการพยากรณ์

ในการศึกษานี้ ได้ทำการตรวจสอบแบบจำลองทั้ง 4 แบบ ได้แก่ Naive Model, Simple Exponential Smoothing (SES), Additive Decomposition และ Holt-Winters Additive โดยพิจารณาใน 3 ด้านหลัก ได้แก่

1.ค่าสถิติของค่าคลาดเคลื่อน

2.การแจกแจงของค่าคลาดเคลื่อน

3.สหสัมพันธ์ในตัวเอง (Autocorrelation)

1. การตรวจสอบความเป็น White Noise และค่าสถิติพื้นฐาน

จากการวิเคราะห์สถิติเชิงพรรณนาของค่าคลาดเคลื่อน พบว่าแบบจำลองส่วนใหญ่มีค่าเฉลี่ยเข้าใกล้ศูนย์ อย่างไรก็ตามมีความแตกต่างกันในด้านการกระจายตัว

แบบจำลอง Holt-Winters Additive มีค่าเฉลี่ยของค่าความคลาดเคลื่อนใกล้ศูนย์มากที่สุด และมีส่วนเบี่ยงเบนมาตรฐานต่ำกว่าแบบจำลองอื่น แสดงให้เห็นว่าแบบจำลองสามารถอธิบายข้อมูลได้อย่างมีประสิทธิภาพและมีความคลาดเคลื่อนต่ำ

ในขณะที่แบบจำลอง Additive Decomposition มีการกระจายตัวของค่าคลาดเคลื่อนค่อนข้างสูง ซึ่งสอดคล้องกับค่าความคลาดเคลื่อน(MAE,MSE,RMSE) ที่อยู่ในระดับบสูงจากผลการเปรียบเทียบแบบจำลองก่อนหน้า

2. การตรวจสอบการแจกแจงปกติ (Normality)

จากการวิเคราะห์ผ่าน Histogram และ Normal Probability Plot พบว่าค่าคลาดเคลื่อนของแบบจำลอง Holt-Winters มีลักษณะการแจกแจงใกล้เคียงแบบปกติ โดยจุดข้อมูลส่วนใหญ่อยู่ใกล้เส้นแนวตรง และไม่มีค่าผิดปกติรุนแรง แสดงให้เห็นว่าค่าคลาดเคลื่อนมีการแจกแจงที่เหมาะสมตามข้อสมมติทางสถิติ ในทางตรงกันข้าม แบบจำลอง Naive และ SES มีการเบี่ยงเบนจากการแจกแจงปกติในบางช่วง ซึ่งบ่งชี้ว่าความคลาดเคลื่อนยังไม่เป็นไปตามข้อสมมติทางสถิติอย่างสมบูรณ์

3. การตรวจสอบสหสัมพันธ์ในตัวเอง (Autocorrelation)

จากการพิจารณากราฟ ACF (Autocorrelation Function) ของค่าคลาดเคลื่อน พบว่า

1.แบบจำลอง Naive และ SES ปรากฏแท่งกราฟพุ่งทะลุเส้นช่วงความเชื่อมั่นอย่างชัดเจนในหลายช่วง มี Autocorrelation สูงในหลายค่า Lag เช่นที่ Lag 24, 48, 72ซึ่งสอดคล้องกับฤดูรายวัน แสดงว่าแบบจำลองยังไม่สามารถกำจัดอิทธิพลของฤดูกาลออกจากข้อมูลได้อย่างสมบูรณ์

2.แบบจำลอง Additive Decomposition แม้ว่าค่าสหสัมพันธ์จะลดลงเมื่อ แต่ยังคงพบค่า Autocorrelation ในบางช่วง Lag แสดงว่ายังมีโครงสร้างของข้อมูลบางส่วนที่แบบจำลองอธิบายได้ไม่ครบถ้วน (Non-random)

3.แบบจำลอง Holt-Winters Additive ค่า Autocorrelation ส่วนใหญ่อยู่ภายในช่วงความเชื่อมั่น และไม่ปรากฏรูปแบบที่ชัดเจน แสดงว่าค่าคลาดเคลื่อนไม่มี Autocorrelation และมีลักษณะใกล้เคียงแบบสุ่ม (White Noise) ซึ่งสะท้อนถึงความเหมาะสมของแบบจำลองในการอธิบายข้อมูล

แบบจำลอง	Mean Residual	StDev	P-value (Normality)	Max ACF	สรุปผล
Naive	0.15	110.81	<0.005	0.84	ไม่เหมาะสม
SES	0.46	179.66	<0.005	0.052	ไม่เหมาะสม
Additive	0.000	212.70	<0.005	0.084	พอใช้
Holt-Winters Additive	-0.374	53.83	>0.05	0.052	เหมาะสม

ตารางที่ 8 การวิเคราะห์ค่าคลาดเคลื่อน(Residual Diagnostic)

(ดูภาพการวิเคราะห์ได้จากภาคผนวก)

จากผลการวิเคราะห์พบว่า แบบจำลองในกลุ่ม Naive, SES และ Additive Decomposition ยังมีข้อจำกัด เนื่องจากค่าคลาดเคลื่อนไม่เป็นอิสระต่อกัน (มี Autocorrelation) และมีการแจกแจงที่ไม่เป็นปกติ ซึ่งไม่สอดคล้องกับข้อสมมติพื้นฐานของแบบจำลองอนุกรมเวลา

ในทางตรงกันข้าม แบบจำลอง Holt-Winters Additive มีคุณสมบัติสอดคล้องกับข้อสมมติทางสถิติครบถ้วน ทั้งในด้านค่าเฉลี่ยที่ใกล้ศูนย์ การไม่มีสหสัมพันธ์ในตัวเอง การแจกแจงใกล้เคียงปกติ และความแปรปรวนคงที่

ดังนั้นจึงสามารถสรุปได้ว่า Holt-Winters Additive เป็นแบบจำลองที่มีความเหมาะสมมากที่สุด และสามารถนำไปใช้ในการพยากรณ์ความต้องการใช้ไฟฟ้าในอนาคตได้อย่างมีประสิทธิภาพ

หากพบว่า Residual ยังมี Autocorrelation หรือไม่เป็น White Noise สามารถปรับปรุงแบบจำลองได้ เช่น เพิ่ม seasonal component ปรับค่าพารามิเตอร์ หรือเลือกใช้แบบจำลองที่มีความยืดหยุ่นสูงขึ้น เช่น SARIMA

3.5 การวิเคราะห์ความแม่นยำ

การวิเคราะห์ความแม่นยำของแบบจำลองพยากรณ์ เป็นขั้นตอนสำคัญในการประเมินประสิทธิภาพของแบบจำลอง โดยพิจารณาจากค่าความคลาดเคลื่อนระหว่างค่าพยากรณ์ (Forecast) และค่าจริง (Actual) ซึ่งสะท้อนถึงความสามรถของแบบจำลองในการอธิบายข้อมูลและทำนายค่าในอนาคต ในการศึกษานี้โดยใช้ตัวชี้วัดความแม่นยำ 4ค่า ได้แก่

1. Mean Absolute Error (MAE)
2. Mean Squared Error (MSE)
3. Root Mean Squared Error (RMSE)
4. Mean Absolute Percentage Error (MAPE)

โดยแบบจำลองที่ให้ค่าความคลาดเคลื่อนต่ำกว่า จะถือว่าแบบจำลองมีความแม่นยำสูงกว่า

จากการเปรียบเทียบแบบจำลองทั้งหมดในหัวข้อก่อนหน้า พบว่าแบบจำลอง Holt-Winters Additive ให้ค่าความคลาดเคลื่อนต่ำที่สุดในชุดข้อมูลฝึก(Training Set) จึงเลือกแบบจำลองดังกล่าวมาประเมินความแม่นยำกับชุดข้อมูลทดสอบ (Test set)

ตารางวิเคราะห์ความแม่นยำของแบบวัด Holt-Winters Additive

Model	**MAE**	**MSE**	**RMSE**	**MAPE**
Holt-Winters Additive	647.8491	547074.105	739.6446	30.8287

ตารางที่ 9 วิเคราะห์ความแม่นยำของแบบวัด Holt-Winters Additive

จากผลการวิเคราะห์ พบว่าแบบจำลอง Holt-Winters Additive มีค่า MAE เท่ากับ 647.8491 แสดงว่าโดยเฉลี่ยแล้วค่าพยากรณ์มีความแตกต่างจากค่าจริงประมาณ 648 เมกะวัตต์ ซึ่งสะท้อนว่าค่าพยากรณ์ยังมีความคลาดเคลื่อนในระดับหนึ่งเมื่อทดสอบกับข้อมูลใหม่

ในส่วนของค่า MSE เท่ากับ 547,074.105 และ RMSE เท่ากับ 739.6446 แสดงให้เห็นว่าความคลาดเคลื่อนโดยรวมของแบบจำลองยังอยู่ในระดับค่อนข้างสูง โดยเฉพาะ RMSE ซึ่งให้น้ำหนักกับค่าคลาดเคลื่อนที่มีขนาดใหญ่ จึงสะท้อนถึงความผันผวนของข้อมูลในช่วงทดสอบที่แบบจำลองไม่สามารถอธิบายได้อย่างสมบูรณ์

สำหรับค่า MAPE เท่ากับ 30.8287% แสดงให้เห็นว่าค่าพยากรณ์มีความคลาดเคลื่อนเฉลี่ยประมาณร้อยละ 30.83 ของค่าจริง ซึ่งจัดอยู่ในระดับ ปานกลาง (Moderate Accuracy) โดยทั่วไปค่า MAPE ในช่วง 20%–50% ถือว่าแบบจำลองยังสามารถใช้งานได้ในเชิงการพยากรณ์แนวโน้ม

แบบจำลอง Holt-Winters Additive สามารถพยากรณ์ข้อมูลได้ในระดับปานกลาง โดยยังคงสามารถสะท้อนแนวโน้ม (Trend) และรูปแบบฤดูกาล (Seasonality) ของข้อมูลได้อย่างชัดเจน อย่างไรก็ตาม ค่าความคลาดเคลื่อนที่เพิ่มขึ้นในชุดข้อมูลทดสอบบ่งชี้ว่าแบบจำลองยังมีข้อจำกัดในด้านความแม่นยำเชิงปริมาณ

ดังนั้น แบบจำลองนี้จึงเหมาะสำหรับการพยากรณ์ระยะสั้นในภาพรวม แต่หากต้องการเพิ่มความแม่นยำในอนาคต อาจพิจารณาปรับค่าพารามิเตอร์ของแบบจำลอง หรือผสมผสานกับปัจจัยภายนอกเพิ่มเติม เช่น สภาพอากาศ หรือรูปแบบวันทำงานและวันหยุด เพื่อช่วยให้การพยากรณ์มีประสิทธิภาพมากยิ่งขึ้น

จากการวิเคราะห์ข้อผิดพลาด พบว่าความคลาดเคลื่อนสูงมักเกิดในช่วงเวลาที่มีการใช้ไฟฟ้าสูง เช่น ช่วงเย็นหรือช่วงวันหยุด ซึ่งสะท้อนว่าแบบจำลองไม่สามารถจับการเปลี่ยนแปลงที่เกิดขึ้นอย่างรวดเร็วได้อย่างสมบูรณ์

3.6 การตีความแบบจำลอง (Model Interpretation)

หลังจากเลือกแบบจำลอง Holt-Winters Additive ซึ่งให้ความแม่นยำสูงที่สุดแล้ว ในขั้นตอนนี้จะทำการตีความองค์ประกอบของแบบจำลอง เพื่ออธิบายความหมายของแนวโน้มและรูปแบบฤดูกาลในบริบทของการใช้ไฟฟ้าในภาคใต้ โดยสรุปผลการตีความแสดงในตารางที่ 10

องค์ประกอบ	ผลที่พบ	การตีความเชิงบริบท
Level(Lt)	~2100 MW	ระดับการใช้ไฟฟ้าเฉลี่ยของภาคใต้
Trend(Tt)	เพิ่มขึ้นเล็กน้อย	ความต้องการไฟฟ้าเพิ่มตามเศรษฐกิจ\อากาศ
Seasonality (St)	สูงช่วง 19:00-21.00	ช่วงใช้ไฟสูงสุด (Peak hours)
Seasonality (St)	ต่ำช่วง 04:00-06.00	ช่วงใช้ไฟต่ำสุด
Residual	ไม่มี pattern	โมเดลอธิบายข้อมูลได้ดี

ตารางที่ 10 การตีความแบบจำลอง Holt-Winters Additive

3.7 การพยากรณ์ล่วงหน้า (Forecasting)

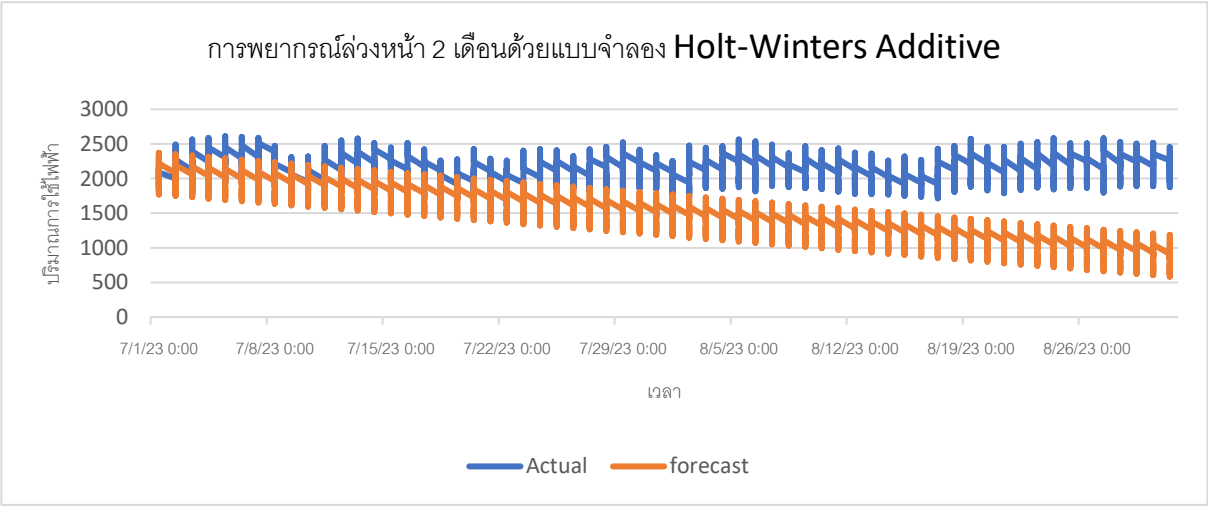

หลังจากการเปรียบเทียบประสิทธิภาพของแบบจำลองพยากรณ์ในขั้นตอนก่อนหน้า พบว่าแบบจำลอง Holt-Winters Additive เป็นแบบจำลองที่มีความเหมาะสมมากที่สุด เนื่องจากให้ค่าความคลาดเคลื่อนต่ำที่สุดในชุดข้อมูลฝึก (Training Set) และสามารถอธิบายองค์ประกอบของข้อมูลที่มีทั้งแนวโน้ม (Trend) และฤดูกาล (Seasonality) ได้อย่างมีประสิทธิภาพ ดังนั้นจึงเลือกใช้แบบจำลองดังกล่าวในการพยากรณ์ข้อมูลล่วงหน้า

ในการศึกษานี้ ได้ทำการพยากรณ์ความต้องการใช้ไฟฟ้าในภาคใต้ของประเทศไทยเป็นระยะเวลา 2 เดือนล่วงหน้า โดยใช้ข้อมูลรายชั่วโมง (Hourly Data) และอาศัยค่าพารามิเตอร์ของแบบจำลองที่ได้จากการประมาณในชุดข้อมูลฝึก (Training Set) เพื่อคำนวณค่าพยากรณ์ในอนาคต

ผลการพยากรณ์แสดงให้เห็นว่า แบบจำลองสามารถสะท้อน รูปแบบฤดูกาลรายวัน (Daily Seasonality) ได้อย่างชัดเจน โดยค่าพยากรณ์มีลักษณะขึ้นลงเป็นคาบซ้ำทุก ๆ 24 ชั่วโมง ซึ่งสอดคล้องกับพฤติกรรมการใช้ไฟฟ้าในชีวิตประจำวันของผู้บริโภค เช่น การใช้ไฟฟ้าที่เพิ่มสูงขึ้นในช่วงเย็นถึงค่ำ และลดลงในช่วงกลางคืนถึงเช้ามืด แสดงให้เห็นว่าแบบจำลองสามารถเรียนรู้และจำลองรูปแบบเชิงฤดูกาลของข้อมูลได้อย่างเหมาะสม

อย่างไรก็ตาม เมื่อพิจารณาเปรียบเทียบค่าพยากรณ์กับค่าจริง (Actual) พบว่า ค่าพยากรณ์มีแนวโน้มต่ำกว่าค่าจริง (Underestimation) อย่างต่อเนื่อง โดยเฉพาะในช่วงปลายของระยะเวลาการพยากรณ์ ซึ่งอาจเกิดจากข้อจำกัดของแบบจำลองในการประมาณค่าแนวโน้ม (Trend) จากข้อมูลในอดีต หรืออาจสะท้อนถึงการเปลี่ยนแปลงของพฤติกรรมการใช้ไฟฟ้าในช่วงข้อมูลทดสอบที่แตกต่างจากช่วงข้อมูลฝึก

ลักษณะดังกล่าวส่งผลให้ค่าความคลาดเคลื่อนของแบบจำลองเพิ่มขึ้นเมื่อทำการทดสอบกับข้อมูลใหม่ ซึ่งสอดคล้องกับค่า Mean Absolute Percentage Error (MAPE) ที่มีค่าประมาณร้อยละ 30 แสดงว่าแบบจำลองมีความแม่นยำอยู่ในระดับ ปานกลาง โดยยังสามารถใช้พยากรณ์แนวโน้มโดยรวมของข้อมูลได้ แต่ยังมีข้อจำกัดในด้านความแม่นยำเชิงปริมาณ

สรุปผลการพยากรณ์

แม้ว่าแบบจำลอง Holt-Winters Additive จะสามารถอธิบายโครงสร้างของข้อมูลได้ดี ทั้งในด้านแนวโน้มและฤดูกาล แต่ยังมีข้อจำกัดในการพยากรณ์ค่าที่มีการเปลี่ยนแปลงอย่างรวดเร็วหรือมีปัจจัยภายนอกเข้ามาเกี่ยวข้อง ดังนั้น เพื่อเพิ่มประสิทธิภาพในการพยากรณ์ในอนาคต อาจพิจารณาแนวทางเพิ่มเติม เช่น การปรับค่าพารามิเตอร์ของแบบจำลองให้เหมาะสมมากยิ่งขึ้น การใช้

แบบจำลองที่มีความยืดหยุ่นสูงขึ้น เช่น SARIMA หรือ Prophet การนำตัวแปรภายนอก (Exogenous Variables) เช่น สภาพอากาศ วันหยุด หรือกิจกรรมทางเศรษฐกิจ มาร่วมในการวิเคราะห์

นอกจากนี้ ได้มีการประมาณช่วงความเชื่อมั่นของค่าพยากรณ์ (Prediction Interval) ที่ระดับ 95% เพื่อสะท้อนความไม่แน่นอนของค่าพยากรณ์ โดยพบว่าแบบจำลองมีแนวโน้ม Underestimation ในช่วงปลาย ซึ่งอาจเกิดจากการเปลี่ยนแปลงของแนวโน้มในข้อมูลใหม่

บทที่ 4

สรุปและอภิปรายผล แนะนำข้อเสนอแนะ

4.1สรุปและอภิปรายผล

การศึกษาครั้งนี้มีวัตถุประสงค์เพื่อวิเคราะห์ลักษณะข้อมูลอนุกรมเวลา และสร้างแบบจำลองพยากรณ์เพื่อเปรียบเทียบประสิทธิภาพของแบบจำลองต่าง ๆ สำหรับเลือกแบบจำลองที่เหมาะสมที่สุดในการพยากรณ์ข้อมูลในอนาคต โดยใช้ข้อมูลรายชั่วโมงในช่วงเวลา 8 เดือน และแบ่งข้อมูลออกเป็นชุดฝึก (Training set) และชุดทดสอบ (Testing set) ในอัตราส่วน 6 เดือนต่อ 2 เดือน

จากการวิเคราะห์ข้อมูลเบื้องต้น (Exploratory Data Analysis: EDA) พบว่าข้อมูลมีแนวโน้ม (Trend) เพิ่มขึ้นเล็กน้อยตามช่วงเวลา และมีรูปแบบฤดูกาล (Seasonality) ที่เกิดซ้ำอย่างชัดเจน โดยเฉพาะรูปแบบรายชั่วโมงและรายวันในสัปดาห์ นอกจากนี้ข้อมูลยังมีความผันผวนในระยะสั้น ซึ่งเป็นลักษณะของข้อมูลอนุกรมเวลาที่มีทั้งแนวโน้มและฤดูกาล

ในการศึกษาครั้งนี้ได้พัฒนาแบบจำลองพยากรณ์จำนวน 4 แบบ ได้แก่

1.Naive Model

2.Simple Exponential Smoothing (SES)

3.Additive Decomposition Model

4.Holt-Winters Additive Method

จากการเปรียบเทียบประสิทธิภาพของแบบจำลองด้วยตัวชี้วัด MAE, MSE และ RMSE จากข้อมูลชุดฝึก (Training set) พบว่าแบบจำลอง Holt-Winters Additive ให้ค่าความคลาดเคลื่อนต่ำที่สุด แสดงว่าแบบจำลองสามารถอธิบายโครงสร้างของข้อมูลที่มีทั้งแนวโน้มและฤดูกาลได้ดีที่สุด

จากนั้นได้นำแบบจำลอง Holt-Winters Additive ไปทดสอบกับข้อมูลชุดทดสอบ (Testing set) เพื่อประเมินความสามารถในการพยากรณ์ข้อมูลใหม่ที่แบบจำลองไม่เคยเห็นมาก่อน พบว่าแบบจำลอง

มีค่า Mean Absolute Error (MAE) เท่ากับ 647.8491 ค่า Mean Squared Error (MSE) เท่ากับ 547,074.105 ค่า Root Mean Squared Error (RMSE) เท่ากับ 739.6446 และค่า Mean Absolute Percentage Error (MAPE) เท่ากับ 30.8287%

ค่าความคลาดเคลื่อนดังกล่าวแสดงว่าแบบจำลองสามารถพยากรณ์ข้อมูลได้ในระดับปานกลาง โดยค่า MAPE ประมาณร้อยละ 30.83 สะท้อนว่าค่าพยากรณ์มีความคลาดเคลื่อนจากค่าจริงประมาณร้อยละ 30 ซึ่งอาจเกิดจากความผันผวนของข้อมูลในช่วงชุดทดสอบที่แตกต่างจากชุดฝึก รวมถึงรูปแบบฤดูกาลที่เปลี่ยนแปลงไปในช่วงเวลาใหม่

แบบจำลอง Naive ให้ค่าความแม่นยำอยู่ในระดับปานกลาง เนื่องจากใช้ค่าก่อนหน้าเป็นค่าพยากรณ์ โดยไม่พิจารณาแนวโน้มหรือฤดูกาล ขณะที่แบบจำลอง Simple Exponential Smoothing (SES) ให้ค่าความคลาดเคลื่อนสูงกว่า เนื่องจากไม่สามารถอธิบายทั้งแนวโน้มและฤดูกาลของข้อมูลได้อย่างครบถ้วน

สำหรับแบบจำลอง Additive Decomposition แม้สามารถแยกองค์ประกอบของข้อมูลออกเป็นแนวโน้มและฤดูกาลได้ แต่ยังไม่สามารถพยากรณ์ข้อมูลได้แม่นยำเท่ากับแบบจำลอง Holt-Winters เนื่องจากแบบจำลองไม่สามารถปรับค่าพารามิเตอร์แบบไดนามิกในแต่ละช่วงเวลา

ดังนั้น สามารถสรุปได้ว่าแบบจำลอง Holt-Winters Additive เป็นแบบจำลองที่เหมาะสมที่สุดสำหรับการพยากรณ์ข้อมูลในการศึกษาครั้งนี้ เนื่องจากสามารถอธิบายโครงสร้างของข้อมูลที่มีทั้งแนวโน้มและฤดูกาลได้ และให้ค่าความคลาดเคลื่อนต่ำที่สุดเมื่อเทียบกับแบบจำลองอื่น

อย่างไรก็ตาม จากผลการพยากรณ์พบแนวโน้มของ การประมาณค่าต่ำกว่าค่าจริง(Underestimation) ในช่วงปลายของการพยากรณ์ ซึ่งสะท้อนข้อจำกัดของแบบจำลองในการจับการเปลี่ยนแปลงของแนวโน้มในข้อมูลใหม่

ผลการศึกษานี้สามารถนำไปใช้ในการวางแผนการผลิตไฟฟ้า การจัดสรรโหลด และการบริหารความเสี่ยงด้านพลังงาน โดยเฉพาะในช่วงเวลาที่มีความต้องการใช้ไฟฟ้าสูง

4.2ข้อเสนอแนะ

จากผลการศึกษา สามารถเสนอแนะแนวทางเพื่อพัฒนาและปรับปรุงการพยากรณ์ในอนาคตได้ดังนี้

1.การปรับค่าพารามิเตอร์ของแบบจำลอง ควรทดลองปรับค่า smoothing parameters ได้แก่ α (alpha), β (beta) และ γ (gamma) เพื่อหาค่าที่เหมาะสมที่สุด ซึ่งจะช่วยลดค่าความคลาดเคลื่อนและเพิ่มความแม่นยำของแบบจำลอง

2.การใช้แบบจำลองเพิ่มเติมควรทดลองใช้แบบจำลองอื่น เช่น SARIMA หรือ Prophet เพื่อเปรียบเทียบประสิทธิภาพ และเพิ่มทางเลือกในการวิเคราะห์

3.การเพิ่มช่วงเวลาของข้อมูล ควรใช้ข้อมูลระยะยาวมากขึ้น เช่น 1 ปี หรือหลายปี เพื่อให้แบบจำลองสามารถเรียนรู้รูปแบบฤดูกาลระยะยาว (Yearly Seasonality) ได้ดียิ่งขึ้น

4.การนำปัจจัยภายนอกเข้ามาวิเคราะห์ ควรพิจารณาตัวแปรภายนอก เช่น สภาพอากาศ (Temperature, Humidity) วันหยุดนักขัตฤกษ์ รูปแบบวันทำงานและวันหยุด ซึ่งมีผลต่อพฤติกรรมการใช้ไฟฟ้า และช่วยเพิ่มความแม่นยำของแบบจำลอง

5.การประเมินแบบจำลองที่เข้มข้นขึ้น ควรใช้เทคนิค เช่น Rolling Forecast หรือ Time Series Cross-validation เพื่อให้การประเมินแบบจำลองมีความน่าเชื่อถือมากขึ้น

ภาคผนวก

ขั้นตอนการวิเคราะห์ที่สามารถทำซ้ำได้ (Reproducibility Appendix)

ภาคผนวก ก ข้อมูลที่ใช้ในการศึกษา

ข้อมูลที่ใช้ในการศึกษาครั้งนี้เป็นข้อมูลความต้องการใช้ไฟฟ้ารายชั่วโมงของภาคใต้ของประเทศไทย โดยครอบคลุมช่วงเวลา 8 เดือน ตั้งแต่เดือนมกราคม พ.ศ. 2567 ถึงเดือนสิงหาคม พ.ศ. 2567 รวมจำนวนทั้งสิ้น 5,831 ค่า

ตัวแปรที่ใช้ในการวิเคราะห์ประกอบด้วย

Variable	Type	Unit	Description
Datetime	DateTime	-	วันและเวลา
South Demand	Numeric	MW	ความต้องการใช้ไฟฟ้าภาคใต้

ก่อนนำข้อมูลมาวิเคราะห์ ได้ดำเนินการตรวจสอบและปรับปรุงข้อมูล ดังนี้

ตรวจสอบค่าที่หายไป (Missing values)

ตรวจสอบค่าผิดปกติ (Outliers) ด้วย Boxplot

เรียงลำดับข้อมูลตามเวลา

ตรวจสอบความต่อเนื่องของเวลา (Time continuity)

ภาคผนวก ข การแบ่งชุดข้อมูล (Train/Test Split)

ข้อมูลถูกแบ่งออกเป็น 2 ส่วน ได้แก่

ชุดฝึก (Training set) จำนวน 6 เดือนแรกชุดทดสอบ (Testing set) จำนวน 2 เดือนสุดท้าย

อัตราส่วนการแบ่งข้อมูลเท่ากับ 75:25 โดยใช้วิธี Time-based split เพื่อรักษาลำดับเวลา ซึ่งเหมาะสมกับข้อมูลอนุกรมเวลา

ภาคผนวก ค ซอฟต์แวร์ที่ใช้

การวิเคราะห์ดำเนินการโดยใช้ Microsoft Excel และ Minitab สำหรับการสร้างแบบจำลองอนุกรมเวลาและการประเมินผล

ภาคผนวก ง ขั้นตอนการวิเคราะห์ข้อมูล

ขั้นตอนการวิเคราะห์สามารถทำซ้ำได้ตามลำดับดังนี้

ขั้นตอนที่ 1 นำเข้าข้อมูลลงใน Microsoft Excel

ขั้นตอนที่ 2 ตรวจสอบ Missing values และ Outliers

ขั้นตอนที่ 3 แปลงข้อมูลให้อยู่ในรูปแบบ Time series

ขั้นตอนที่ 4 สร้าง Time Series Plot เพื่อดูแนวโน้ม

ขั้นตอนที่ 5 วิเคราะห์ Seasonality ด้วย Boxplot รายชั่วโมง

ขั้นตอนที่ 6 ทดสอบ Stationarity ด้วย ADF test

ขั้นตอนที่ 7 สร้างแบบจำลอง Naive Model

ขั้นตอนที่ 8 สร้างแบบจำลอง SES ทดลองค่า α หลายค่า

ขั้นตอนที่ 9 สร้าง Additive Decomposition Model

ขั้นตอนที่ 10 สร้าง Holt-Winters Additive Model

ขั้นตอนที่ 11 เปรียบเทียบค่า MAE, MSE, RMSE

ขั้นตอนที่ 12 เลือกแบบจำลองที่ดีที่สุด

ขั้นตอนที่ 13 ประเมินผลด้วย Testing set

ขั้นตอนที่ 14 วิเคราะห์ Residual diagnostics

ภาคผนวก จ พารามิเตอร์ของแบบจำลอง

Model	**Parameter**	**Value**
SES	α	0.5
Holt-Winters	α	0.2
	β	0.01
	γ	0.2
Seasonal period	s	24

ภาคผนวก ฉ ตัวชี้วัดความแม่นยำ

ตัวชี้วัดที่ใช้ในการประเมินแบบจำลอง ได้แก่

Mean Absolute Error (MAE)

Mean Squared Error (MSE)

Root Mean Squared Error (RMSE)

Mean Absolute Percentage Error (MAPE)

การคำนวณใช้สูตรมาตรฐานดังนี้

MAE = ค่าเฉลี่ยของ |Actual − Forecast|

MSE = ค่าเฉลี่ยของ $(\text{Actual} - \text{Forecast})^2$

RMSE = $\sqrt{\text{MSE}}$

MAPE = ค่าเฉลี่ยของ |(Actual − Forecast)/Actual| × 100

ภาคผนวก ช การตั้งค่าเริ่มต้น (Initialization)

การประมาณค่า Holt-Winters ใช้ค่าเริ่มต้นดังนี้

Level เริ่มต้น = ค่าเฉลี่ย 1 วันแรก

Trend เริ่มต้น = ความแตกต่างเฉลี่ย 2 วันแรก

Seasonal index = ค่าเฉลี่ยรายชั่วโมง

ภาคผนวก ซ การตรวจสอบ Residual

ดำเนินการตรวจสอบดังนี้

ตรวจสอบค่าเฉลี่ยของ Residual ใกล้ศูนย์

ตรวจสอบ Autocorrelation ด้วย ACF Plot

ตรวจสอบ Normality ด้วย Histogram

ตรวจสอบ Variance คงที่

ตรวจสอบ White Noise

ภาคผนวก ฌ ข้อจำกัดของการทำซ้ำ

เนื่องจากการวิเคราะห์ดำเนินการผ่าน Excel และ Minitab การประมาณค่าอาจแตกต่างเล็กน้อยจากการ rounding แต่ไม่ส่งผลต่อข้อสรุปหลักของการศึกษา

ภาคผนวก ญ การนำไปใช้งาน

ผู้วิจัยสามารถทำซ้ำได้โดย ใช้ข้อมูลเดียวกัน ใช้พารามิเตอร์เดียวกัน ใช้ขั้นตอนเดียวกัน

ใช้ seasonal period = 24 ผลลัพธ์ที่ได้จะใกล้เคียงกับงานวิจัยนี้

ภาคผนวก ฎ ภาพข้อมูล Microsoft Excel และภาพการวิเคราะห์ minitab

	A	B	C	D	E	F	G	H	I
1	datetime	south_demand	Naïve	Res	ABS	MAPE	MAE	MSE	RMSE
2	1/1/2023 0:00	1565.6	*	*	*	*	82.10944	12276.49933	110.7993652
3	1/1/2023 1:00	1549.6	1565.6	-16	16	1.032525			
4	1/1/2023 2:00	1473.7	1549.6	-75.9	75.9	5.150302			
5	1/1/2023 3:00	1418.1	1473.7	-55.6	55.6	3.920739			
6	1/1/2023 4:00	1390.3	1418.1	-27.8	27.8	1.999568			
7	1/1/2023 5:00	1418.3	1390.3	28	28	1.974194			
8	1/1/2023 6:00	1484.1	1418.3	65.8	65.8	4.433663			
9	1/1/2023 7:00	1393.4	1484.1	-90.7	90.7	6.509258			
10	1/1/2023 8:00	1370	1393.4	-23.4	23.4	1.708029			
11	1/1/2023 9:00	1411.2	1370	41.2	41.2	2.919501			
12	1/1/2023 10:00	1457.6	1411.2	46.4	46.4	3.183315			
13	1/1/2023 11:00	1477.7	1457.6	20.1	20.1	1.360222			
14	1/1/2023 12:00	1460.5	1477.7	-17.2	17.2	1.177679			
15	1/1/2023 13:00	1459.3	1460.5	-1.2	1.2	0.082231			
16	1/1/2023 14:00	1479.5	1459.3	20.2	20.2	1.365326			
17	1/1/2023 15:00	1508.5	1479.5	29	29	1.92244			
18	1/1/2023 16:00	1527.7	1508.5	19.2	19.2	1.256791			
19	1/1/2023 17:00	1557.2	1527.7	29.5	29.5	1.894426			
20	1/1/2023 18:00	1638.1	1557.2	80.9	80.9	4.938648			
21	1/1/2023 19:00	2017.1	1638.1	379	379	18.78935			

ภาพการสร้างแบบจำลอง Naive และการวิเคราะห์

south_demand	SES	Forecast	res	ABS	MAPE	MAE	MSE	RMSE	a		0.5
1565.6	1565.6	*	*	*	*	152.0060804	32271.04	179.6414	0.1	8.2330173	
1549.6	1565.6	1565.6	-16	16	1.032525				0.2	8.2073983	
1473.7	1557.6	1565.6	-91.9	91.9	6.236005				0.3	7.8862821	
1418.1	1515.65	1557.6	-139.5	139.5	9.837106				0.4	7.5173116	
1390.3	1466.875	1515.65	-125.35	125.35	9.01604				0.5	7.2028641	
1418.3	1428.5875	1466.875	-48.575	48.575	3.424875						
1484.1	1423.44375	1428.588	55.5125	55.5125	3.740482						
1393.4	1453.771875	1423.444	-30.0437	30.04375	2.156147						
1370	1423.585938	1453.772	-83.7719	83.77187	6.114735						
1411.2	1396.792969	1423.586	-12.3859	12.38594	0.877688						
1457.6	1403.996484	1396.793	60.80703	60.80703	4.171723						
1477.7	1430.798242	1403.996	73.70352	73.70352	4.987718						
1460.5	1454.249121	1430.798	29.70176	29.70176	2.033671						
1459.3	1457.374561	1454.249	5.050879	5.050879	0.346117						
1479.5	1458.33728	1457.375	22.12544	22.12544	1.495467						
1508.5	1468.91864	1458.337	50.16272	50.16272	3.325338						
1527.7	1488.70932	1468.919	58.78136	58.78136	3.847703						
1557.2	1508.20466	1488.709	68.49068	68.49068	4.398323						
1638.1	1532.70233	1508.205	129.8953	129.8953	7.929634						
2017.1	1585.401165	1532.702	484.3977	484.3977	24.01456						

ภาพการสร้างแบบจำลองSimple Exponential Smoothing (SES)และการวิเคราะห์

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T
	datetime	Quarter	index	south_demand	hour	24-MA	2x24MA	deTrend1	S-index1	Des1	Rt	Time index	fitTrend	Forecast	Res	MAE	MSE	RMSE	hour	S-index1
	1/1/2023 0:00	1	1	1565.6	0	*	*	*	*	*	*	*	*	*	*	173.3469298	45231.0636	212.6759592	0	197.1702165
	1/1/2023 1:00	2	2	1549.6	1	*	*	*	*	*	*	*	*	*	*				1	153.5531998
	1/1/2023 2:00	3	3	1473.7	2	*	*	*	*	*	*	*	*	*	*				2	20.94134259
	1/1/2023 3:00	4	4	1418.1	3	*	*	*	*	*	*	*	*	*	*				3	-76.0234259
	1/1/2023 4:00	5	5	1390.3	4	*	*	*	*	*	*	*	*	*	*				4	-158.315891
	1/1/2023 5:00	6	6	1418.3	5	*	*	*	*	*	*	*	*	*	*				5	-223.087523
	1/1/2023 6:00	7	7	1484.1	6	*	*	*	*	*	*	*	*	*	*				6	-252.710405
	1/1/2023 7:00	8	8	1393.4	7	*	*	*	*	*	*	*	*	*	*				7	-228.570567
0	1/1/2023 8:00	9	9	1370	8	*	*	*	*	*	*	*	*	*	*				8	-131.596019
1	1/1/2023 9:00	10	10	1411.2	9	*	*	*	*	*	*	*	*	*	*				9	-248.691123
2	1/1/2023 10:00	11	11	1457.6	10	*	*	*	*	*	*	*	*	*	*				10	-252.289387
3	1/1/2023 11:00	12	12	1477.7	11	*	*	*	*	*	*	*	*	*	*				11	-91.5696875
4	1/1/2023 12:00	13	13	1460.5	12	*	*	*	*	*	*	*	*	*	*				12	1.555451389
5	1/1/2023 13:00	14	14	1459.3	13	*	*	*	*	*	*	*	*	*	*				13	44.10429398
6	1/1/2023 14:00	15	15	1479.5	14	*	*	*	*	*	*	*	*	*	*				14	-16.8506829
7	1/1/2023 15:00	16	16	1508.5	15	*	*	*	*	*	*	*	*	*	*				15	4.192407407
8	1/1/2023 16:00	17	17	1527.7	16	*	*	*	*	*	*	*	*	*	*				16	123.6632755
9	1/1/2023 17:00	18	18	1557.2	17	*	*	*	*	*	*	*	*	*	*				17	126.8202083
0	1/1/2023 18:00	19	19	1638.1	18	*	*	*	*	*	*	*	*	*	*				18	91.325
1	1/1/2023 19:00	20	20	2017.1	19	*	*	*	*	*	*	*	*	*	*				19	-8.91069444
2	1/1/2023 20:00	21	21	1958.6	20	*	*	*	*	*	*	*	*	*	*				20	0.586712963
3	1/1/2023 21:00	22	22	1904	21	*	*	*	*	*	*	*	*	*	*				21	343.6541667
4	1/1/2023 22:00	23	23	1812.2	22	*	*	*	*	*	*	*	*	*	*				22	328.2629167
5	1/1/2023 23:00	24	24	1708.1	23	1560.017	1560.4021	147.697917	286.0464236	1422.053576	-138.348507	1	1934.926573	2220.972997	-512.872997				23	286.0464236
6	2/1/2023 0:00	1	25	1584.1	0	1560.788	1559.7292	24.3708333	197.1702165	1386.929784	-172.799383	2	1935.006609	2132.176825	-548.076825					
7	2/1/2023 1:00	2	26	1498.8	1	1558.671	1557.8542	-59.054167	153.5531998	1345.2468	-212.607366	3	1935.086645	2088.639845	-589.839845					
8	2/1/2023 2:00	3	27	1434.5	2	1557.038	1556.3917	-121.89167	20.94134259	1413.558657	-142.833009	4	1935.166681	1956.108024	-521.608024					
9	2/1/2023 3:00	4	28	1387.1	3	1555.746	1555.1813	-168.08125	-76.0234259	1463.123426	-92.0578241	5	1935.246717	1859.223291	-472.123291					
0	2/1/2023 4:00	5	29	1363.2	4	1554.617	1554.0708	-190.87083	-158.315891	1521.515891	-32.5549421	6	1935.326753	1777.010862	-413.810862					

ภาพการสร้างแบบจำลอง Additive Decomposition และการวิเคราะห์

	A	B	C	D	E	F	G	H	I	J	K	L	M
1	datetime	q	period	south_deman	level	trend	season	fitted	residuals	ABS	MAE	MSE	RMSE
2	1/1/2023 0:00	1	1	1565.6	*	*	5.5833333	*	*	*	39.9590	2897.166693	53.82533505
3	1/1/2023 1:00	2	2	1549.6	*	*	-10.41667	*	*	*			
4	1/1/2023 2:00	3	3	1473.7	*	*	-86.31667	*	*	*			
5	1/1/2023 3:00	4	4	1418.1	*	*	-141.9167	*	*	*			
6	1/1/2023 4:00	5	5	1390.3	*	*	-169.7167	*	*	*			
7	1/1/2023 5:00	6	6	1418.3	*	*	-141.7167	*	*	*			
8	1/1/2023 6:00	7	7	1484.1	*	*	-75.91667	*	*	*		α 0.2	
9	1/1/2023 7:00	8	8	1393.4	*	*	-166.6167	*	*	*		β 0.01	
10	1/1/2023 8:00	9	9	1370	*	*	-190.0167	*	*	*		γ 0.2	
11	1/1/2023 9:00	10	10	1411.2	*	*	-148.8167	*	*	*			
12	1/1/2023 10:00	11	11	1457.6	*	*	-102.4167	*	*	*			
13	1/1/2023 11:00	12	12	1477.7	*	*	-82.31667	*	*	*			
14	1/1/2023 12:00	13	13	1460.5	*	*	-99.51667	*	*	*			
15	1/1/2023 13:00	14	14	1459.3	*	*	-100.7167	*	*	*			
16	1/1/2023 14:00	15	15	1479.5	*	*	-80.51667	*	*	*			
17	1/1/2023 15:00	16	16	1508.5	*	*	-51.51667	*	*	*			
18	1/1/2023 16:00	17	17	1527.7	*	*	-32.31667	*	*	*			
19	1/1/2023 17:00	18	18	1557.2	*	*	-2.816667	*	*	*			
20	1/1/2023 18:00	19	19	1638.1	*	*	78.083333	*	*	*			
21	1/1/2023 19:00	20	20	2017.1	*	*	457.08333	*	*	*			
22	1/1/2023 20:00	21	21	1958.6	*	*	398.58333	*	*	*			
23	1/1/2023 21:00	22	22	1904	*	*	343.98333	*	*	*			
24	1/1/2023 22:00	23	23	1812.2	*	*	252.18333	*	*	*			

ภาพการสร้างแบบจำลอง Holt-Winters Additive Methodและการวิเคราะห์

4341	.2267											
4342	.2819											
4343	.6564											
4344	.5484	h	Date	Actual	forecast	Res	MAE	MSE	RMSE		MAPE	
4345		1	1/7/23 00:00	2082.2	2098.0572	-15.85719246	647.8491	547074.105	739.6446	0.0076	30.8287	
4346		2	1/7/23 01:00	2011.6	1998.6911	12.90890552				0.0064		
4347		3	1/7/23 02:00	1959.3	1914.5473	44.75267154				0.0228		
4348		4	1/7/23 03:00	1905	1845.8588	59.14119024				0.0310		
4349		5	1/7/23 04:00	1868.4	1806.4287	61.97131725				0.0332		
4350		6	1/7/23 05:00	1878.1	1836.4220	41.67799302				0.0222		
4351		7	1/7/23 06:00	1963.7	1951.5105	12.18945916				0.0062		
4352		8	1/7/23 07:00	1895.1	1770.2535	124.8465197				0.0659		
4353		9	1/7/23 08:00	1996.5	1784.5146	211.9854383				0.1062		
4354		10	1/7/23 09:00	2109	1964.1376	144.8624486				0.0687		
4355		11	1/7/23 10:00	2140.2	2058.0618	82.13816163				0.0384		
4356		12	1/7/23 11:00	2156.6	2107.0762	49.52384852				0.0230		
4357		13	1/7/23 12:00	2052.6	2054.9113	-2.311271429				0.0011		
4358		14	1/7/23 13:00	2010	2081.0014	-71.00142506				0.0353		
4359		15	1/7/23 14:00	2035.6	2192.1670	-156.567029				0.0769		
4360		16	1/7/23 15:00	2034.5	2171.5359	-137.0358681				0.0674		
4361		17	1/7/23 16:00	2032.2	2125.8691	-93.66910033				0.0461		
4362		18	1/7/23 17:00	1979.4	2013.0145	-33.61448598				0.0170		
4363		19	1/7/23 18:00	1990.5	2022.2697	-31.7696727				0.0160		
4364		20	1/7/23 19:00	2322.7	2345.6163	-22.91633226				0.0099		
4365		21	1/7/23 20:00	2313.7	2371.9991	-58.29907103				0.0252		
4366		22	1/7/23 21:00	2260.3	2319.4938	-59.19379939				0.0262		
4367		23	1/7/23 22:00	2158.5	2231.0223	-72.52234545				0.0336		
4368		24	1/7/23 23:00	2090.1	2216.1912	-126.091207				0.0603		
4369		25	2/7/23 00:00	1999.4	2078.6079	-79.20787135				0.0396		
4370		26	2/7/23 01:00	1931	1979.2418	-48.24177338				0.0250		
4371		27	2/7/23 02:00	1861	1895.0980	-34.09800735				0.0183		
4372		28	2/7/23 03:00	1822.4	1826.4095	-4.00948865				0.0022		
4373		29	2/7/23 04:00	1790	1786.9794	3.020638359				0.0017		
4374		30	2/7/23 05:00	1816.7	1816.9727	-0.272685875				0.0002		
4375		31	2/7/23 06:00	1905.3	1932.0612	-26.76121973				0.0140		
4376		32	2/7/23 07:00	1783.4	1750.8042	32.59584081				0.0183		
4377		33	2/7/23 08:00	1791	1765.0652	25.93475936				0.0145		
4378		34	2/7/23 09:00	1880	1944.6882	-64.68823028				0.0344		
4379		35	2/7/23 10:00	1948.9	2038.6125	-89.71251726				0.0460		
4380		36	2/7/23 11:00	1998.1	2087.6268	-89.52683037				0.0448		
4381		37	2/7/23 12:00	1967	2035.4620	-68.46195032				0.0348		

Data | EDA | Naïve | SES | Holt winter | Additive Decomposit… | +

ภาพการวิเคราะห์ความแม่นยำของHolt-Winters Additive Method

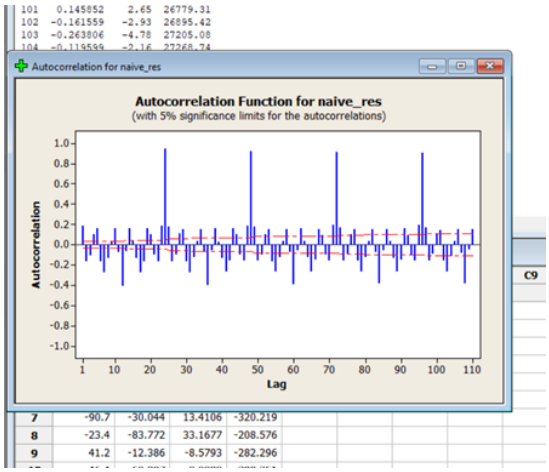

ภาพการวิเคราะห์ Autocorrelation (ACF) ของค่า Residual จากโมเดล (Naive)

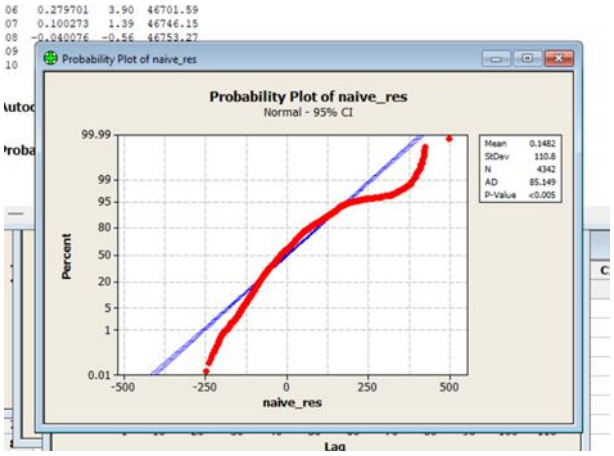

Probability Plot of naive_res (กราฟตรวจสอบการแจกแจงปกติของ Residual จากโมเดล Naive)

Descriptive Statistics: naive_res

Variable	N	N*	Mean	SE Mean	StDev	Minimum	Q1	Median	Q3
naive_res	4342	0	0.15	1.68	110.81	-249.60	-75.00	-19.50	46.40

Variable	Maximum
naive_res	498.60

ภาพการวิเคราะห์สถิติเชิงพรรณนา (Descriptive Statistics) ของค่า Residual (naïve_res)

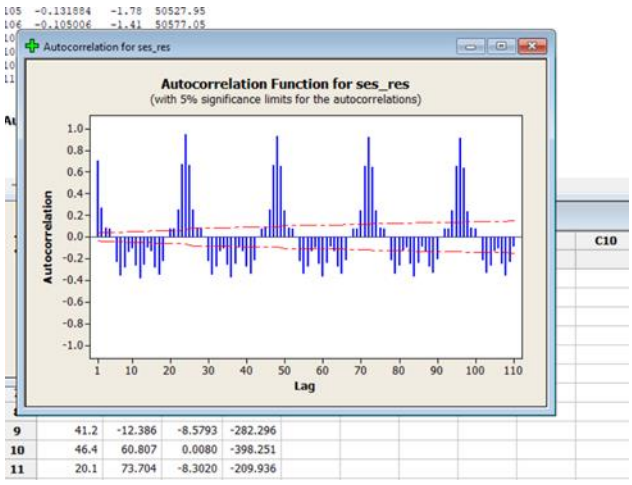

ภาพการวิเคราะห์ Autocorrelation (ACF) ของค่า Residual จากโมเดล (SES)

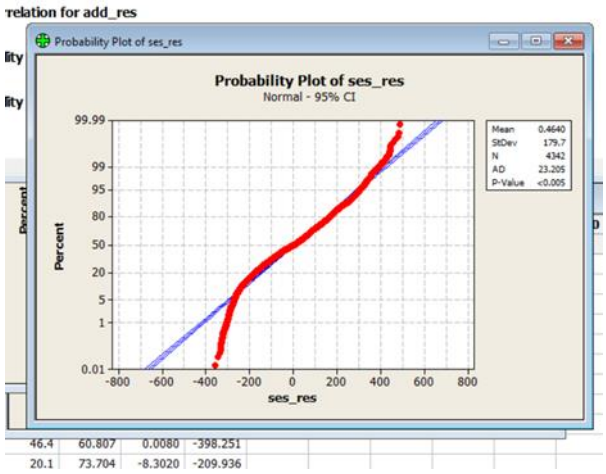

Probability Plot of ses_res (กราฟตรวจสอบการแจกแจงปกติของ Residual จากโมเดล SES)

Descriptive Statistics: ses_res

Variable	N	N*	Mean	SE Mean	StDev	Minimum	Q1	Median	Q3
ses_res	4342	0	0.46	2.73	179.66	-360.91	-148.95	2.83	136.32

Variable	Maximum
ses_res	488.93

ภาพการวิเคราะห์สถิติเชิงพรรณนา (Descriptive Statistics) ของค่า Residual (ses_res)

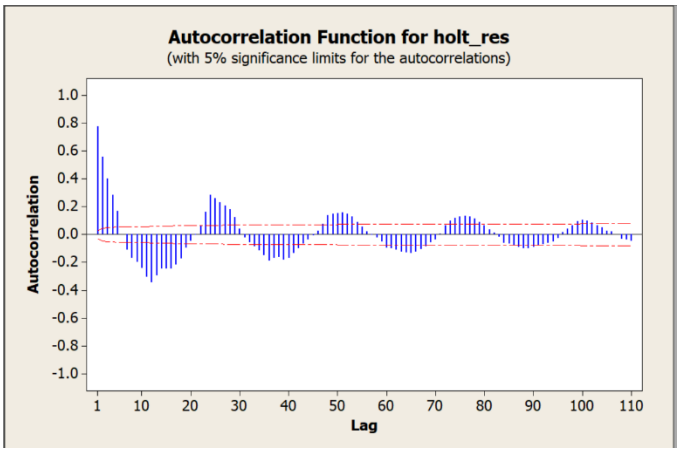

ภาพการวิเคราะห์ Autocorrelation (ACF) ของค่า Residual จากโมเดล (Holt-Winters)

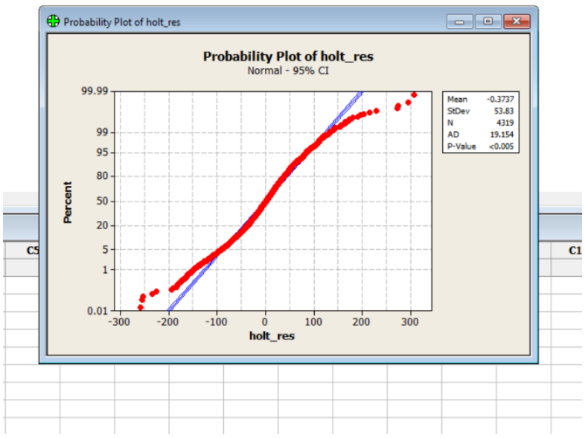

Probability Plot of holt_res (กราฟตรวจสอบการแจกแจงปกติของ Residual จากโมเดล Holt-Winters)

Descriptive Statistics: holt_res

Variable	N	N*	Mean	SE Mean	StDev	Minimum	Q1	Median	Q3
holt_res	4319	0	-0.374	0.819	53.830	-259.930	-29.655	1.147	30.304

Variable	Maximum
holt_res	308.687

ภาพการวิเคราะห์สถิติเชิงพรรณนา (Descriptive Statistics) ของค่า Residual (holt_res)

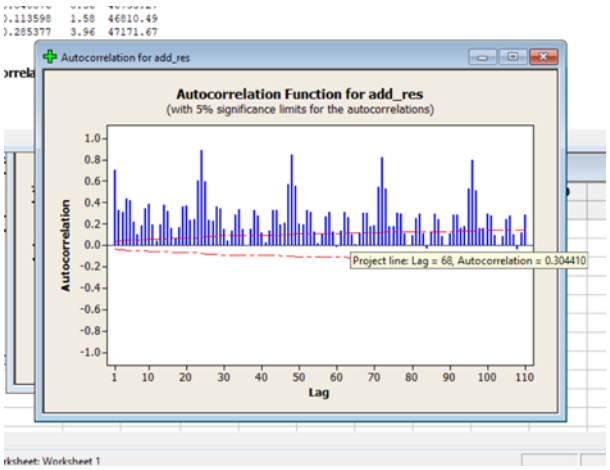

ภาพการวิเคราะห์ Autocorrelation (ACF) ของค่า Residual จากโมเดล (Additive)

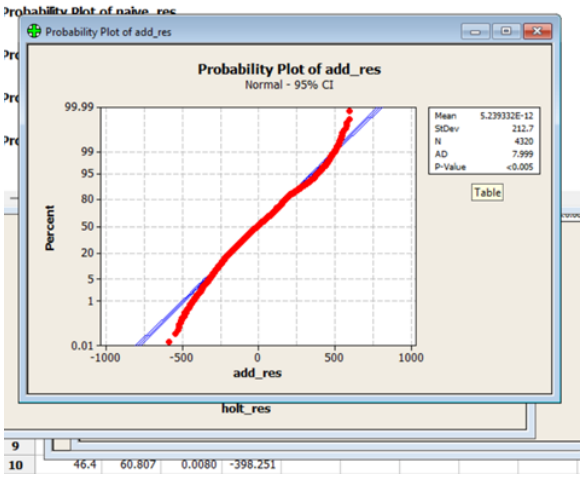

Probability Plot of holt_res (กราฟตรวจสอบการแจกแจงปกติของ Residual จากโมเดล Additive)

Descriptive Statistics: add_res

Variable	N	N*	Mean	SE Mean	StDev	Minimum	Q1	Median	Q3
add_res	4320	0	0.00	3.24	212.70	-589.84	-154.69	-10.89	143.12

Variable	Maximum
add_res	594.45

ภาพการวิเคราะห์สถิติเชิงพรรณนา (Descriptive Statistics) ของค่า Residual (add_res)