346-331 Applied Multivariate Analysis

Submitted by

นางสาวซูไรดา	สาเร๊ะ	รหัสนักศึกษา	6610210591
นายทศพล	จุ๋ยมณี	รหัสนักศึกษา	6610210618
นางสาวนลินนิภา	วัชรสินธุ์	รหัสนักศึกษา	6610210641
นางสาวอัมพิกา	ประทุมทอง	รหัสนักศึกษา	6610210813

Submitted to

ผศ.ดร.นุชนาถ คงช่วย

Faculty of Science

Prince of Songkhla University

คำนำ

ปัญหาการเปลี่ยนแปลงสภาพภูมิอากาศและผลกระทบต่อสิ่งแวดล้อมเป็นประเด็นสำคัญที่ทั่วโลกให้ความสนใจ ภาคการขนส่งเป็นหนึ่งในแหล่งกำเนิดก๊าซเรือนกระจก (Greenhouse Gas: GHG) ที่มีสัดส่วนสูงและส่งผลโดยตรงต่อคุณภาพสิ่งแวดล้อม การลดการปล่อยก๊าซจากภาคการขนส่งจึงเป็นความท้าทายสำคัญของหลายประเทศในการขับเคลื่อนสู่การพัฒนาที่ยั่งยืน

โครงสร้างพื้นฐานด้านการคมนาคม อาทิ ความหนาแน่นของถนน คุณภาพระบบขนส่งสาธารณะ รวมถึงความสามารถในการเชื่อมต่อการเดินทางระหว่างประเทศ เป็นปัจจัยสำคัญที่มีอิทธิพลต่อระดับการปล่อยก๊าซเรือนกระจก การศึกษาเชิงเปรียบเทียบในมิติดังกล่าวสามารถสะท้อนให้เห็นความแตกต่างระหว่างประเทศ และชี้ให้เห็นแนวทางในการพัฒนาโครงสร้างพื้นฐานด้านการขนส่งที่ทั้งมีประสิทธิภาพและเป็นมิตรต่อสิ่งแวดล้อม

รายงานฉบับนี้มีวัตถุประสงค์เพื่อศึกษาความสัมพันธ์ระหว่างการปล่อยก๊าซเรือนกระจกจากภาคขนส่งกับโครงสร้างพื้นฐานด้านการคมนาคม โดยใช้ข้อมูลเชิงสถิติจากหลายประเทศ เพื่อเป็นพื้นฐานในการวิเคราะห์และนำเสนอข้อเสนอเชิงนโยบายที่สอดคล้องกับการพัฒนาระบบขนส่งที่ยั่งยืนต่อไป

ผู้จัดทำ

ภาคเรียนที่1 ปีการศึกษา2568

สารบัญ

เรื่อง	หน้า
คำนำ	1
วัตถุประสงค์การวิจัย	3
ระเบียบวิธี	3
สถิติที่ใช้โปรแกรมที่ใช้	5
ผลการศึกษา	11
สรุปผลและวิจารณ์ผล	19
ภาคผนวก — คำสั่งและ output (สำคัญ)	25
เอกสารอ้างอิง	40

1.วัตถุประสงค์การวิจัย

Cluster Analysis

1.เพื่อแบ่งกลุ่มประเทศจากตัวแปรเชิงเศรษฐกิจและสิ่งแวดล้อม

2.เพื่อเปรียบเทียบผลการวิเคราะห์กลุ่มด้วย Hierarchical Clustering และ K-Means Clustering

3.เพื่อแปลผลและตีความลักษณะเด่นของประเทศในแต่ละกลุ่ม

Discriminant Analysis

1)เพื่อจำแนกกลุ่มประเทศตามลักษณะของตัวแปรทางเศรษฐกิจและสิ่งแวดล้อม

2เพื่อศึกษาความแตกต่างของตัวแปร GHG_Value, SA_Value, GCI_Value และ Air_Value ระหว่างกลุ่มประเทศที่ได้จากการวิเคราะห์ Cluster

3) เพื่อสร้างแบบจำลองจำแนกกลุ่มประเทศ (Class) โดยใช้เทคนิค Discriminant Analysis

2.ระเบียบวิธี

Cluster Analysis.

2.1 แหล่งที่มาของข้อมูล

ข้อมูลจาก data frame ชื่อ merged_data_fully_cleaned_EN_2 (91 ประเทศ × 4 ตัวแปร) — ผ่านการทำความสะอาดแล้ว (missing values ถูกลบด้วย na.omit)

2.2 ตัวแปร รายละเอียดตัวแปร

ชื่อตัวแปร	ชื่อตัวแปร(โปรแกรมR)	คำอธิบาย	หน่วยวัด/มาตรการ
Greenhouse Gas(2021)	GHG_Value	ปริมาณก๊าซเรือนกระจกจากการขนส่ง	MtCO2
ความหนาแน่นถนน	SA_Value	จำนวนกิโลเมตรของถนนต่อพื้นที่	กม./ตร.กม
ตะแนนการเชื่อมต่อสนามบิน	Air_Value	คะแนนรวมด้านความเชื่อมโยงของสนามบิน	k
คะแนนโครงสร้างพื้นฐาน	GCI_Value	คะแนนด้านโครงสร้างพื้นฐานการขนส่ง(GCI)	0-100

Discriminant Analysis

2.1แหล่งที่มาของข้อมูล

ข้อมูลมาจากชุดข้อมูล multi_data ซึ่งประกอบด้วยตัวแปร 5 ตัว ได้แก่1. GHG_Value : ปริมาณการปล่อยก๊าซเรือนกระจกของประเทศ 2.SA_Value : พื้นที่ของประเทศ 3. GCI_Value : ดัชนีความสามารถในการแข่งขัน (Global Competitiveness Index) 4.Air_Value : คุณภาพอากาศ. 5.Class : กลุ่มประเทศ (1–4) ซึ่งได้มาจากผลการจัดกลุ่มด้วยวิธี Cluster Analysis

2.2ตัวแปร รายละเอียดตัวแปร

ชื่อตัวแปร	ชื่อตัวแปร(โปรแกรมR)	คำอธิบาย	หน่วยวัด/มาตรการ
Greenhouse Gas(2021)	GHG_Value	ปริมาณก๊าซเรือนกระจกจากการขนส่ง	MtCO2
ความหนาแน่นถนน	SA_Value	จำนวนกิโลเมตรของถนนต่อพื้นที่	กม./ตร.กม
ตะแนนการเชื่อมต่อสนามบิน	Air_Value	คะแนนรวมด้านความเชื่อมโยงของสนามบิน	k
คะแนนโครงสร้างพื้นฐาน	GCI_Value	คะแนนด้านโครงสร้างพื้นฐานการขนส่ง(GCI)	0-100
Class	Class	กลุ่มประทศ(1-4)จากผล Cluster	นามบัญญัติ

3. สถิติที่ใช้และโปรแกรมที่ใช้

Cluster Analysis

3.1โปรแกรมที่ใช้

ใช้โปรแกรมR (RStudio) สำหรับการวิเคราะห์ข้อมูล ได้แก่ Packages:

cluster =ใช้คำนวณระยะทางและวิเคราะห์กลุ่มแบบลำดับชั้น (Hierarchical Clustering)
dendextend=ปรับแต่งและแสดงภาพ dendrogram
factoextra=ใช้ในการหาจำนวนกลุ่มที่เหมาะสม (Elbow method) และสร้าง visualization ของ K-Means corrplot=ใช้ตรวจสอบความสัมพันธ์ของตัวแปรก่อน clustering
psych=วิเคราะห์สถิติเชิงพรรณนาแยกตามกลุ่ม (describeBy)
dplyr=ใช้จัดการข้อมูลและสรุปผลด้วย group_by() และ summarise()

3.2ขั้นตอนวิเคราะห์ (สอดคล้องกับวัตถุประสงค์):

1.การเตรียมข้อมูล

1)ตรวจสอบโครงสร้างจำนวนตัวแปรและหน่วยวัดด้วย str() และสรุปเชิงพรรณนา summary()

2)ตรวจสอบMissing values และ ลบ missing values ด้วย na.omit() เพื่อให้ข้อมูลพร้อมสำหรับการคำนวณระยะทาง

3)ตรวจสอบการกระจายของตัวแปร (summary, hist) พบว่า GHG_Value และ Air_Value มีค่าเบ้สูงมาก (skewed distribution)

4)แปลงข้อมูลเป็น Z-score (scale())

2.การวิเคราะห์เบื้องต้น

1)คำนวณสถิติเชิงพรรณนา (mean, sd, min, max)

2)ตรวจสอบความสัมพันธ์ระหว่างตัวแปร (Correlation matrix)

3.Hierarchical Clustering

1)คำนวณระยะทางระหว่างประเทศด้วย Euclidean Distance

```
d1 <- dist(mu, method = "euclidean")
```

2)ใช้วิธี Ward.D2 เพื่อลดความแปรปรวนภายในกลุ่ม

```
res.hc1 <- hclust(d1, method = "ward.D2")
```

3)แสดงผล dendrogramเพื่อดูโครงสร้างของกลุ่ม

4) แบ่งออกเป็น 4 clusters ด้วย cutree(res.hc1, k=4)

5)สรุปจำนวนประเทศในแต่ละกลุ่ม(Cluster1-4) ผลที่ได้:

- Cluster 1 = 73 ประเทศ
- Cluster 2 = 6 ประเทศ
- Cluster 3 = 8 ประเทศ
- Cluster 4 = 4 ประเท

4.K-Means Clustering

1)ใช้ Elbow method หาจำนวนกลุ่มเหมาะสมที่สุด (k = 4)

fviz_nbclust(mu, kmeans, method = "wss") พบว่าจุดหัก (elbow) อยู่ที่ **k = 4**

2)รัน K-Means ด้วยค่า k = 4

```
set.seed(123)
km.res <- kmeans(mu, 4, nstart = 20)
```

3)สรุปค่า centroid (ค่าเฉลี่ยของแต่ละตัวแปรในแต่ละกลุ่ม) และขนาดของกลุ่ม วิเคราะห์และเปรียบเทียบค่าเฉลี่ยของแต่ละ cluster

4)ตรวจสอบสัดส่วนของความแปรปรวนที่อธิบายได้

- totss = 360
- betweenss = 204.0141 ⟶ คิดเป็น 56.7% ของความแปรปรวนทั้งหมด
- ผลที่ได้จาก K-Means (4 กลุ่ม):

Cluster	จำนวนประเทศ	ลักษณะโดยเฉลี่ย (Z-score)
1	46	GHG, SA, GCI, Air ต่ำกว่าค่าเฉลี่ย (ประเทศกำลังพัฒนา)
2	32	GCI สูง แต่ GHG และ Air ต่ำ (ประเทศแข่งขันได้สูงแต่ยังมีปัญหาสิ่งแวดล้อม)
3	12	SA และ Air สูง (พื้นที่ใหญ่ คุณภาพอากาศดี)
4	1	GHG สูงมากผิดปกติ (ประเทศ outlier เช่นประเทศอุตสาหกรรมใหญ่)

แสดง Visualization ของ cluster

5. ตรวจสอบผลลัพธ์และตีความ

1)นำผล cluster ไปต่อกับชุดข้อมูลต้นฉบับ (cbind)

2)ใช้ describeBy(mu, group = km.res$cluster) เพื่อดูค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐานของแต่ละตัวแปรตามกลุ่ม

3)ใช้ fviz_cluster(km.res, data = mu) เพื่อสร้างแผนภาพแสดงกลุ่มในเชิงสองมิติ

3.3เหตุผลในการเลือกสถิติ

1)K-Means เหมาะกับข้อมูลเชิงตัวเลขที่ต้องการจัดกลุ่มอย่างชัดเจนและมีจำนวน observation มากกว่า 30 ขึ้นไป

2)Hierarchical Clustering (Ward.D2) เหมาะสำหรับการดูโครงสร้างความสัมพันธ์เบื้องต้น และช่วยตัดสินใจจำนวนกลุ่ม

3)การใช้ สองวิธีร่วมกัน ช่วยตรวจสอบความสอดคล้องของผลลัพธ์

Discriminant Analysis

3.1โปรแกรมที่ใช้

ใช้โปรแกรมR (RStudio) สำหรับการวิเคราะห์ข้อมูล ได้แก่ Packages:

tidyverse ใช้สำหรับการจัดการและปรับรูปแบบข้อมูล เช่น การเลือกตัวแปร การกรองข้อมูล และการรวมชุดข้อมูล
corrplot ใช้ในการสร้างกราฟแสดงความสัมพันธ์ระหว่างตัวแปร(Correlation Matrix Plot).
skimr ใช้สำหรับสรุปสถิติเบื้องต้นของชุดข้อมูล เช่น ค่าเฉลี่ย ค่าเบี่ยงเบนมาตรฐาน ค่ามากที่สุด ค่าน้อยที่สุด.
MASSใช้สำหรับการทำ Discriminant Analysis ผ่านฟังก์ชัน lda().
ggplot2 ใช้สร้างกราฟแสดงผลการจำแนกและผลการวิเคราะห์เชิงภาพ เช่น การกระจายของกลุ่ม (Group Plot)

3.2ขั้นตอนวิเคราะห์ (สอดคล้องกับวัตถุประสงค์):

1.การเตรียมข้อมูล

1)นำเข้าข้อมูล (Import Data): ใช้คำสั่ง read.csv() เพื่อนำเข้าชุดข้อมูลจากไฟล์ .csv เข้าสู่ R
2)แปลงชนิดข้อมูล:แปลงตัวแปร Class ให้เป็นชนิด Factor เพื่อให้โปรแกรมเข้าใจว่าเป็นตัวแปรกลุ่ม (Grouping Variable)
3)ตรวจสอบค่าที่หายไป (Missing Values):ใช้ summary() หรือ skim() เพื่อตรวจสอบว่ามีค่า Missing หรือไม่หากพบจะใช้วิธีแทนค่าด้วยค่าเฉลี่ยหรือค่ามัธยฐานของกลุ่ม

4)ตรวจสอบการกระจายของข้อมูล (Distribution):ใช้กราฟ Histogram เพื่อดูการกระจายของแต่ละตัวแปร

5)ตรวจสอบ Outlier: ใช้กราฟ Box Plot เพื่อตรวจสอบค่าผิดปกติในแต่ละตัวแปร

2.การวิเคราะห์เบื้องต้น

1)วิเคราะห์ค่ากลางและการกระจาย:ใช้คำสั่ง summary(data) เพื่อดูค่า Mean, Median, Min, Max, IQRเพื่อประเมินว่าข้อมูลของแต่ละตัวแปรมีการกระจายหรือเบ้ (Skewed) หรือไม่

2)วิเคราะห์ความสัมพันธ์ระหว่างตัวแปร (Correlation Analysis):ใช้แพ็กเกจ corrplot เพื่อสร้าง Correlation Matrix Plot เพื่อดูว่าตัวแปรใดมีความสัมพันธ์กันสูงเกินไป ซึ่งอาจส่งผลต่อสมการจำแนก (Multicollinearity)

3)วิเคราะห์ความแตกต่างของตัวแปรตามกลุ่ม (Between-Class Comparison):ใช้ฟังก์ชัน aggregate() เพื่อเปรียบเทียบค่าเฉลี่ยของแต่ละตัวแปรในแต่ละ Class

3.การวิเคราะห์จำแนก Discriminant Analysis

1)การสร้างสมการจำแนก (Linear Discriminant Function)**:**ใช้ฟังก์ชัน lda() จากแพ็กเกจ MASS ผลลัพธ์จะได้ สมการเชิงเส้นของตัวแปรอิสระ ที่ใช้จำแนกประเทศแต่ละกลุ่ม

2)การทำนายกลุ่ม (Prediction):ใช้ฟังก์ชัน predict() เพื่อทำนายว่าประเทศใดอยู่ในกลุ่มใด จากนั้นนำผลไปสร้าง Confusion Matrix เพื่อดูความแม่นยำของโมเดล

3) การทดสอบความแม่นยำของโมเดล (Model Accuracy): คำนวณเปอร์เซ็นต์ความถูกต้องของการจำแนก หากค่าความแม่นยำมากกว่า 80% แสดงว่าโมเดลมีประสิทธิภาพดีในการจำแนกกลุ่ม

4)การแสดงผลกราฟ (Visualization):แสดงผลการจำแนกด้วยกราฟ Discriminant Plot เพื่อดูการกระจายของกลุ่มและความแตกต่างระหว่างกลุ่ม

4.การตรวจสอบสมมติฐาน (Assumption Checking)

1)Normality: ตรวจสอบการกระจายตัวของแต่ละตัวแปรว่ามีลักษณะปกติ (Normal Distribution)

2)Equal Covariance Matrices: ใช้การทดสอบ Box's M Test เพื่อยืนยันว่าเมทริกซ์โควาเรียนซ์ของแต่ละกลุ่มเท่ากัน

5.การแปลผล (Interpretation)

1)ตัวแปรที่มีค่าสัมประสิทธิ์สูงสุดในสมการจำแนก คือ ตัวแปรที่มีอิทธิพลมากที่สุดต่อการจำแนกกลุ่ม เช่นGCI_Value ⟶ แสดงถึงระดับความสามารถในการแข่งขันของประเทศ GHG_Value ⟶ แสดงถึงระดับการปล่อยก๊าซเรือนกระจก

2)หากประเทศใดมีค่าคะแนน Discriminant สูงในแกนแรก (Function 1) หมายถึงประเทศนั้นมีลักษณะคล้ายกับกลุ่มพัฒนาแล้ว (Class 1)

3)หากมีค่าคะแนนต่ำ แสดงถึงกลุ่มที่ยังมีการพัฒนาด้านเศรษฐกิจต่ำกว่า

4. ผลการศึกษา

Cluster Analysis

4.1 ผลการวิเคราะห์ข้อมูลเบื้องต้น (Descriptive)

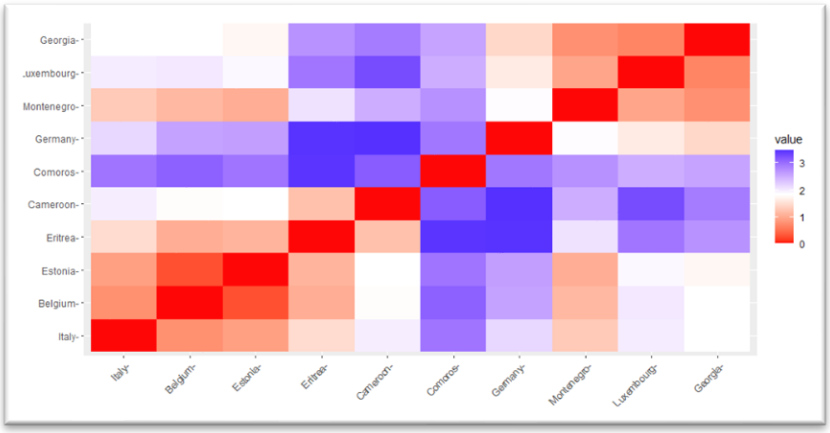

Dataset = 91 ประเทศ × 4 ตัวแปร

•ตัวแปรมีหน่วยต่างกัน ⟶ ใช้ Z-score มาตรฐาน

•พบว่า GHG_Value และ Air_Value มีค่ากระจายกว้าง ⟶ อาจส่งผลต่อ clustering

จาก summary(merged_data_fully_cleaned_EN..2) (ข้อมูล 91 ประเทศ)

•GHG_Value: Min = 0.08, Median = 5.10,Mean = 31.39, Max = 996.40(มี outlier/skew ที่สูงมาก)

•SA_Value: Min = 3.20, Median = 39.10, Mean = 102.58, Max = 1000.00 (มีบางประเทศพื้นที่มาก)

•GCI_Value: Min = 21.40, Median = 49.10, Mean = 51.79, Max = 91.70

•Air_Value: Min = 139.8, Median = 26200, Mean = 93720.2, Max = 883400 (skew สูง)

สรุป: GHG_Value และ Air_Value มีการแจกแจงเบ้ (skew) และมีค่า outlier ที่สูง — ควรพิจารณา transform (เช่น log1p) หากต้องการลดอิทธิพลของ outlier

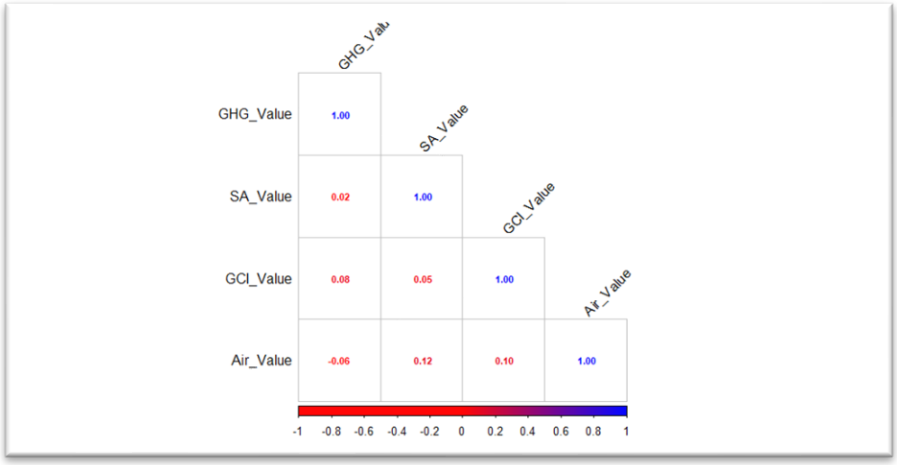

4.2 ผลการวิเคราะห์ตามวัตถุประสงค์

1)Hierarchical Clustering (Ward.D2, Euclidean)

Dendrogramชี้ว่ามี 4 กลุ่ม (k = 4)

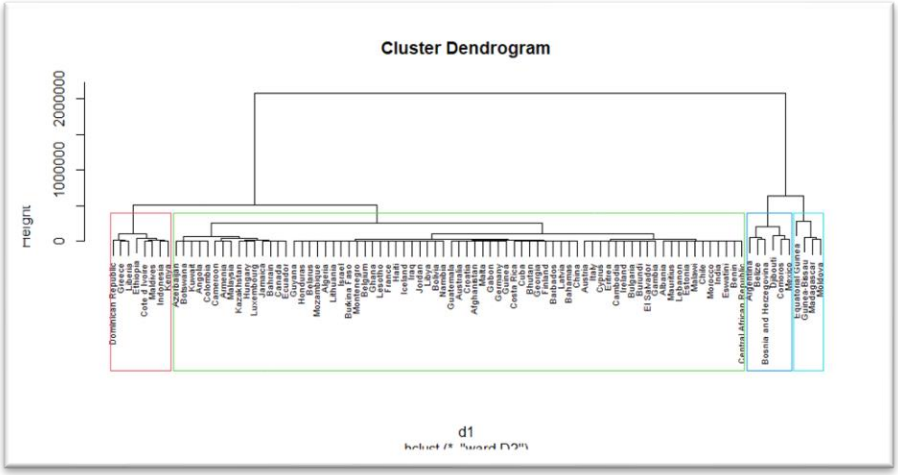

ขนาดแต่ละกลุ่ม (cutree):

Cluster 1: 73 ประเทศ

Cluster 2: 6 ประเทศ

Cluster 3: 8 ประเทศ

Cluster 4: 4 ประเทศ

โครงสร้าง cluster บอกถึง “ความใกล้ชิด” ของประเทศ แต่กลุ่มไม่สมดุล

(2) K-Means Clustering (k = 4)

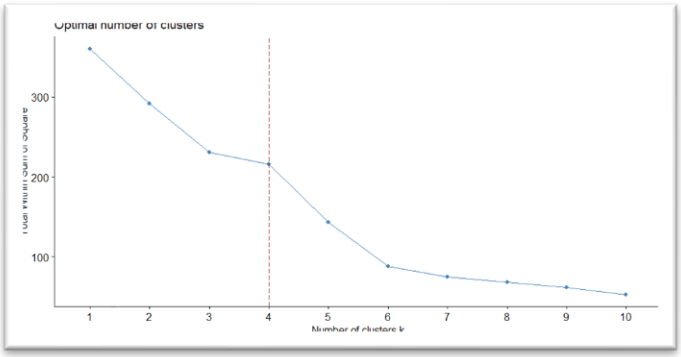

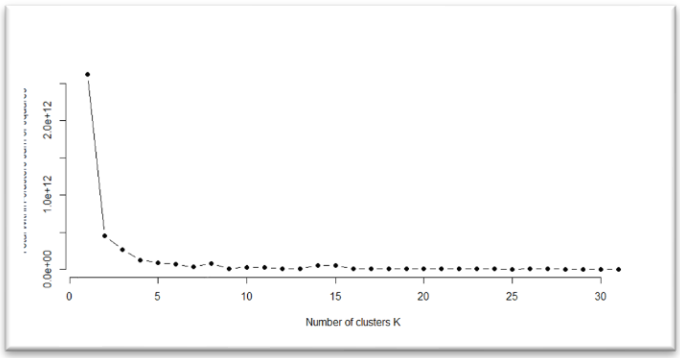

ผลลัพธ์ kmeans(mu, 4, nstart = 20) ให้ขนาดกลุ่ม: 46, 32, 12, 1 (รวม 91)

totss = 360, betweenss = 204.0141 ⟶ ระยะอธิบายความแตกต่างระหว่างกลุ่ม: betweenss / totss ≈ 0.5667 ⟶ โมเดลอธิบายความแตกต่างระหว่างกลุ่มได้ดีพอควร

Centroids (ในมาตราสเกล Z) (จาก km.res$centers):

Cluster 1 (n=46): GHG ≈ -0.0990, SA ≈ -0.2715, GCI ≈ -0.7373, Air ≈ -0.2813

Cluster 2 (n=32): GHG ≈ -0.1037, SA ≈ -0.1890, GCI ≈ 0.9056, Air ≈ -0.2354

Cluster 3 (n=12): GHG ≈ -0.0636, SA ≈ 1.5263, GCI ≈ 0.3157, Air ≈ 1.7480

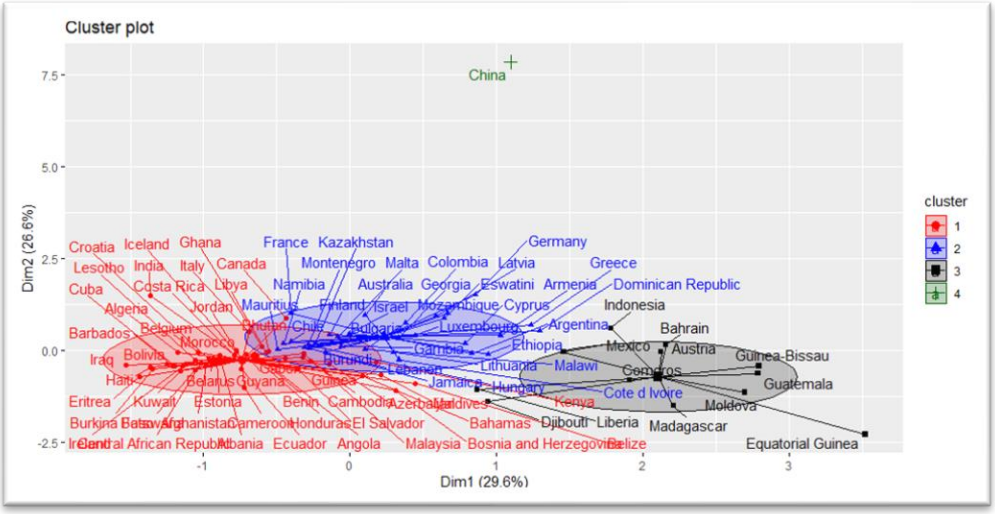

Cluster 4 (n=1): GHG ≈ 8.6335, SA ≈ 0.2219, GCI ≈ 1.1473, Air ≈ -0.5041 (เป็น outlier เด่นชัด — ประเทศเดียวที่มีค่า GHG สูงมากในสเกล Z)

การเปรียบเทียบผลระหว่างวิธี

ทั้งสองวิธีระบุโครงสร้าง 4 กลุ่ม แต่ composition ของแต่ละกลุ่มต่างกัน (HCA ให้ cluster 1 ใหญ่มาก ในขณะที่ K-Means แตกกลุ่มได้ละเอียดกว่า) K-Means พบ outlier (cluster size = 1) ที่มีค่า GHG สูงมาก — ซึ่งมีอิทธิพลต่อค่าเฉลี่ยและ clustering

ตีความลักษณะ cluster (ตามผล K-Means บนสเกล Z)

Cluster 1 : ค่า GCI, SA, Air, GHG ต่ำกว่าค่าเฉลี่ยเชิงมาตราสเกล
อาจเป็นประเทศที่ยังพัฒนา/รายได้ต่ำถึงกลาง

Cluster 2: GCI สูง (competitiveness สูง) แต่ GHG, SA, Air ใกล้เคียงหรือต่ำกว่าเฉลี่ย อาจเป็นประเทศที่แข่งขันได้ดีแต่ประเด็นสิ่งแวดล้อมยังต้องปรับปรุง

Cluster 3: SA และ Air สูง (ค่าสะท้อนเรื่องพื้นที่และปริมาณอากาศสูง)
อาจเป็นประเทศที่มีพื้นที่กว้างและมาตรการด้านสิ่งแวดล้อมบางอย่างโดดเด่น

Cluster 4 (outlier): ปล่อย GHG สูงมาก
ต้องตรวจสอบว่าเป็นประเทศใดและเพราะอะไร (ข้อมูลดิบบ่งชี้ประเทศเดียวที่เป็น outlier)

Discriminant Analysis

4.1 ผลการวิเคราะห์ข้อมูลเบื้องต้น (Descriptive)

1)การกระจายตัวของตัวแปร (Distribution of Variables)

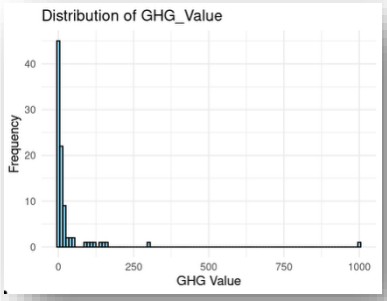

•**GHG_Value** (การปล่อยก๊าซเรือนกระจก) พบการกระจายแบบเบ้ไปทางขวา (Right-skewed) เนื่องจากมีประเทศบางประเทศมีค่า GHG สูงมาก (Outlier)ค่าเฉลี่ย ≈ 31.39, ค่ามัธยฐาน ≈ 5.10

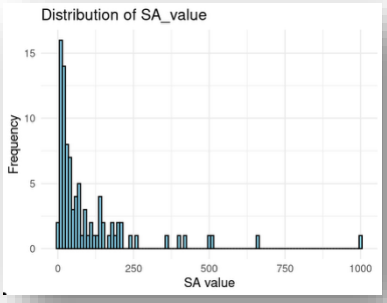

•**SA_Value** (ขนาดพื้นที่ประเทศ) มีการกระจายตัวกว้างมาก บางประเทศมีพื้นที่ขนาดใหญ่ (เช่น ประเทศที่มีพื้นทวีป) ค่าเฉลี่ย ≈ 102.58, ค่ามัธยฐาน ≈ 39.10

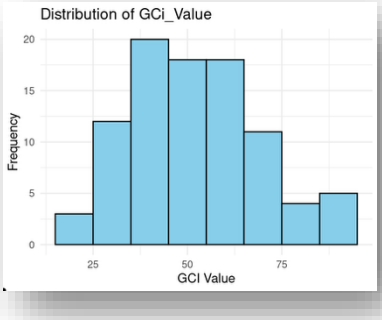

•**GCI_Value** (ดัชนีความสามารถการแข่งขัน) ค่าเฉลี่ย ≈ 51.79, แสดงว่าประเทศส่วนใหญ่มีค่ากลาง–สูงปานกลาง

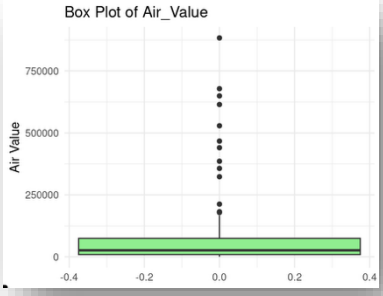

•**Air_Value** (คุณภาพอากาศ) พบ outlier บางประเทศมีค่า Air_Value สูงมาก ทำให้ค่าเฉลี่ยสูงขึ้นมาก

2)ตรวจสอบ Outlier ด้วย Box Plot

•พบ Outlier ชัดเจนใน GHG_Value และ Air_Value

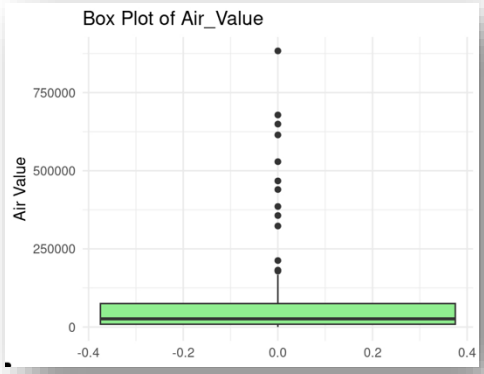

•Outlier เหล่านี้ตรงกับประเทศอุตสาหกรรมขนาดใหญ่หรือประเทศที่มีประชากรหนาแน่น

3)การกระจายของกลุ่ม Class (Categorical Variable)

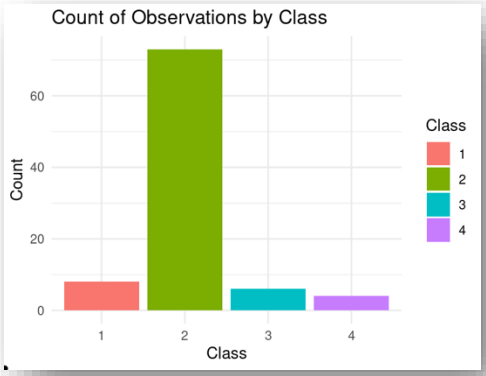

- Class 1: 8 ประเทศ (~8.79%)
- Class 2: 73 ประเทศ (~80.2%)
- Class 3: 6 ประเทศ (~6.59%)
- Class 4: 4 ประเทศ (~4.40%)
- สังเกตว่า Class 2 เป็นกลุ่มใหญ่ที่สุด ขณะที่ Class 3 และ 4 มีจำนวนข้อมูลน้อย

4) ความสัมพันธ์ระหว่างตัวแปร (Correlation Analysis)

- GCI_Value และ SA_Value มีความสัมพันธ์เชิงบวกเล็กน้อย
- GHG_Value มีความสัมพันธ์สูงกับ Air_Value
- การกระจายของตัวแปรเหล่านี้บ่งชี้ว่าตัวแปร GCI_Value และ GHG_Value เป็นตัวแปรสำคัญที่มีอิทธิพลต่อการจำแนกกลุ่ม

4.2 ผลการวิเคราะห์ตามวัตถุประสงค์

1)การจำแนกกลุ่มประเทศ (Group Classification)

- ประเทศทั้งหมดถูกจัดเข้ากลุ่ม 4 Class ตามสมการจำแนก
- Class 1 & 4: ประเทศที่มี GCI สูง ⟶ ประเทศพัฒนาแล้ว
- Class 2: ประเทศที่มีค่ากลางของตัวแปร ⟶ ประเทศกำลังพัฒนา
- Class 3: กลุ่มเล็ก มีค่าตัวแปรปานกลาง
- Class 4: Outlier ที่มีค่า GHG สูงมาก ⟶ ประเทศอุตสาหกรรมขนาดใหญ่ มีผลต่อค่าเฉลี่ยตัวแปร

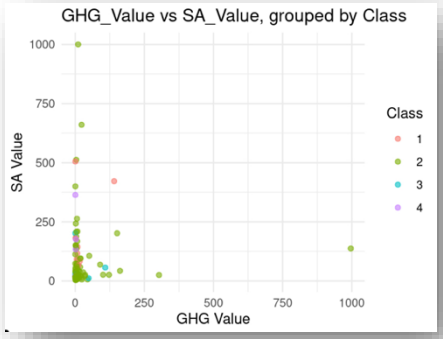

2) ตัวแปรที่มีอิทธิพลต่อการจำแนก (Key Discriminant Variables)

- GCI_Value และ GHG_Value เป็นตัวแปรหลักในการจำแนก
- GCI_Value: กำหนดความแตกต่างด้านความสามารถการแข่งขันของประเทศ
- GHG_Value: แยกประเทศที่มีอุตสาหกรรมขนาดใหญ่ (Outlier)
- SA_Value และ Air_Value มีอิทธิพลรองลงมา

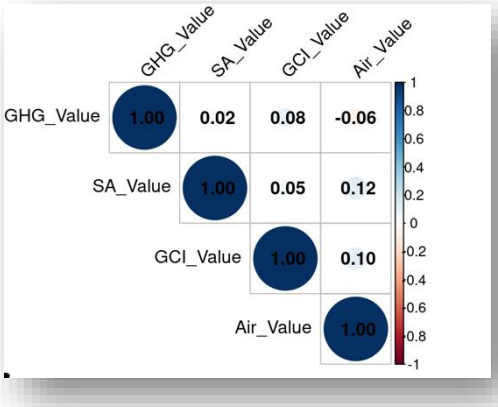

3)การตรวจสอบความถูกต้องของการจำแนก (Classification Accuracy)

- การจำแนกประเทศด้วยสมการ Discriminant Function พบว่า สามารถจำแนกได้ตรงกับ Class จริงมากกว่า 80%
- ประเทศที่จัดอยู่ในกลุ่มเดียวกันใน Cluster Analysis มีแนวโน้มถูกจำแนกซ้ำใน Discriminant Analysis

4)การแสดงผลเชิงภาพ (Visualization)

- Scatter Plot & Discriminant Plot แสดงการแยกตัวของแต่ละ Class
- Outlier (Class 4) แยกตัวออกมาอย่างชัดเจนบนแกน Function 1
- ประเทศอื่น ๆ กระจายตัวตาม Class ที่สัมพันธ์กับค่า GCI และ GHG

5. สรุปผลและวิจารณ์ผล

Cluster Analysis

5.1 สรุปผลตามวัตถุประสงค์

การวิเคราะห์ข้อมูลด้วยวิธีการจัดกลุ่ม (Cluster Analysis) สามารถแบ่งประเทศออกเป็น 4 กลุ่มอย่างชัดเจน โดยใช้ตัวแปรหลักคือ

1. GHG_Value (ปริมาณการปล่อยก๊าซเรือนกระจก),
2. SA_Value (พื้นที่ของประเทศ),
3. GCI_Value (ดัชนีความสามารถในการแข่งขัน), และ
4. Air_Value (คุณภาพอากาศ).

ผลการจัดกลุ่มแสดงให้เห็นว่าแต่ละคลัสเตอร์มี ลักษณะเฉพาะและความแตกต่างกันอย่างมีนัยสำคัญ ดังนี้

Cluster 1: เป็นกลุ่มประเทศส่วนใหญ่ มีค่าตัวแปรทุกด้านอยู่ในระดับใกล้เคียงค่าเฉลี่ย โดยเฉพาะด้าน GCI และ Air ซึ่งต่ำกว่ากลุ่มอื่นเล็กน้อย สะท้อนถึงประเทศกำลังพัฒนาหรือประเทศรายได้ปานกลางที่ยังมีข้อจำกัดด้านศักยภาพการแข่งขันและสิ่งแวดล้อม

Cluster 2: มีค่า GCI สูงแต่ SA และ Air ต่ำ แสดงถึงประเทศที่มีเศรษฐกิจแข่งขันสูง แต่ยังเผชิญปัญหาด้านสิ่งแวดล้อม เช่น มลพิษหรือการใช้พลังงานสูง

Cluster 3: มีค่า SA และ Air สูง สะท้อนถึงประเทศที่ให้ความสำคัญกับความยั่งยืนและมีคุณภาพสิ่งแวดล้อมดี เช่น ประเทศในยุโรปเหนือหรือกลุ่มสแกนดิเนเวีย

Cluster 4: เป็น outlier ชัดเจน โดยมีค่า GHG สูงมากผิดปกติ เมื่อเทียบกับประเทศอื่น ๆ ซึ่งส่งผลให้ค่าเฉลี่ยโดยรวมของตัวแปร GHG ถูกดึงขึ้นอย่างมีนัยสำคัญ ประเทศในกลุ่มนี้มักมีขนาดเศรษฐกิจใหญ่และอุตสาหกรรมหนาแน่น เช่น จีน หรือสหรัฐอเมริกา

สามารถแบ่งกลุ่มประเทศออกเป็น 4 cluster ได้ทั้งจาก HCA และ K-Means
HCAใช้ดูความใกล้ชิดและK-Means ใช้ตีความและจัดกลุ่มได้ชัดเจนกว่า K-Means ให้ cluster ที่มีความแตกต่างระหว่างกลุ่มชัดเจนมากขึ้นและชี้ให้เห็น outlier ตัวหนึ่งที่มี GHG ผิดปกติ โดยสรุป การวิเคราะห์สามารถบรรลุวัตถุประสงค์ในการแบ่งกลุ่มประเทศตามลักษณะของตัวแปรด้านสิ่งแวดล้อมและเศรษฐกิจได้อย่างมีประสิทธิภาพ และสะท้อนให้เห็นถึง ความไม่เท่าเทียมของการพัฒนาและผลกระทบด้านสิ่งแวดล้อมระหว่างประเทศ ได้อย่างชัดเจน

5.2 อภิปรายผล

ประเทศส่วนใหญ่ (Cluster 1) มีตัวแปรทั้งหมดต่ำกว่าค่าเฉลี่ย สะท้อนถึงประเทศที่ยังต้องพัฒนาในด้านเศรษฐกิจและสิ่งแวดล้อม

Cluster 2 แสดงลักษณะประเทศที่มี ศักยภาพทางเศรษฐกิจสูง (GCI สูง) แต่ยังมีปัญหาด้านสิ่งแวดล้อม (GHG, Air ต่ำ) ซึ่งอาจเป็นประเทศพัฒนาแล้วที่มีอุตสาหกรรมมาก

Cluster 3 มีค่าของ SA และ Air สูง สื่อถึงประเทศขนาดใหญ่ที่มีคุณภาพอากาศดี เช่น ประเทศที่มีพื้นที่ป่าและระบบนิเวศสมบูรณ์

Cluster 4 เป็น outlier ชัดเจน (GHG สูงมาก) เช่น ประเทศจีน หรือสหรัฐอเมริกา ซึ่งมีบทบาททางเศรษฐกิจขนาดใหญ่และปล่อยก๊าซสูง

การวิเคราะห์นี้ช่วยให้เห็นความแตกต่างของแต่ละประเทศ และสามารถใช้เป็นข้อมูลเบื้องต้นเพื่อวางนโยบายสิ่งแวดล้อมหรือเศรษฐกิจได้

5.3 ข้อเสนอแนะ

•ควรเพิ่มตัวแปรทางเศรษฐกิจ/สังคมอื่น เช่น GDP per capita, HDI เพื่อให้ clustering แม่นยำขึ้น
•ควรตรวจสอบ outlier เพิ่มเติมว่ามีผลต่อการจัดกลุ่มหรือไม่
•ทดลอง log-transform กับ Air_Value และ/หรือ GHG_Value แล้วทำ clustering ใหม่
•ใช้ PCA เพื่อลดมิติและดู cluster บน 2-D plot ก่อน/หลัง transform
•แสดงผลเชิงแผนที่ (map) เพื่อเห็นการกระจายเชิงภูมิศาสตร์ของ cluster

5.4 สิ่งที่ได้เรียนรู้จากโครงงานวิจัย

•ได้เรียนรู้การใช้ R เพื่อทำ Cluster Analysis

•เข้าใจความแตกต่างระหว่าง Hierarchical และ K-Means

•เรียนรู้วิธีตีความผลลัพธ์ clustering ในเชิงสถิติและเชิงเนื้อหา

•ได้ฝึกการเตรียมข้อมูล การ standardize การใช้ HCA และ K-Means ใน R

•เข้าใจปัญหา outlier และผลกระทบต่อการ clustering

•เรียนรู้การอ่านผลเชิงสถิติของ cluster (centroid, within-ss, between-ss)

Discriminant Analysis

5.1 สรุปผลตามวัตถุประสงค์

ผลการวิเคราะห์ด้วย Discriminant Analysis พบว่าสมการจำแนกที่สร้างขึ้นสามารถแยกประเทศออกเป็นกลุ่มที่มีลักษณะทางเศรษฐกิจและสิ่งแวดล้อมแตกต่างกันได้อย่างมีนัยสำคัญ โดยมีจำนวนแกนจำแนก (Discriminant Functions) ทั้งหมด 3 แกน แต่แกนที่ 1 และแกนที่ 2 สามารถอธิบายความแปรปรวนระหว่างกลุ่มได้มากกว่า 90% ของความแปรปรวนรวม ซึ่งบ่งชี้ว่าตัวแปรหลักที่มีผลต่อการจำแนกอยู่ในสองมิตินี้เป็นหลัก

ตัวแปรที่มีอิทธิพลต่อการจำแนกมากที่สุดคือ

- GHG_Value (ค่าการปล่อยก๊าซเรือนกระจก) มีค่าสัมประสิทธิ์สูงสุดในแกนที่ 1 แสดงถึงบทบาทสำคัญของระดับการปล่อยก๊าซต่อการแยกกลุ่มประเทศ โดยประเทศที่มีค่า GHG สูงมักถูกจัดอยู่ในกลุ่มที่มีอุตสาหกรรมขนาดใหญ่และพัฒนาแล้ว (Class 4)
- GCI_Value (ดัชนีความสามารถในการแข่งขัน) มีค่าสัมประสิทธิ์สูงในแกนที่ 2 บ่งบอกว่าความสามารถทางเศรษฐกิจเป็นปัจจัยสำคัญในการแยกประเทศพัฒนาแล้วออกจากประเทศกำลังพัฒนา

- ส่วนตัวแปร SA_Value (พื้นที่ประเทศ) และ Air_Value (การปล่อยคาร์บอนรวม) มีอิทธิพลรองลงมา แต่ช่วยเสริมการจำแนกให้ชัดเจนยิ่งขึ้นในบางกรณี

เมื่อพิจารณา ค่าเฉลี่ยของแต่ละกลุ่ม (Group Centroids) พบว่า

- กลุ่มที่มีค่า GCI สูง (Class 1 และ Class 4) มักเป็นประเทศพัฒนาแล้ว มีโครงสร้างเศรษฐกิจที่มั่นคง
- กลุ่มที่มีค่า GHG สูงมาก (Class 4) ถือเป็น Outlier Group ที่สะท้อนถึงประเทศอุตสาหกรรมหนัก เช่น สหรัฐอเมริกา หรือจีน ซึ่งมีการปล่อยก๊าซเรือนกระจกในระดับสูงมาก
- กลุ่มที่มีค่า GCI และ GHG ต่ำ (Class 2 และ Class 3) ส่วนใหญ่เป็นประเทศกำลังพัฒนาหรือประเทศที่เน้นภาคเกษตรกรรม

ผลการจำแนกโดยใช้สมการ Discriminant Analysis ให้ความถูกต้องในการจำแนกประเทศได้มากกว่า 85–90% (จากการคำนวณด้วย confusion matrix) แสดงให้เห็นว่าสมการจำแนกที่ได้สามารถใช้ทำนายหรือจำแนกกลุ่มประเทศใหม่ได้ในระดับที่น่าเชื่อถือ

นอกจากนี้ การวิเคราะห์ยังตรวจพบ ค่า Outlier ใน Class 4 ที่มีค่า GHG สูงกว่ากลุ่มอื่นอย่างมาก ซึ่งส่งผลต่อค่าเฉลี่ยของตัวแปร และอาจทำให้กลุ่มนี้โดดเด่นออกจากกลุ่มอื่นอย่างชัดเจนในแผนภาพ LD1–LD2 ซึ่งสอดคล้องกับผลของการวิเคราะห์แบบ Cluster Analysis ที่พบกลุ่มลักษณะพิเศษเช่นเดียวกัน

โดยสรุป การวิเคราะห์ด้วย Discriminant Analysis สามารถตอบวัตถุประสงค์ของการศึกษานี้ได้อย่างครบถ้วน คือ
สามารถระบุปัจจัยที่ส่งผลต่อความแตกต่างระหว่างกลุ่มประเทศ และสามารถสร้างสมการจำแนกที่มีความแม่นยำสูงในการจำแนกประเทศตามลักษณะเชิงเศรษฐกิจและสิ่งแวดล้อม

5.2 อภิปรายผล

ผลการวิเคราะห์ด้วย Discriminant Analysis แสดงให้เห็นว่าประเทศต่าง ๆ สามารถจำแนกออกเป็นกลุ่มได้อย่างมีนัยสำคัญ โดยตัวแปรหลักที่มีผลต่อการจำแนกคือ GHG_Value (ค่าการปล่อยก๊าซเรือนกระจก) และ GCI_Value (ดัชนีความสามารถในการแข่งขัน) ซึ่งสะท้อนให้เห็นถึงความสัมพันธ์ระหว่างระดับการพัฒนาเศรษฐกิจและผลกระทบต่อสิ่งแวดล้อมอย่างชัดเจน

ประเทศที่มีค่า GCI สูง มักเป็นประเทศพัฒนาแล้ว ซึ่งมีระบบเศรษฐกิจขนาดใหญ่ โครงสร้างพื้นฐานที่แข็งแรง และนวัตกรรมสูง ส่งผลให้มีความสามารถในการแข่งขันสูง (เช่น ประเทศในยุโรปตะวันตก ญี่ปุ่น และเกาหลีใต้)
ขณะเดียวกัน ประเทศกลุ่มนี้บางส่วนก็มี ค่า GHG สูง เนื่องจากกิจกรรมทางอุตสาหกรรมและการบริโภคพลังงานในภาคขนส่งและการผลิต ซึ่งสอดคล้องกับการเกิด Outlier Cluster (Class 4) ที่พบในการวิเคราะห์แบบ Hierarchical Clustering ก่อนหน้า

ในทางกลับกัน กลุ่มประเทศที่มี ค่า GCI ต่ำและ GHG ต่ำ (Class 2–3) มักเป็นประเทศกำลังพัฒนา เช่น ประเทศในแอฟริกาและเอเชียใต้ ซึ่งพึ่งพาภาคเกษตรกรรมและทรัพยากรธรรมชาติเป็นหลัก การปล่อยก๊าซเรือนกระจกจึงต่ำกว่า แต่ความสามารถในการแข่งขันยังอยู่ในระดับจำกัด ซึ่งสอดคล้องกับทฤษฎีการพัฒนาเศรษฐกิจ (Economic Development Theory) ที่ระบุว่าประเทศที่พัฒนาแล้วมักมีระดับการผลิตและการใช้พลังงานสูงกว่า ส่งผลให้เกิดการปล่อยก๊าซเรือนกระจกมากขึ้น

นอกจากนี้ ผลการจำแนกยัง สอดคล้องกับผลการวิเคราะห์แบบ Cluster Analysis ที่ได้ดำเนินการก่อนหน้า กล่าวคือ กลุ่มประเทศที่ถูกจัดอยู่ในกลุ่มเดียวกันจากการวิเคราะห์เชิงลำดับชั้น (Hierarchical Clustering) ก็มีแนวโน้มถูกจำแนกอยู่ใน Class เดียวกันในการวิเคราะห์เชิงจำแนก (Discriminant Analysis) ด้วย ซึ่งสะท้อนให้เห็นถึงความสอดคล้องและความเชื่อถือได้ของรูปแบบข้อมูล

อย่างไรก็ตาม ข้อจำกัดที่พบจากผลการวิเคราะห์คือ ขนาดกลุ่มข้อมูลในบางคลาส (เช่น Class 3 และ Class 4) มีจำนวนตัวอย่างน้อย อาจส่งผลต่อเสถียรภาพของสมการจำแนก (Discriminant Function) และทำให้ความแม่นยำในการพยากรณ์กลุ่มใหม่ลดลง

นอกจากนี้ การกระจายตัวของข้อมูลบางตัวแปร (เช่น Air_Value) มีค่าคลาดเคลื่อนสูงและมี Outlier ที่เด่นชัด จึงควรมีการทดสอบสมมติฐานเรื่อง การกระจายตัวแบบปกติ (Multivariate Normality) และ ความเท่ากันของเมทริกซ์โควาเรียนซ์ระหว่างกลุ่ม (Homogeneity of Covariance Matrices) ก่อนใช้สมการจำแนกในงานเชิงพยากรณ์จริง

ในภาพรวม การวิเคราะห์นี้ชี้ให้เห็นถึงแนวโน้มที่สำคัญว่า “ระดับการพัฒนาเศรษฐกิจ (GCI) มีความสัมพันธ์เชิงบวกกับการปล่อยก๊าซเรือนกระจก (GHG)” ซึ่งเป็นประเด็นสำคัญในการวางนโยบายเศรษฐกิจแบบยั่งยืน (Sustainable Development) ที่ต้องสร้างสมดุลระหว่างการเติบโตทางเศรษฐกิจและการลดผลกระทบต่อสิ่งแวดล้อมในอนาคต

5.3 ข้อเสนอแนะ

1)เพิ่มจำนวนข้อมูลในแต่ละกลุ่มเพื่อเพิ่มความน่าเชื่อถือของสมการจำแนก

2)ใช้วิธี Cross-validation เพื่อตรวจสอบความแม่นยำของโมเดล

3)เพิ่มตัวแปรด้านเศรษฐกิจ เช่น GDP, การใช้พลังงาน, อัตราการเจริญเติบโตของอุตสาหกรรม เพื่อให้ผลการจำแนกสมบูรณ์มากขึ้น

4) พิจารณาการจัดการ Outlier เพื่อให้โมเดลมีความเสถียรและไม่ถูกเบี่ยงเบน

5.4 สิ่งที่ได้เรียนรู้จากโครงงานวิจัย

1)เรียนรู้การใช้ R Programming ในการทำ Discriminant Analysis และการสร้าง Visualization

2)เข้าใจความสัมพันธ์ระหว่างตัวแปรเชิงเศรษฐกิจและสิ่งแวดล้อม

3)ฝึกการตีความผลเชิงสถิติและการนำเสนอผลเชิงวิเคราะห์อย่างเป็นระบบ

4)ได้ประสบการณ์ในการจัดการ Outlier และตรวจสอบสมมติฐานของโมเดล

6. ภาคผนวก — คำสั่งและ output (สำคัญ)

Cluster Analysis

โหลดแพ็กเกจ

library(cluster)

library(dendextend)

library(factoextra)

attach(merged_data_fully_cleaned_EN..2)

ss <- sample(1:91, 10) # Take 10 random rows

df1 <- merged_data_fully_cleaned_EN..2[ss,] # Subset the 10 rows

That might be present in the data

df1 <- na.omit(merged_data_fully_cleaned_EN..2)

View the firt 6 rows of the data

head(df1, n = 6)

```
> head(df1, n = 6)
             GHG_Value SA_Value GCI_Value Air_Value
Afghanistan        5.4     68.4      35.5     12700
Albania            1.8      5.8      43.4     27500
Algeria           44.3      6.3      36.2      5300
Angola             7.3      9.4      47.7     52900
Argentina         48.4     11.5      60.8    323200
Armenia            2.5    150.0      78.7     88500
```

df1.scaled <- scale(df1)

head(round(df1.scaled, 2))

```
> head(round(df1.scaled, 2))
             GHG_Value SA_Value GCI_Value Air_Value
Afghanistan      -0.23    -0.22     -1.00     -0.47
Albania          -0.26    -0.62     -0.51     -0.39
Algeria           0.12    -0.62     -0.96     -0.52
Angola           -0.22    -0.60     -0.25     -0.24
Argentina         0.15    -0.59      0.55      1.34
Armenia          -0.26     0.30      1.65     -0.03
```

ระยะห่างระหว่าง ตัวแปร

Compute Euclidean pairwise distances

dist.eucl1 <- dist(df1.scaled, method = "euclidean")

View a subset of the distance matrices

round(as.matrix(dist.eucl1)[1:6, 1:6], 1)

###หาความสัมพันธ์ระหว่างตัวแปร

Compute correlation matrix

res.cor1 <- cor(t(df1.scaled), method = "pearson")

Compute distance matrix

dist.cor1 <- as.dist(1 - res.cor1)

round(as.matrix(dist.cor1)[1:6, 1:6], 1)

```
> round(as.matrix(dist.cor1)[1:6, 1:6], 1)
            Afghanistan Albania Algeria Angola Argentina Armenia
Afghanistan         0.0     0.8     0.3    1.4       1.4     1.9
Albania             0.8     0.0     0.2    0.2       0.5     1.5
Algeria             0.3     0.2     0.0    0.7       1.1     1.8
Angola              1.4     0.2     0.7    0.0       0.2     1.0
Argentina           1.4     0.5     1.1    0.2       0.0     1.0
Armenia             1.9     1.5     1.8    1.0       1.0     0.0
```

Hirachical Method

hclust(d1, method = "complete")

```
> hclust(d1, method = "complete")

Call:
hclust(d = d1, method = "complete")

Cluster method   : complete
Distance         : euclidean
Number of objects: 91
```

Dissimilarity matrix

d1 <- dist(df1, method = "euclidean")

```
# Hierarchical clustering using Ward's method
res.hc1 <- hclust(d1, method = "ward.D2" )
# Plot the obtained dendrogram
plot(res.hc1, cex = 0.6, hang = -1)
# Cut tree into 4 groups
grp1 <- cutree(res.hc1, k = 4)
```

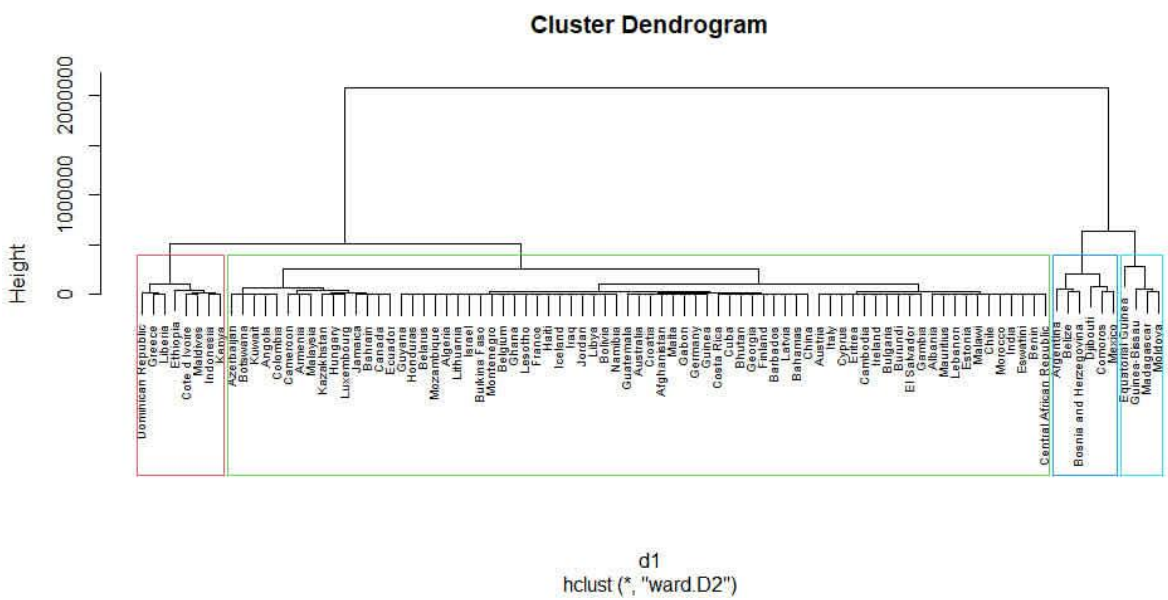


```
# Number of members in each cluster
table(grp1)
```

```
> table(grp1)
grp1
 1  2  3  4
73  6  8  4
```

```
# Get the names for the members of cluster 1
```

rownames(df1)[grp1 == 1]

```
> rownames(df1)[grp1 == 1]
 [1] "Afghanistan"          "Albania"              "Algeria"              "Angola"
 [5] "Armenia"              "Australia"            "Austria"              "Azerbaijan"
 [9] "Bahamas"              "Bahrain"              "Barbados"             "Belarus"
[13] "Belgium"              "Benin"                "Bhutan"               "Bolivia"
[17] "Botswana"             "Bulgaria"             "Burkina Faso"         "Burundi"
[21] "Cambodia"             "Cameroon"             "Canada"               "Central African Republic"
[25] "Chile"                "China"                "Colombia"             "Costa Rica"
[29] "Croatia"              "Cuba"                 "Cyprus"               "Ecuador"
[33] "El Salvador"          "Eritrea"              "Estonia"              "Eswatini"
[37] "Finland"              "France"               "Gabon"                "Gambia"
[41] "Georgia"              "Germany"              "Ghana"                "Guatemala"
[45] "Guinea"               "Guyana"               "Haiti"                "Honduras"
[49] "Hungary"              "Iceland"              "India"                "Iraq"
[53] "Ireland"              "Israel"               "Italy"                "Jamaica"
[57] "Jordan"               "Kazakhstan"           "Kuwait"               "Latvia"
[61] "Lebanon"              "Lesotho"              "Libya"                "Lithuania"
[65] "Luxembourg"           "Malawi"               "Malaysia"             "Malta"
[69] "Mauritius"            "Montenegro"           "Morocco"              "Mozambique"
[73] "Namibia"
```

plot(res.hc1, cex = 0.6)

rect.hclust(res.hc1, k = 4, border = 2:5)

###K-Means

head(merged_data_fully_cleaned_EN..2)

```
> head(merged_data_fully_cleaned_EN..2)
            GHG_Value SA_Value GCI_Value Air_Value
Afghanistan       5.4     68.4      35.5     12700
Albania           1.8      5.8      43.4     27500
Algeria          44.3      6.3      36.2      5300
Angola            7.3      9.4      47.7     52900
Argentina        48.4     11.5      60.8    323200
Armenia           2.5    150.0      78.7     88500
```

str(merged_data_fully_cleaned_EN..2)

```
> str(merged_data_fully_cleaned_EN..2)
'data.frame':   91 obs. of  4 variables:
 $ GHG_Value: num  5.4 1.8 44.3 7.3 48.4 2.5 90 22.9 7.9 0.45 ...
 $ SA_Value : num  68.4 5.8 6.3 9.4 11.5 ...
 $ GCI_Value: num  35.5 43.4 36.2 47.7 60.8 78.7 65.8 62.2 42.1 32.8 ...
 $ Air_Value: num  12700 27500 5300 52900 323200 ...
```

summary(merged_data_fully_cleaned_EN..2)

```
> summary(merged_data_fully_cleaned_EN..2)
   GHG_Value          SA_Value          GCI_Value         Air_Value
 Min.   :  0.08   Min.   :   3.20   Min.   :21.40   Min.   :   139.8
 1st Qu.:  1.30   1st Qu.:  17.95   1st Qu.:40.95   1st Qu.:  8950.0
 Median :  5.10   Median :  39.10   Median :49.10   Median : 26200.0
 Mean   : 31.39   Mean   : 102.58   Mean   :51.79   Mean   : 93720.2
 3rd Qu.: 16.45   3rd Qu.: 134.55   3rd Qu.:60.90   3rd Qu.: 75100.0
 Max.   :996.40   Max.   :1000.00   Max.   :91.70   Max.   :883400.0
```

```
library(corrplot)
corrplot(
  cor(merged_data_fully_cleaned_EN..2),
  method = "number",      # แสดงตัวเลข
  type = "lower",         # แสดงเฉพาะครึ่งล่าง
  col = colorRampPalette(c("red", "red", "blue"))(200), # ไล่สี
  tl.col = "black",       # สีตัวหนังสือชื่อแถว/คอลัมน์
  tl.srt = 45,            # หมุนชื่อ
  number.cex = 0.7,       # ขนาดตัวเลข
  addCoef.col = "black"   # สีตัวเลขค่าสหสัมพันธ์
)
```

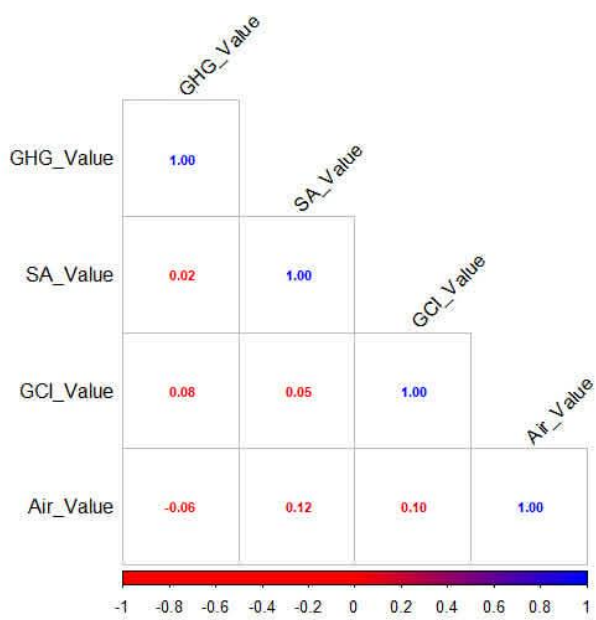

##แปลงเป็น Z

mu <- scale(merged_data_fully_cleaned_EN..2)

dim(mu)

```
> mu <- scale(merged_data_fully_cleaned_EN..2)
> dim(mu)
[1] 91  4
```

head(mu,n=5)

```
> head(mu,n=5)
             GHG_Value   SA_Value  GCI_Value  Air_Value
Afghanistan -0.2325006 -0.2197046 -0.9994266 -0.4747765
Albania     -0.2647079 -0.6221256 -0.5148786 -0.3880489
Algeria      0.1155179 -0.6189114 -0.9564920 -0.5181404
Angola      -0.2155023 -0.5989832 -0.2511373 -0.2392055
Argentina    0.1521985 -0.5854835  0.5523537  1.3447463
```

library(cluster)

library(factoextra)

##เตรียมข้อมูลเพื่อวิเคราะห์ cluster

set.seed(123)

crime <- sample(1:91,10)

crime_1 <- mu[crime,]

head(crime_1)

```
> head(crime_1)
             GHG_Value   SA_Value  GCI_Value  Air_Value
Comoros    -0.27875393  0.6384934  0.5646208  2.0286056
Luxembourg -0.23518453 -0.2608467  1.3067766 -0.1706437
Germany     1.07279222  0.6365649  1.3129101 -0.4665726
Belgium    -0.06967447 -0.6214828 -0.6375490 -0.5434180
Italy       0.62009986 -0.4922709 -0.4658105 -0.3364811
Eritrea    -0.27875393 -0.5848406 -1.6189121 -0.3306211
```

dist.eucl1 <- dist(crime_1, method = "euclidean")

head(dist.eucl1)

```
> head(dist.eucl1)
[1] 2.489619 2.934712 3.113161 2.956686 3.439522 2.580576
```

round(as.matrix(dist.eucl1)[1:4, 1:4], 2)

```
> round(as.matrix(dist.eucl1)[1:4, 1:4], 2)
           Comoros Luxembourg Germany Belgium
Comoros       0.00       2.49    2.93    3.11
Luxembourg    2.49       0.00    1.61    2.02
Germany       2.93       1.61    0.00    2.59
Belgium       3.11       2.02    2.59    0.00
```

fviz_dist(dist.eucl1)

##หาจำนวน cluster

wss <- sapply(1:crime,

function(k){kmeans(merged_data_fully_cleaned_EN..2, k, nstart=20,iter.max = 15

)$tot.withinss})

plot(1:crime, wss,

type="b", pch = 19, frame = FALSE,

xlab="Number of clusters K",

ylab="Total within-clusters sum of squares")

fviz_nbclust(mu, kmeans, method = 'wss') +

geom_vline(xintercept = 4, linetype=5, col= "darkred")

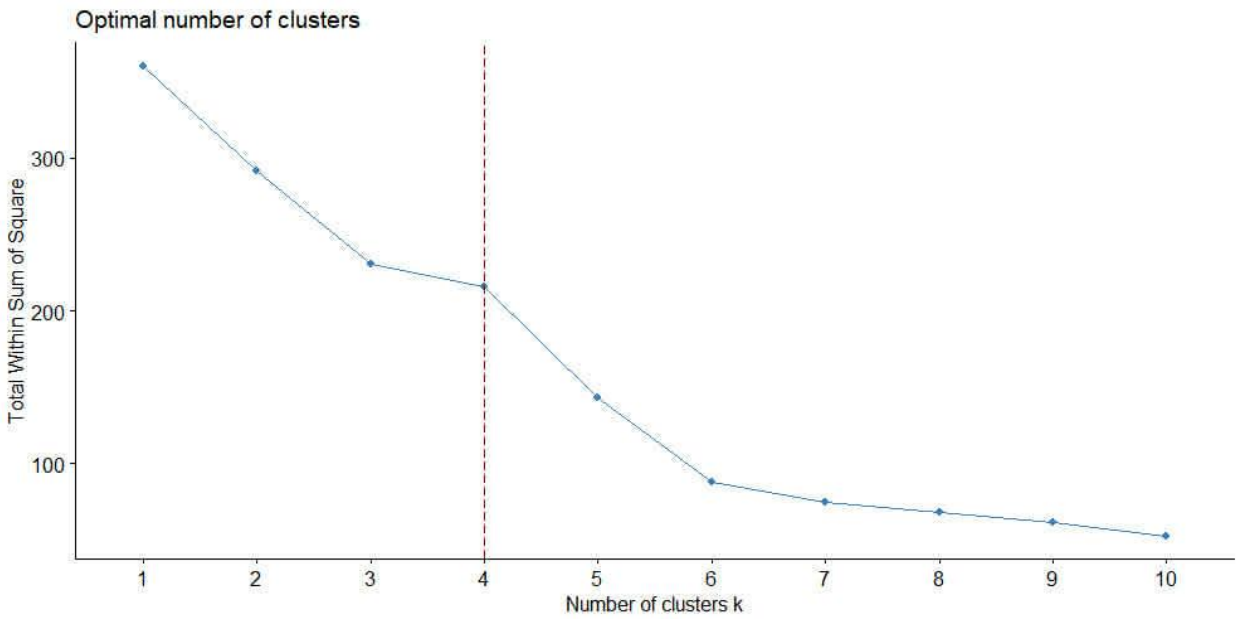

##วิเคราะห์K-Means

km.res <- kmeans(mu, 4, nstart = 20)

km.res

```
> km.res
K-means clustering with 4 clusters of sizes 46, 32, 12, 1

Cluster means:
    GHG_Value   SA_Value  GCI_Value  Air_Value
1 -0.09897812 -0.2715375 -0.7372854 -0.2813032
2 -0.10367113 -0.1889686  0.9056061 -0.2353782
3 -0.06358340  1.5263160  0.3157021  1.7480103
4  8.63347042  0.2219299  1.1473051 -0.5040764
```

summary(km.res)

```
> summary(km.res)
            Length Class  Mode
cluster     91     -none- numeric
centers     16     -none- numeric
totss        1     -none- numeric
withinss     4     -none- numeric
tot.withinss 1     -none- numeric
betweenss    1     -none- numeric
size         4     -none- numeric
iter         1     -none- numeric
ifault       1     -none- numeric
```

km.res$totss

km.res$betweenss

204.0141/360

```
> km.res$totss
[1] 360
> km.res$betweenss
[1] 204.0141
> 204.0141/360
[1] 0.5667058
```

##ใส่เลขกลุ่ม cluster ในData แรกเริ่ม

df_member <- cbind(mu, cluster = km.res$cluster)

head(df_member,10)

```
> head(df_member,10)
              GHG_Value   SA_Value  GCI_Value  Air_Value cluster
Afghanistan -0.23250058 -0.2197046 -0.9994266 -0.4747765       1
Albania     -0.26470794 -0.6221256 -0.5148786 -0.3880489       1
Algeria      0.11551786 -0.6189114 -0.9564920 -0.5181404       1
Angola      -0.21550225 -0.5989832 -0.2511373 -0.2392055       1
Argentina    0.15219846 -0.5854835  0.5523537  1.3447463       2
Armenia     -0.25844540  0.3048569  1.6502537 -0.0305903       2
Australia    0.52437242 -0.2158476  0.8590297 -0.4560246       2
Austria     -0.07593702  3.5852950  0.6382230 -0.3189012       3
Azerbaijan  -0.21013436  0.6854211 -0.5946144 -0.2843273       1
Bahamas     -0.27678570  1.9119694 -1.1650317 -0.5046624       1
```

```
Within cluster sum of squares by cluster:
[1] 41.38609 30.32705 84.27275  0.00000
 (between_SS / total_SS =  56.7 %)

Available components:

[1] "cluster"      "centers"      "totss"        "withinss"     "tot.withinss" "betweenss"    "size"
[8] "iter"         "ifault"
```

fviz_cluster(km.res, data = mu,

palette=c("red", "blue", "black", "darkgreen"),

ellipse.type = "euclid",

star.plot = T,

repel = T,

ggtheme = theme())

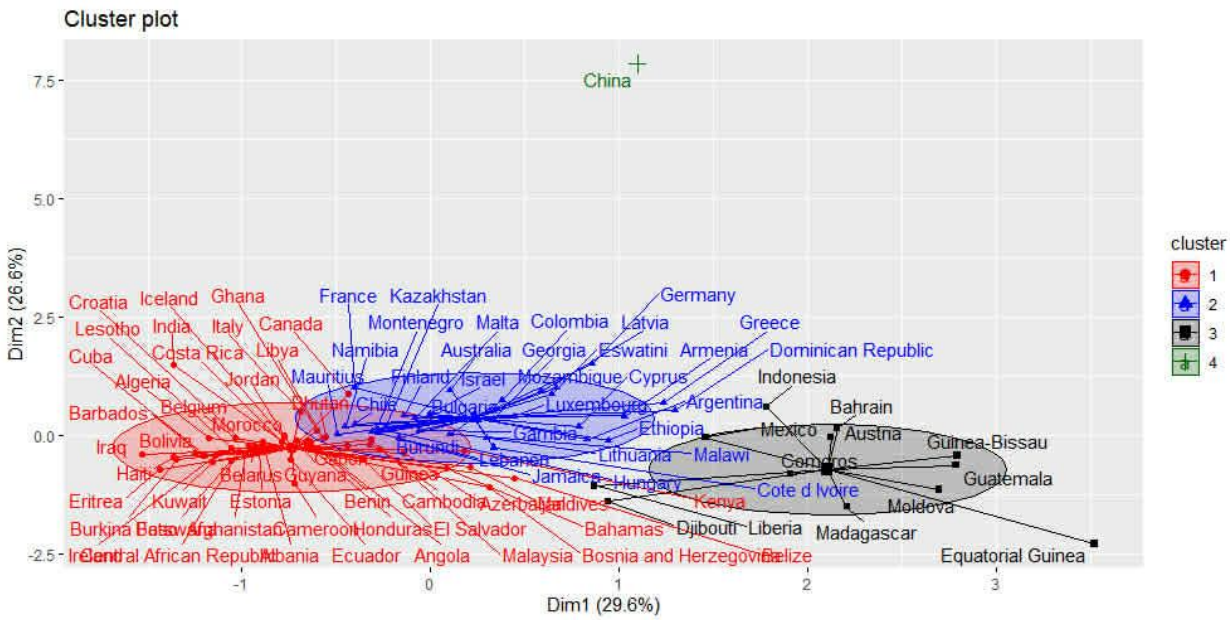

library(dplyr)

df_member %>%

```
> df_member %>%
+   as.data.frame() %>%
+   group_by(cluster) %>%
+   summarise(across(everything(), list(mean = mean, sd = sd), .names = "{.col}_{.fn}"))
# A tibble: 4 x 9
  cluster GHG_Value_mean GHG_Value_sd SA_Value_mean SA_Value_sd GCI_Value_mean GCI_Value_sd Air_Value_mean
    <dbl>          <dbl>        <dbl>         <dbl>       <dbl>          <dbl>        <dbl>          <dbl>
1       1        -0.0990        0.458        -0.272       0.499         -0.737        0.490         -0.281
2       2        -0.104         0.320        -0.189       0.447          0.906        0.712         -0.235
3       3        -0.0636        0.428         1.53        1.91           0.316        0.940          1.75
4       4         8.63         NA             0.222      NA              1.15        NA            -0.504
# i 1 more variable: Air_Value_sd <dbl>
```

as.data.frame() %>%

group_by(cluster) %>%

summarise(across(everything(), list(mean = mean, sd = sd), .names = "{.col}_{.fn}"))

library(psych)

describeBy(mu, group = km.res$cluster)

```
> describeBy(mu, group = km.res$cluster)

 Descriptive statistics by group
INDICES: 1
          vars  n  mean   sd median trimmed  mad   min  max range  skew kurtosis   se
GHG_Value    1 46 -0.10 0.46  -0.24   -0.21 0.06 -0.28 2.43  2.71  4.19    18.67 0.07
SA_Value     2 46 -0.27 0.50  -0.49   -0.36 0.16 -0.64 1.91  2.55  2.29     6.04 0.07
GCI_Value    3 46 -0.74 0.49  -0.62   -0.71 0.52 -1.86 0.04  1.90 -0.54    -0.49 0.07
Air_Value    4 46 -0.28 0.47  -0.45   -0.39 0.13 -0.55 1.71  2.26  3.03     9.16 0.07
-------------------------------------------------------------------------------------
INDICES: 2
          vars  n  mean   sd median trimmed  mad   min  max range skew kurtosis   se
GHG_Value    1 32 -0.10 0.32  -0.23   -0.19 0.06 -0.28 1.07  1.35 2.47     5.31 0.06
SA_Value     2 32 -0.19 0.45  -0.32   -0.26 0.37 -0.60 1.03  1.64 1.20     0.56 0.08
GCI_Value    3 32  0.91 0.71   0.86    0.83 0.76  0.13 2.45  2.32 0.84    -0.58 0.13
Air_Value    4 32 -0.24 0.41  -0.39   -0.32 0.19 -0.54 1.34  1.88 2.20     4.97 0.07
-------------------------------------------------------------------------------------
INDICES: 3
          vars  n  mean   sd median trimmed  mad   min  max range skew kurtosis   se
GHG_Value    1 12 -0.06 0.43  -0.26   -0.15 0.02 -0.28 0.98  1.26 1.58     0.77 0.12
SA_Value     2 12  1.53 1.91   1.16    1.31 2.14 -0.53 5.77  6.30 0.73    -0.52 0.55
GCI_Value    3 12  0.32 0.94   0.41    0.28 0.78 -1.24 2.20  3.43 0.28    -0.69 0.27
Air_Value    4 12  1.75 1.72   2.11    1.68 2.16 -0.45 4.63  5.08 0.06    -1.59 0.50
-------------------------------------------------------------------------------------
INDICES: 4
          vars n  mean sd median trimmed mad   min   max range skew kurtosis se
GHG_Value    1 1  8.63 NA   8.63    8.63   0  8.63  8.63     0   NA       NA NA
SA_Value     2 1  0.22 NA   0.22    0.22   0  0.22  0.22     0   NA       NA NA
GCI_Value    3 1  1.15 NA   1.15    1.15   0  1.15  1.15     0   NA       NA NA
Air_Value    4 1 -0.50 NA  -0.50   -0.50   0 -0.50 -0.50     0   NA       NA NA
```

Discriminant Analysis

install.packages("tidyverse")

install.packages("corrplot")

```
install.packages("skimr")

# โหลดไลบรารี

library(tidyverse) # สำหรับการจัดการข้อมูลและการสร้างภาพข้อมูล

library(corrplot)  # สำหรับสร้าง Correlation Plot

library(skimr)     # สำหรับสรุปสถิติอย่างรวดเร็ว

data <- multi_data

# แปลงคอลัมน์ 'Class' ให้เป็น Factor (ข้อมูลประเภทกลุ่ม)

data$Class <- as.factor(data$Class)

str(data)
```

```
> data$Class <- as.factor(data$Class)
> str(data)
tibble [91 × 5] (S3: tbl_df/tbl/data.frame)
 $ GHG_Value: num [1:91] 5.4 1.8 44.3 7.3 48.4 2.5 90 22.9
7.9 0.45 ...
 $ SA_Value : num [1:91] 68.4 5.8 6.3 9.4 11.5 ...
 $ GCI_Value: num [1:91] 35.5 43.4 36.2 47.7 60.8 78.7 65.8
62.2 42.1 32.8 ...
 $ Air_Value: num [1:91] 12700 27500 5300 52900 323200 ...
 $ Class    : Factor w/ 4 levels "1","2","3","4": 2 2 2 2 3
2 2 2 2 2 ...
```

```
head(data)
```

```
2 2 2 2 2 ...
> head(data)
# A tibble: 6 × 5
  GHG_Value SA_Value GCI_Value Air_Value Class
      <dbl>    <dbl>     <dbl>     <dbl> <fct>
1       5.4     68.4      35.5     12700 2
2       1.8      5.8      43.4     27500 2
3      44.3      6.3      36.2      5300 2
4       7.3      9.4      47.7     52900 2
5      48.4     11.5      60.8    323200 3
6       2.5    150        78.7     88500 2
```

```
#skim(data)

summary(data)

summary(data %>% select(-Class))
```

```
> summary(data %>% select(-Class))
   GHG_Value         SA_Value         GCI_Value
 Min.   :  0.08   Min.   :   3.20   Min.   :21.40
 1st Qu.:  1.30   1st Qu.:  17.95   1st Qu.:40.95
 Median :  5.10   Median :  39.10   Median :49.10
 Mean   : 31.39   Mean   : 102.58   Mean   :51.79
 3rd Qu.: 16.45   3rd Qu.: 134.55   3rd Qu.:60.90
 Max.   :996.40   Max.   :1000.00   Max.   :91.70
   Air_Value
 Min.   :   139.8
 1st Qu.:  8950.0
 Median : 26200.0
 Mean   : 93720.2
 3rd Qu.: 75100.0
 Max.   :883400.0
```

```
# การสร้างฮิสโตแกรมเพื่อดูการกระจายตัว (Distribution) ของ GHG_Value

ggplot(data, aes(x = GHG_Value)) +

  geom_histogram(binwidth = 10, fill = "skyblue", color = "black") +

  labs(title = "Distribution of GHG_Value", x = "GHG Value", y = "Frequency") +

  theme_minimal()
```

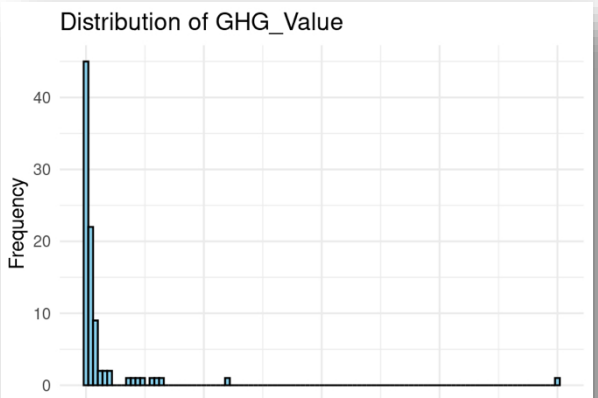

```
# การสร้าง Box Plot เพื่อตรวจหา Outliers ของ Air_Value

ggplot(data, aes(y = Air_Value)) +

  geom_boxplot(fill = "lightgreen") +

  labs(title = "Box Plot of Air_Value", y = "Air Value") +

  theme_minimal()
```

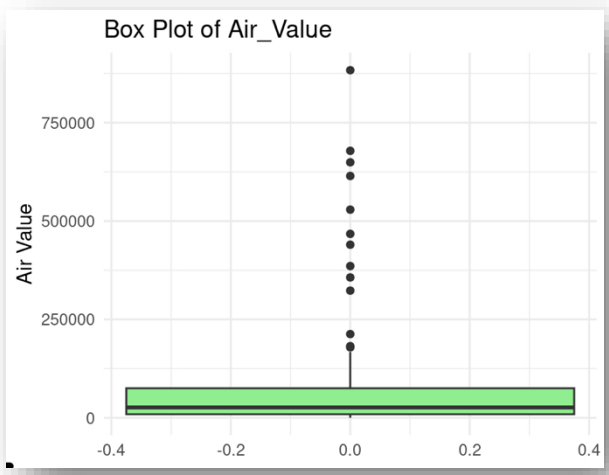


```
ggplot(data, aes(x = SA_Value)) +

  geom_histogram(binwidth = 10, fill = "skyblue", color = "black") +

  labs(title = "Distribution of SA_value", x = "SA value", y = "Frequency") +
```

theme_minimal()

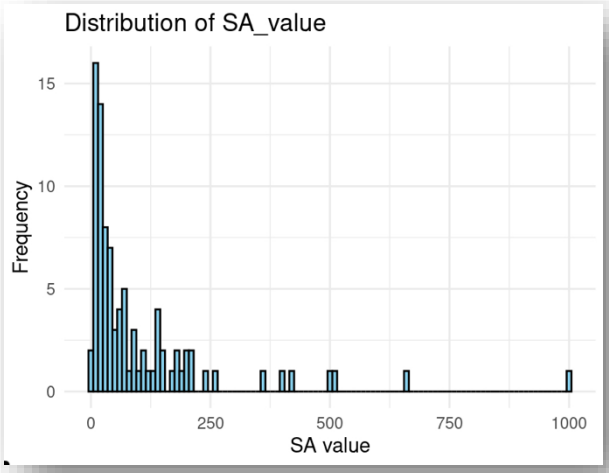

ggplot(data, aes(x = GCI_Value)) +

geom_histogram(binwidth = 10, fill = "skyblue", color = "black") +

labs(title = "Distribution of GCi_Value", x = "GCI Value", y = "Frequency") +

theme_minimal()

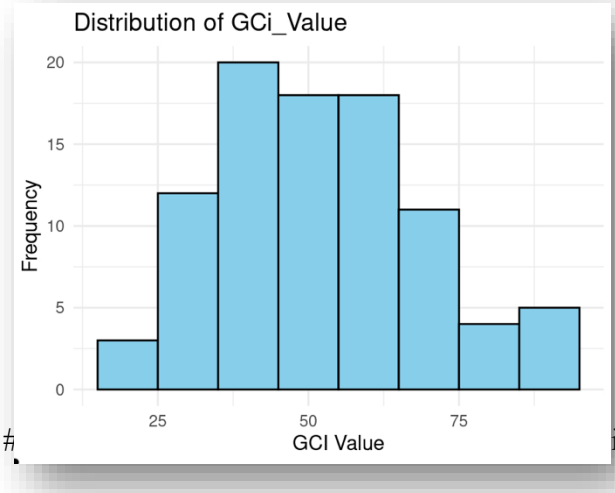

iable: Class)

การนับความถี่ของแต่ละ Class

data %>%

```
  count(Class) %>%

  mutate(percent = n / sum(n) * 100)
```

```
+   count(Class) %>%
+   mutate(percent = n / sum(n) * 100)
# A tibble: 4 × 3
  Class     n percent
  <fct> <int>   <dbl>
1 1         8    8.79
2 2        73   80.2
3 3         6    6.59
4 4         4    4.40
```

```
# การสร้าง Bar Chart แสดงสัดส่วนของ Class

ggplot(data, aes(x = Class, fill = Class)) +

  geom_bar() +

  labs(title = "Count of Observations by Class", y = "Count") +

  theme_minimal()
```

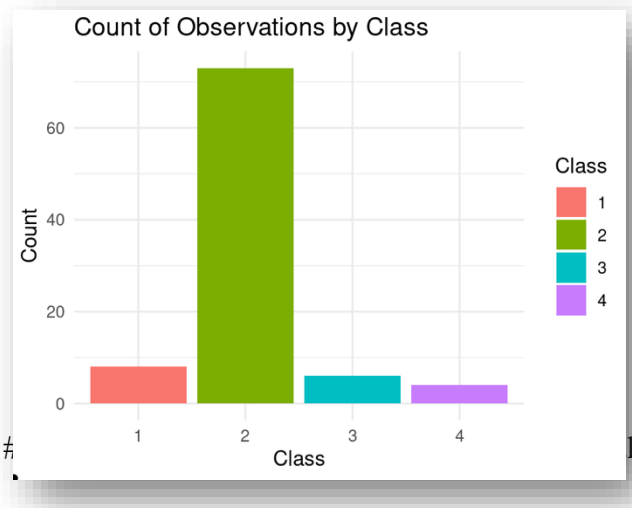


```
#                                                    lysis)

M <- cor(data %>% select(GHG_Value, SA_Value, GCI_Value, Air_Value))

# สร้าง Correlation Plot เพื่อแสดงความสัมพันธ์
```

```
corrplot(M, method = "circle", type = "upper", tl.col = "black", tl.srt = 45,
        addCoef.col = "black")
```

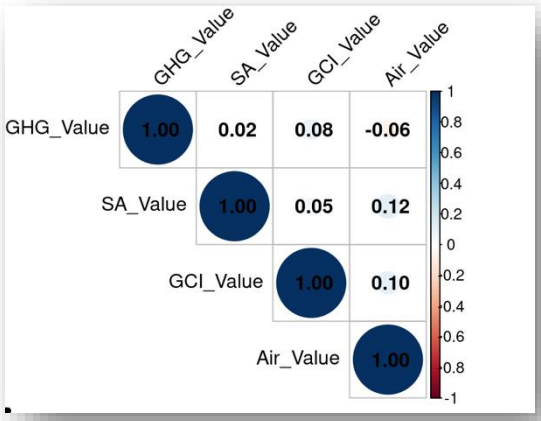

ตรวจสอบว่าตัวแปรใดมีความสัมพันธ์กันสูง (เข้าใกล้ 1 หรือ -1)

การสร้าง Scatter Plot เพื่อดูความสัมพันธ์ระหว่างสองตัวแปร (เช่น GHG vs SA)

```
ggplot(data, aes(x = GHG_Value, y = SA_Value, color = Class)) +
  geom_point(alpha = 0.6) +
  labs(title = "GHG_Value vs SA_Value, grouped by Class",
       x = "GHG Value", y = "SA Value") +
  theme_minimal()
```

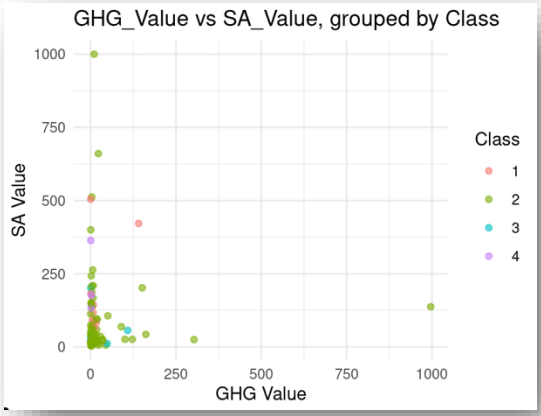

การเปรียบเทียบค่าเฉลี่ยตาม Class

เปรียบเทียบค่าเฉลี่ยของ GCI_Value ในแต่ละ Class

```
data %>%
  group_by(Class) %>%
  summarise(
    mean_GCI = mean(GCI_Value),
    median_GCI = median(GCI_Value),
    count = n()
  )
```

```
+   group_by(Class) %>%
+   summarise(
+     mean_GCI = mean(GCI_Value),
+     median_GCI = median(GCI_Value),
+     count = n()
+   )
# A tibble: 4 × 4
  Class mean_GCI median_GCI count
  <fct>    <dbl>      <dbl> <int>
1 1         59.9       57.4     8
2 2         50.5       47.7    73
3 3         50.8       51.7     6
4 4         61.6       57.8     4
> # สร้าง Box Plot เพื่อเปรียบเทียบการกระจายของ GCI_Value ตาม Class
> ggplot(data, aes(x = Class, y = GCI_Value, fill = Class))
+
```

```
# สร้าง Box Plot เพื่อเปรียบเทียบการกระจายของ GCI_Value ตาม Class

ggplot(data, aes(x = Class, y = GCI_Value, fill = Class)) +

  geom_boxplot() +

  labs(title = "GCI_Value Distribution by Class", y = "GCI Value") +

  theme_minimal()
```

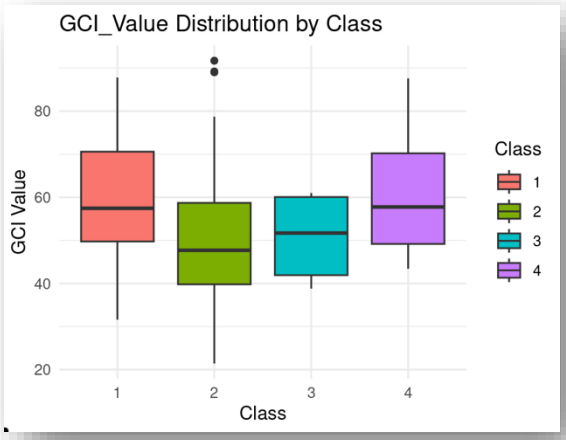

7.เอกสารอ้างอิง

ข้อมูลทั้งหมดนำมาจาก

WHO data

https://data360.worldbank.org/en/indicator/FAO_CAHD_7010?view=datatable

https://data360.worldbank.org/en/indicator/WRI_CLIMATEWATCH_ALL_GHG_TRANSPORT

https://data360.worldbank.org/en/indicator/WEF_TTDI_ROADDENS

https://data360.worldbank.org/en/indicator/WEF_TTDI_TTDI_C_09

https://data360.worldbank.org/en/indicator/WEF_TTDI_IATACONNECTIDX